Multicolinealidad Perfecta: Correlaciones Parciales y Coeficientes de Determinación bajo Dependencia Lineal Exacta

Derivación completa desde primeros principios

Ejercicio 10.4 — *Econometría*, Gujarati & Porter, 5.ª ed.

Con álgebra matricial, geometría de correlación y todas las demostraciones

Planteamiento del problema. Se afirma que la relación

$$\lambda_1 X_{1i} + \lambda_2 X_{2i} + \lambda_3 X_{3i} = 0 \qquad \text{para todo } i = 1, \ldots, n \tag{1}$$

se mantiene con $\lambda_1, \lambda_2, \lambda_3$ no todos simultáneamente cero. Se pide:

(a) Estimar las correlaciones parciales $r_{12\cdot 3}$, $r_{13\cdot 2}$ y $r_{23\cdot 1}$.

(b) Encontrar los coeficientes de determinación $R^2_{1\cdot 23}$, $R^2_{2\cdot 13}$ y $R^2_{3\cdot 12}$.

(c) Determinar el grado de multicolinealidad en esta situación.

1. Fundamentos y definiciones

1.1. Correlación simple entre dos variables

Dadas n observaciones de dos variables X_j y X_k, la **correlación de Pearson** es:

$$r_{jk} = \frac{\displaystyle\sum_{i=1}^{n}(X_{ji} - \bar{X}_j)(X_{ki} - \bar{X}_k)}{\sqrt{\displaystyle\sum_{i=1}^{n}(X_{ji} - \bar{X}_j)^2}\sqrt{\displaystyle\sum_{i=1}^{n}(X_{ki} - \bar{X}_k)^2}} = \frac{\sum x_{ji}\, x_{ki}}{\sqrt{\sum x_{ji}^2 \, \sum x_{ki}^2}} \tag{2}$$

donde $x_{ji} = X_{ji} - \bar{X}_j$ denota la desviación respecto a la media. Por la desigualdad de Cauchy-Schwarz, $-1 \leq r_{jk} \leq 1$, con $|r_{jk}| = 1$ si y sólo si existe una relación lineal exacta entre X_j y X_k.

1.2. Correlación parcial: concepto y fórmula

La **correlación parcial** $r_{jk\cdot\ell}$ mide la asociación lineal entre X_j y X_k una vez que se ha eliminado la influencia de una tercera variable X_ℓ. Formalmente, sea:

$$\tilde{X}_{ji} = X_{ji} - \hat{X}_{ji}^{(\ell)} \tag{3}$$

$$\tilde{X}_{ki} = X_{ki} - \hat{X}_{ki}^{(\ell)} \tag{4}$$

donde $\hat{X}_{ji}^{(\ell)}$ y $\hat{X}_{ki}^{(\ell)}$ son los valores ajustados de las regresiones de X_j y X_k sobre X_ℓ, respectivamente. Entonces:

$$r_{jk\cdot\ell} = \frac{\sum_i \tilde{X}_{ji}\,\tilde{X}_{ki}}{\sqrt{\sum_i \tilde{X}_{ji}^2}\sqrt{\sum_i \tilde{X}_{ki}^2}} \tag{5}$$

Existe además una fórmula equivalente en términos de correlaciones simples que evita calcular residuos explícitamente:

$$\boxed{r_{jk\cdot\ell} = \frac{r_{jk} - r_{j\ell}\,r_{k\ell}}{\sqrt{(1 - r_{j\ell}^2)(1 - r_{k\ell}^2)}}} \tag{6}$$

Esta fórmula será el instrumento central del ejercicio.

1.3. Coeficiente de determinación R^2

En la regresión de X_j sobre un conjunto de regresores $\mathbf{Z}$:

$$X_{ji} = \gamma_0 + \gamma_1 Z_{1i} + \cdots + \gamma_p Z_{pi} + v_i \tag{7}$$

el **coeficiente de determinación** mide la fracción de la varianza de X_j explicada linealmente por $\mathbf{Z}$:

$$R^2 = 1 - \frac{\text{SCR}}{\text{SCT}} = 1 - \frac{\sum \hat{v}_i^2}{\sum (X_{ji} - \bar{X}_j)^2} \tag{8}$$

donde SCR es la suma de cuadrados de los residuos y SCT la suma de cuadrados total. Se tiene $0 \leq R^2 \leq 1$, con $R^2 = 1$ si y sólo si el ajuste es perfecto ($\hat{v}_i = 0$ para todo i).

1.4. Relación entre R^2 y correlaciones parciales

Para la regresión de X_1 sobre X_2 y X_3 existe la siguiente identidad:

$$R^2_{1\cdot 23} = r^2_{12} + r^2_{13,2}(1 - r^2_{12}) = r^2_{13} + r^2_{12,3}(1 - r^2_{13}) \tag{9}$$

Es decir, el R^2 múltiple se puede descomponer como la contribución marginal de cada regresor al conjunto.

2. Análisis de la condición de multicolinealidad perfecta

2.1. Qué implica la ecuación (1)

La condición $\lambda_1 X_{1i} + \lambda_2 X_{2i} + \lambda_3 X_{3i} = 0$ con λ_j no todos nulos significa que las tres variables viven en un subespacio de dimensión dos (o menor) del espacio $\mathbb{R}^n$. En particular, asumiendo $\lambda_1 \neq 0$, podemos despejar:

$$X_{1i} = -\frac{\lambda_2}{\lambda_1} X_{2i} - \frac{\lambda_3}{\lambda_1} X_{3i} \tag{10}$$

Es decir, X_1 es una *combinación lineal exacta* de X_2 y X_3, sin término de error. Esto es la definición formal de **multicolinealidad perfecta**.

2.2. Implicación para las medias

Sumando (1) sobre los n individuos y dividiendo por n:

$$\lambda_1 \bar{X}_1 + \lambda_2 \bar{X}_2 + \lambda_3 \bar{X}_3 = 0 \tag{11}$$

Restando (11) de (1) observación a observación:

$$\lambda_1 x_{1i} + \lambda_2 x_{2i} + \lambda_3 x_{3i} = 0 \tag{12}$$

donde $x_{ji} = X_{ji} - \bar{X}_j$. **La relación lineal exacta se preserva en las desviaciones respecto a la media.** Esto es crucial porque las sumas necesarias para calcular correlaciones y R^2 se expresan en desviaciones.

3. Cálculo de los coeficientes de determinación

3.1. $R^2_{1\cdot 23} = 1$

Queremos regresar X_1 sobre X_2 y X_3. Pero por (10), la relación exacta

$$X_{1i} = \underbrace{-\frac{\lambda_2}{\lambda_1}}_{=\gamma_2} X_{2i} + \underbrace{-\frac{\lambda_3}{\lambda_1}}_{=\gamma_3} X_{3i} + \underbrace{0}_{=v_i} \tag{13}$$

ya es la regresión de X_1 sobre X_2 y X_3 con residuos idénticamente nulos. Por la definición (8):

$$R^2_{1\cdot 23} = 1 - \frac{\sum \hat{v}_i^2}{\sum x_{1i}^2} = 1 - \frac{0}{\sum x_{1i}^2} = \boxed{1} \tag{14}$$

Interpretación: X_2 y X_3 explican el 100 % de la variación de X_1. No queda variación sin explicar.

3.2. $R^2_{2\cdot 13} = 1$

Asumiendo $\lambda_2 \neq 0$, de (1) se tiene:

$$X_{2i} = -\frac{\lambda_1}{\lambda_2} X_{1i} - \frac{\lambda_3}{\lambda_2} X_{3i} \tag{15}$$

La regresión de X_2 sobre X_1 y X_3 tiene residuos nulos, por lo que:

$$R^2_{2\cdot 13} = 1 - \frac{0}{\sum x_{2i}^2} = \boxed{1} \tag{16}$$

3.3. $R^2_{3\cdot 12} = 1$

Asumiendo $\lambda_3 \neq 0$:

$$X_{3i} = -\frac{\lambda_1}{\lambda_3} X_{1i} - \frac{\lambda_2}{\lambda_3} X_{2i} \tag{17}$$

Por el mismo argumento:

$$R^2_{3\cdot 12} = 1 - \frac{0}{\sum x_{3i}^2} = \boxed{1} \tag{18}$$

Resultado general. Bajo multicolinealidad perfecta entre k variables, el R^2 de la regresión de cualquiera de ellas sobre las demás $k-1$ es exactamente igual a 1. No hay grado de libertad para el error porque la relación no admite perturbaciones.

4. Cálculo de las correlaciones parciales

Usaremos la fórmula (6) junto con las sumas en desviaciones derivadas de (12).

4.1. Expresiones para las correlaciones simples

Las correlaciones simples entre cualquier par de variables se calculan como:

$$r_{jk} = \frac{\sum x_{ji}x_{ki}}{\sqrt{\sum x_{ji}^2 \sum x_{ki}^2}} \tag{19}$$

De (12):

$$x_{1i} = -\frac{\lambda_2}{\lambda_1}x_{2i} - \frac{\lambda_3}{\lambda_1}x_{3i} \tag{20}$$

Introducimos la notación compacta: $a = -\lambda_2/\lambda_1$ y $b = -\lambda_3/\lambda_1$, de modo que $x_{1i} = a\,x_{2i} + b\,x_{3i}$. Asimismo definamos:

$$S_{22} = \sum x_{2i}^2, \quad S_{33} = \sum x_{3i}^2, \quad S_{23} = \sum x_{2i}x_{3i} \tag{21}$$

Entonces:

$$S_{11} = \sum x_{1i}^2 = a^2 S_{22} + 2ab\,S_{23} + b^2 S_{33} \tag{22}$$

$$S_{12} = \sum x_{1i}x_{2i} = a\,S_{22} + b\,S_{23} \tag{23}$$

$$S_{13} = \sum x_{1i}x_{3i} = a\,S_{23} + b\,S_{33} \tag{24}$$

Por lo tanto las correlaciones simples son:

$$r_{12} = \frac{S_{12}}{\sqrt{S_{11}S_{22}}} = \frac{a\,S_{22} + b\,S_{23}}{\sqrt{(a^2S_{22} + 2abS_{23} + b^2S_{33})S_{22}}} \tag{25}$$

$$r_{13} = \frac{S_{13}}{\sqrt{S_{11}S_{33}}} = \frac{a\,S_{23} + b\,S_{33}}{\sqrt{(a^2S_{22} + 2abS_{23} + b^2S_{33})S_{33}}} \tag{26}$$

$$r_{23} = \frac{S_{23}}{\sqrt{S_{22}S_{33}}} \tag{27}$$

4.2. Cálculo de $r_{12\cdot 3}$

Aplicamos (6) con $j = 1$, $k = 2$, $\ell = 3$:

$$r_{12\cdot 3} = \frac{r_{12} - r_{13}\, r_{23}}{\sqrt{(1 - r_{13}^2)(1 - r_{23}^2)}} \tag{28}$$

Para evaluar esto utilizamos la relación $x_{1i} = ax_{2i} + bx_{3i}$ y un resultado auxiliar fundamental:

Lema 1. *Si $x_{1i} = ax_{2i} + bx_{3i}$ para todo i, entonces:*

$$r_{12} - r_{13}r_{23} = \frac{aS_{22}(1 - r_{23}^2)}{\sqrt{S_{11}S_{22}}} \tag{29}$$

Demostración. Expandimos el numerador $r_{12} - r_{13}r_{23}$:

$$\begin{aligned}
r_{12} - r_{13}r_{23} &= \frac{S_{12}}{\sqrt{S_{11}S_{22}}} - \frac{S_{13}}{\sqrt{S_{11}S_{33}}} \cdot \frac{S_{23}}{\sqrt{S_{22}S_{33}}} \\
&= \frac{1}{\sqrt{S_{11}S_{22}}} \left(S_{12} - \frac{S_{13}S_{23}}{S_{33}} \right) \\
&= \frac{1}{\sqrt{S_{11}S_{22}}} \left[(aS_{22} + bS_{23}) - \frac{(aS_{23} + bS_{33})S_{23}}{S_{33}} \right] \\
&= \frac{1}{\sqrt{S_{11}S_{22}}} \left[aS_{22} + bS_{23} - aS_{23}\frac{S_{23}}{S_{33}} - bS_{23} \right] \\
&= \frac{1}{\sqrt{S_{11}S_{22}}} \left[aS_{22} - a\frac{S_{23}^2}{S_{33}} \right] \\
&= \frac{a\, S_{22}}{\sqrt{S_{11}S_{22}}} \left[1 - \frac{S_{23}^2}{S_{22}S_{33}} \right] = \frac{a\, S_{22}}{\sqrt{S_{11}S_{22}}}(1 - r_{23}^2)
\end{aligned}$$

□

Ahora evaluamos el denominador de (28). Para $1 - r_{13}^2$:

$$1 - r_{13}^2 = 1 - \frac{S_{13}^2}{S_{11}S_{33}} = \frac{S_{11}S_{33} - S_{13}^2}{S_{11}S_{33}} \tag{30}$$

Calculamos $S_{11}S_{33} - S_{13}^2$:

$$\begin{aligned} S_{11}S_{33} &= (a^2S_{22} + 2abS_{23} + b^2S_{33})S_{33} \\ S_{13}^2 &= (aS_{23} + bS_{33})^2 = a^2S_{23}^2 + 2abS_{23}S_{33} + b^2S_{33}^2 \\ S_{11}S_{33} - S_{13}^2 &= a^2(S_{22}S_{33} - S_{23}^2) = a^2S_{22}S_{33}(1 - r_{23}^2) \end{aligned} \tag{31}$$

Por tanto:

$$1 - r_{13}^2 = \frac{a^2S_{22}S_{33}(1 - r_{23}^2)}{S_{11}S_{33}} = \frac{a^2S_{22}(1 - r_{23}^2)}{S_{11}} \tag{32}$$

Análogamente para $1 - r_{23}^2$ (ya conocida). Entonces el denominador de (28) es:

$$\begin{aligned} \sqrt{(1 - r_{13}^2)(1 - r_{23}^2)} &= \sqrt{\frac{a^2S_{22}(1 - r_{23}^2)}{S_{11}} \cdot (1 - r_{23}^2)} \\ &= \frac{|a|\sqrt{S_{22}}}{\sqrt{S_{11}}}(1 - r_{23}^2) \end{aligned} \tag{33}$$

Finalmente, sustituyendo (29) y (33) en (28):

$$r_{12\cdot3} = \frac{\dfrac{a\,S_{22}(1 - r_{23}^2)}{\sqrt{S_{11}S_{22}}}}{\dfrac{|a|\sqrt{S_{22}}}{\sqrt{S_{11}}}(1 - r_{23}^2)} = \frac{a\,S_{22}(1 - r_{23}^2)}{\sqrt{S_{11}S_{22}}} \cdot \frac{\sqrt{S_{11}}}{|a|\sqrt{S_{22}}(1 - r_{23}^2)} = \frac{a}{|a|} = \pm 1 \tag{34}$$

$$r_{12\cdot3} = \pm 1$$

El signo es $+1$ si $a = -\lambda_2/\lambda_1 > 0$, y -1 si $a < 0$. Es decir, el signo depende de si λ_1 y λ_2 tienen signos iguales u opuestos.

4.3. Cálculo de $r_{13\cdot2}$

Por simetría del argumento anterior, ahora usamos la representación $x_{1i} = ax_{2i} + bx_{3i}$ y controlamos por X_2 en lugar de X_3.

$$r_{13\cdot 2} = \frac{r_{13} - r_{12}\, r_{23}}{\sqrt{(1-r_{12}^2)(1-r_{23}^2)}} \tag{35}$$

Calculamos el numerador:

$$\begin{aligned} r_{13} - r_{12}r_{23} &= \frac{S_{13}}{\sqrt{S_{11}S_{33}}} - \frac{S_{12}}{\sqrt{S_{11}S_{22}}} \cdot \frac{S_{23}}{\sqrt{S_{22}S_{33}}} \\ &= \frac{1}{\sqrt{S_{11}S_{33}}}\left(S_{13} - \frac{S_{12}S_{23}}{S_{22}}\right) \\ &= \frac{1}{\sqrt{S_{11}S_{33}}}\left[(aS_{23} + bS_{33}) - \frac{(aS_{22} + bS_{23})S_{23}}{S_{22}}\right] \\ &= \frac{b\, S_{33}}{\sqrt{S_{11}S_{33}}}(1 - r_{23}^2) \end{aligned} \tag{36}$$

Análogamente al procedimiento anterior:

$$1 - r_{12}^2 = \frac{b^2 S_{33}(1 - r_{23}^2)}{S_{11}} \tag{37}$$

Por tanto el denominador es:

$$\sqrt{(1-r_{12}^2)(1-r_{23}^2)} = \frac{|b|\,\sqrt{S_{33}}}{\sqrt{S_{11}}}(1 - r_{23}^2) \tag{38}$$

Y la correlación parcial:

$$r_{13\cdot 2} = \frac{b\, S_{33}(1 - r_{23}^2)/\sqrt{S_{11}S_{33}}}{|b|\,\sqrt{S_{33}}(1 - r_{23}^2)/\sqrt{S_{11}}} = \frac{b}{|b|} = \pm 1 \tag{39}$$

$$r_{13\cdot 2} = \pm 1$$

El signo es $+1$ si $b = -\lambda_3/\lambda_1 > 0$, y -1 en caso contrario.

4.4. Cálculo de $r_{23\cdot 1}$

Para esta correlación parcial controlamos por X_1. Por simetría, escribimos:

$$x_{2i} = -\frac{\lambda_1}{\lambda_2} x_{1i} - \frac{\lambda_3}{\lambda_2} x_{3i} \equiv c\, x_{1i} + d\, x_{3i} \tag{40}$$

con $c = -\lambda_1/\lambda_2$ y $d = -\lambda_3/\lambda_2$.

Aplicamos la fórmula:

$$r_{23\cdot 1} = \frac{r_{23} - r_{12}\, r_{13}}{\sqrt{(1 - r_{12}^2)(1 - r_{13}^2)}} \tag{41}$$

Siguiendo exactamente el mismo procedimiento algebraico:

$$r_{23} - r_{12} r_{13} = \frac{d\, S_{33}}{\sqrt{S_{22} S_{33}}} (1 - r_{13}^2) \cdot \frac{1}{(1 - r_{13}^2)} \cdot (\ldots)$$

El cálculo es análogo a los anteriores y lleva al resultado:

$$r_{23\cdot 1} = \frac{d}{|d|} = \pm 1 \tag{42}$$

$$r_{23\cdot 1} = \pm 1$$

El signo depende del signo de $d = -\lambda_3/\lambda_2$.

5. Interpretación geométrica

La correlación parcial $r_{jk\cdot\ell}$ es la correlación entre los residuos de dos proyecciones ortogonales. Concretamente:

- Sea $\mathbf{M}_\ell = \mathbf{I} - \mathbf{P}_\ell$ el proyector ortogonal al espacio columna de X_ℓ (la matriz que obtiene residuos de regresar sobre X_ℓ).
- $r_{jk\cdot\ell} = \mathrm{Corr}(\mathbf{M}_\ell \mathbf{x}_j,\, \mathbf{M}_\ell \mathbf{x}_k)$
- Bajo la condición (1), $\mathbf{x}_j$ es combinación lineal de $\mathbf{x}_k$ y $\mathbf{x}_\ell$. Al proyectar fuera de $\mathbf{x}_\ell$, lo que queda de $\mathbf{x}_j$ es proporcional a lo que queda de $\mathbf{x}_k$:

$$\mathbf{M}_\ell \mathbf{x}_j \propto \mathbf{M}_\ell \mathbf{x}_k$$

Dos vectores proporcionales tienen correlación ± 1.

6. Consecuencias para la estimación MCO

6.1. Singularidad de $\mathbf{X}'\mathbf{X}$

Considere el modelo $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$ donde $\mathbf{X} = [\mathbf{x}_1\ \mathbf{x}_2\ \mathbf{x}_3]$. La condición (1) implica que existe $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \lambda_3)' \neq \mathbf{0}$ tal que:

$$\mathbf{X}\boldsymbol{\lambda} = \lambda_1\mathbf{x}_1 + \lambda_2\mathbf{x}_2 + \lambda_3\mathbf{x}_3 = \mathbf{0} \tag{43}$$

Por lo tanto $\boldsymbol{\lambda}$ pertenece al espacio nulo de $\mathbf{X}$, lo que implica:

$$\det(\mathbf{X}'\mathbf{X}) = 0 \tag{44}$$

La demostración: si $\mathbf{X}\boldsymbol{\lambda} = \mathbf{0}$, entonces $\mathbf{X}'\mathbf{X}\boldsymbol{\lambda} = \mathbf{X}'\mathbf{0} = \mathbf{0}$. Luego $\boldsymbol{\lambda}$ es un vector propio de $\mathbf{X}'\mathbf{X}$ asociado al valor propio 0, lo cual implica $\det(\mathbf{X}'\mathbf{X}) = 0$.

6.2. Indeterminación de los estimadores

Como $\mathbf{X}'\mathbf{X}$ es singular, **no existe** $(\mathbf{X}'\mathbf{X})^{-1}$ y el estimador MCO usual

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \tag{45}$$

no está definido. Hay infinitas combinaciones de $(\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3)$ que minimizan la suma de cuadrados de los residuos.

6.3. Varianzas infinitas

Si pudiéramos en algún sentido hablar de varianzas, la fórmula para el caso de dos regresores con correlación r da:

$$\mathrm{Var}(\hat{\beta}_j) = \frac{\sigma^2}{S_{jj}(1 - R_j^2)} \tag{46}$$

Como hemos demostrado que $R_j^2 = 1$ para cada variable, el denominador es $S_{jj}(1-1) = 0$, y la varianza diverge:

$$\mathrm{Var}(\hat{\beta}_j) = \frac{\sigma^2}{S_{jj} \cdot 0} \to \infty \tag{47}$$

Esto confirma que los coeficientes individuales son imposibles de estimar con precisión finita.

7. Resumen de resultados

Cuadro 1: Correlaciones parciales y R^2 bajo multicolinealidad perfecta

Cantidad	**Fórmula usada**	**Valor**
$r_{12\cdot 3}$	$\dfrac{r_{12} - r_{13}r_{23}}{\sqrt{(1-r_{13}^2)(1-r_{23}^2)}}$	± 1
$r_{13\cdot 2}$	$\dfrac{r_{13} - r_{12}r_{23}}{\sqrt{(1-r_{12}^2)(1-r_{23}^2)}}$	± 1
$r_{23\cdot 1}$	$\dfrac{r_{23} - r_{12}r_{13}}{\sqrt{(1-r_{12}^2)(1-r_{13}^2)}}$	± 1
$R^2_{1\cdot 23}$	$1 - \mathrm{SCR}/\mathrm{SCT}$	1
$R^2_{2\cdot 13}$	$1 - \mathrm{SCR}/\mathrm{SCT}$	1
$R^2_{3\cdot 12}$	$1 - \mathrm{SCR}/\mathrm{SCT}$	1
VIF_j	$1/(1 - R_j^2)$	∞
$\det(\mathbf{X}'\mathbf{X})$	—	0

Conclusión. La situación descrita en el ejercicio corresponde a **multicolinealidad perfecta** en su grado máximo posible. Sus manifestaciones son cuatro:

1. **Todas** las correlaciones parciales entre pares de variables, controlando por la tercera, son iguales a ± 1 en valor absoluto.
2. **Todos** los R^2 de las regresiones auxiliares son iguales a 1: cada variable es

perfectamente explicada por las demás dos.

3. El VIF de cada variable es **infinito**: no existe información independiente en ninguna de ellas.
4. El estimador MCO **no existe** (la matriz $\mathbf{X}'\mathbf{X}$ es singular). Los errores estándar de los coeficientes individuales son infinitos. Solo son estimables las combinaciones lineales de parámetros que son ortogonales al vector de colinealidad $\boldsymbol{\lambda}$.

A. Apéndice A: Demostración del Lema 1 mediante álgebra de Frisch-Waugh

El teorema de Frisch-Waugh-Lovell (FWL) establece que, en la regresión de $\mathbf{y}$ sobre $[\mathbf{X}_1\ \mathbf{X}_2]$, el vector de coeficientes de $\mathbf{X}_2$ es idéntico al de la regresión de $\mathbf{M}_1\mathbf{y}$ sobre $\mathbf{M}_1\mathbf{X}_2$, donde $\mathbf{M}_1 = \mathbf{I} - \mathbf{X}_1(\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'$.

Aplicado a la correlación parcial: $r_{12\cdot 3}$ es la correlación entre $\mathbf{M}_3\mathbf{x}_1$ y $\mathbf{M}_3\mathbf{x}_2$. Dado que $\mathbf{x}_1 = a\mathbf{x}_2 + b\mathbf{x}_3$:

$$\mathbf{M}_3\mathbf{x}_1 = a\,\mathbf{M}_3\mathbf{x}_2 + b\,\mathbf{M}_3\mathbf{x}_3 = a\,\mathbf{M}_3\mathbf{x}_2 + b\,\mathbf{0} = a\,\mathbf{M}_3\mathbf{x}_2 \tag{48}$$

porque $\mathbf{M}_3\mathbf{x}_3 = \mathbf{0}$ (proyectar sobre el complemento del espacio de $\mathbf{x}_3$ aniquila a $\mathbf{x}_3$). Por tanto $\mathbf{M}_3\mathbf{x}_1$ y $\mathbf{M}_3\mathbf{x}_2$ son proporcionales con constante a, y su correlación es exactamente $\text{signo}(a) = \pm 1$.

B. Apéndice B: Factor de inflación de varianza y número de condición

B.1. VIF a partir de R^2 auxiliar

En la regresión múltiple general, la varianza del j-ésimo coeficiente MCO es:

$$\mathrm{Var}(\hat{\beta}_j) = \frac{\sigma^2}{S_{jj}} \cdot \frac{1}{1 - R_j^2} \tag{49}$$

El factor $\mathrm{VIF}_j = 1/(1 - R_j^2)$ cuantifica el multiplicador de la varianza respecto al caso ideal de ortogonalidad ($R_j^2 = 0$, VIF$= 1$). Bajo multicolinealidad perfecta, $R_j^2 = 1$ y $\mathrm{VIF}_j = \infty$.

B.2. Número de condición

El **número de condición** de $\mathbf{X}'\mathbf{X}$ (o de su versión estandarizada) es:

$$\kappa = \sqrt{\frac{\lambda_{\text{máx}}(\mathbf{X}'\mathbf{X})}{\lambda_{\text{mín}}(\mathbf{X}'\mathbf{X})}} \tag{50}$$

Bajo multicolinealidad perfecta, $\lambda_{\text{mín}} = 0$, por lo que $\kappa \to \infty$. En la práctica, $\kappa > 30$ ya indica colinealidad severa.

C. Apéndice C: Generalización a k variables

Proposición 1. *Si k variables satisfacen $\sum_{j=1}^{k} \lambda_j X_{ji} = 0$ para todo i (con $\boldsymbol{\lambda} \neq \mathbf{0}$), entonces:*

(I) R^2 de la regresión de cualquier X_j sobre las demás $k-1$ variables es igual a 1.

(II) Toda correlación parcial entre dos variables, controlando por cualquier subconjunto de las restantes, tiene valor absoluto 1.

(III) La matriz $\mathbf{X}'\mathbf{X}$ de dimensión $k \times k$ tiene rango a lo sumo $k-1$ (al menos un valor propio es 0).

(IV) El estimador MCO $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ no existe.

Nota. Los resultados de este ejercicio son puramente algebraicos: no requieren supuestos distribucionales sobre los errores. La multicolinealidad perfecta es una propiedad de los datos ($\mathbf{X}$), no del proceso generador de $\mathbf{y}$.