Regresores Ortogonales: Coeficientes, Interceptos y Varianzas bajo $r_{23} = 0$

Derivacion completa desde las ecuaciones normales

Ejercicio 10.8 — *Econometria*, Gujarati & Porter, 5.a ed.

Con demostraciones matriciales, algebra escalar y comparacion de eficiencia

Planteamiento. Se tiene el modelo de regresion multiple:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i \tag{1}$$

y se supone que la correlacion entre los dos regresores es exactamente cero:

$$r_{23} = \frac{\sum x_{2i} x_{3i}}{\sqrt{\sum x_{2i}^2 \sum x_{3i}^2}} = 0 \quad \Longleftrightarrow \quad \sum x_{2i} x_{3i} = 0 \tag{2}$$

donde $x_{ji} = X_{ji} - \bar{X}_j$ denota la desviacion respecto a la media. Se propone ademas estimar dos regresiones simples separadas:

$$Y_i = \alpha_1 + \alpha_2 X_{2i} + u_{1i} \tag{3}$$

$$Y_i = \gamma_1 + \gamma_3 X_{3i} + u_{2i} \tag{4}$$

y se pregunta sobre la relacion entre los estimadores de los tres modelos.

1. Inciso (a): $\hat{\alpha}_2 = \hat{\beta}_2$ y $\hat{\gamma}_3 = \hat{\beta}_3$

1.1. Formulas generales del estimador MCO multiple

Las ecuaciones normales del modelo (**??**), escritas en desviaciones respecto a la media (lo que elimina el intercepto del sistema), son:

$$\hat{\beta}_2 \sum x_{2i}^2 + \hat{\beta}_3 \sum x_{2i}x_{3i} = \sum x_{2i}y_i \tag{5}$$
$$\hat{\beta}_2 \sum x_{2i}x_{3i} + \hat{\beta}_3 \sum x_{3i}^2 = \sum x_{3i}y_i \tag{6}$$

donde $y_i = Y_i - \bar{Y}$. Resolviendo por la regla de Cramer:

$$\hat{\beta}_2 = \frac{(\sum x_{2i}y_i)(\sum x_{3i}^2) - (\sum x_{3i}y_i)(\sum x_{2i}x_{3i})}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2} \tag{7}$$

$$\hat{\beta}_3 = \frac{(\sum x_{3i}y_i)(\sum x_{2i}^2) - (\sum x_{2i}y_i)(\sum x_{2i}x_{3i})}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2} \tag{8}$$

1.2. Simplificacion bajo ortogonalidad

Aplicando la condicion (**??**), $\sum x_{2i}x_{3i} = 0$, en (**??**):

$$\hat{\beta}_2 = \frac{(\sum x_{2i}y_i)(\sum x_{3i}^2) - 0}{(\sum x_{2i}^2)(\sum x_{3i}^2) - 0} = \frac{\sum x_{2i}y_i}{\sum x_{2i}^2} \tag{9}$$

Esta es exactamente la formula del estimador MCO de la pendiente en la regresion simple (**??**):

$$\hat{\alpha}_2 = \frac{\sum x_{2i}y_i}{\sum x_{2i}^2} \tag{10}$$

Por tanto:

$$\boxed{\hat{\beta}_2 = \hat{\alpha}_2} \tag{11}$$

El mismo argumento para $\hat{\beta}_3$ con (**??**):

$$\hat{\beta}_3 = \frac{(\sum x_{3i}y_i)(\sum x_{2i}^2) - 0}{(\sum x_{2i}^2)(\sum x_{3i}^2) - 0} = \frac{\sum x_{3i}y_i}{\sum x_{3i}^2} = \hat{\gamma}_3 \tag{12}$$

$$\boxed{\hat{\beta}_3 = \hat{\gamma}_3} \tag{13}$$

1.3. Interpretacion

Cuando $r_{23} = 0$, los regresores no comparten informacion lineal. El efecto de X_2 sobre Y es completamente separable del efecto de X_3, sin que ninguno contamine al otro. Cada coeficiente de pendiente del modelo multiple coincide con el que se obtendria en una regresion simple que ignora la otra variable.

En terminos de las ecuaciones normales, el cruce $\sum x_{2i}x_{3i}$ actua como el "canal de interferencia" entre los dos estimadores. Al anularse, el sistema (**??**)–(**??**) se desacopla:

$$\hat{\beta}_2 \sum x_{2i}^2 = \sum x_{2i}y_i \tag{14}$$

$$\hat{\beta}_3 \sum x_{3i}^2 = \sum x_{3i}y_i \tag{15}$$

Cada ecuacion se resuelve independientemente, como si la otra variable no existiera.

La ortogonalidad ($r_{23} = 0$) es la condicion bajo la cual omitir una variable del modelo **no sesga** el coeficiente de la variable incluida. Este es el caso ideal en diseno experimental (variables controladas y ortogonales por construccion). En datos observacionales, $r_{23} = 0$ es excepcional.

2. Inciso (b): relacion entre los interceptos

2.1. Formula general del intercepto

En cualquier regresion MCO, el intercepto se obtiene evaluando la recta de regresion en las medias (condicion de primer orden respecto a β_1):

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2\bar{X}_2 - \hat{\beta}_3\bar{X}_3 \tag{16}$$

$$\hat{\alpha}_1 = \bar{Y} - \hat{\alpha}_2\bar{X}_2 \tag{17}$$

$$\hat{\gamma}_1 = \bar{Y} - \hat{\gamma}_3\bar{X}_3 \tag{18}$$

2.2. Relaciones entre los tres interceptos

Dado que $\hat{\beta}_2 = \hat{\alpha}_2$ y $\hat{\beta}_3 = \hat{\gamma}_3$, sustituimos (**??**) en (**??**):

$$\begin{aligned}\hat{\beta}_1 &= \bar{Y} - \hat{\beta}_2\bar{X}_2 - \hat{\beta}_3\bar{X}_3 \\ &= (\bar{Y} - \hat{\alpha}_2\bar{X}_2) - \hat{\beta}_3\bar{X}_3 \\ &= \hat{\alpha}_1 - \hat{\beta}_3\bar{X}_3 \end{aligned} \tag{19}$$

Analogamente, sustituyendo (**??**):

$$\begin{aligned}\hat{\beta}_1 &= (\bar{Y} - \hat{\gamma}_3\bar{X}_3) - \hat{\beta}_2\bar{X}_2 \\ &= \hat{\gamma}_1 - \hat{\beta}_2\bar{X}_2 \end{aligned} \tag{20}$$

Resumiendo:

$$\boxed{\hat{\beta}_1 = \hat{\alpha}_1 - \hat{\beta}_3\bar{X}_3 = \hat{\gamma}_1 - \hat{\beta}_2\bar{X}_2} \tag{21}$$

2.3. Cuando coinciden los interceptos

De (**??**) se deduce:

- $\hat{\beta}_1 = \hat{\alpha}_1$ si y solo si $\hat{\beta}_3\bar{X}_3 = 0$, es decir, si $\bar{X}_3 = 0$ (la media de X_3 es cero) o si $\hat{\beta}_3 = 0$ (la variable X_3 no tiene efecto sobre Y).
- $\hat{\beta}_1 = \hat{\gamma}_1$ si y solo si $\hat{\beta}_2\bar{X}_2 = 0$, es decir, si $\bar{X}_2 = 0$ o $\hat{\beta}_2 = 0$.

En general, ninguna de estas condiciones se cumple con datos economicos reales, por lo que $\hat{\beta}_1 \neq \hat{\alpha}_1$ y $\hat{\beta}_1 \neq \hat{\gamma}_1$.

2.4. Interpretacion geometrica

El intercepto ajusta la recta para que pase por el punto de medias $(\bar{X}_2, \bar{X}_3, \bar{Y})$. Cuando el modelo simple omite X_3, el punto de medias que usa es $(\bar{X}_2, \bar{Y})$. Dado que $\bar{X}_3 \neq 0$

en general, las dos rectas de regresion no tienen el mismo origen vertical.

Los interceptos de las regresiones simples **no coinciden** con el intercepto del modelo multiple, excepto en casos especiales ($\bar{X}_j = 0$ o $\hat{\beta}_j = 0$). La relacion exacta es $\hat{\beta}_1 = \hat{\alpha}_1 - \hat{\beta}_3 \bar{X}_3$.

3. Inciso (c): comparacion de varianzas

3.1. Varianza de $\hat{\beta}_2$ en el modelo multiple

Bajo ortogonalidad, la formula general (**??**) se simplifica a (**??**). La varianza del estimador en el modelo multiple es:

$$\mathrm{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_{2i}^2} \tag{22}$$

donde $\sigma^2 = \mathrm{Var}(u_i)$ es la varianza del error del modelo multiple (**??**). Nótese que el factor VIF desaparece porque $r_{23} = 0$: $\mathrm{VIF}_2 = 1/(1 - r_{23}^2) = 1$.

3.2. Varianza de $\hat{\alpha}_2$ en la regresion simple

En la regresion simple (**??**), el termino de error es:

$$u_{1i} = u_i + \beta_3 X_{3i} \tag{23}$$

Esto es asi porque el verdadero modelo incluye $\beta_3 X_{3i}$, pero al omitirlo, ese termino pasa al error. La varianza del error simple es:

$$\begin{aligned} \sigma_{u_1}^2 &= \mathrm{Var}(u_i + \beta_3 X_{3i}) \\ &= \mathrm{Var}(u_i) + \beta_3^2 \,\mathrm{Var}(X_{3i}) + 2\beta_3 \,\mathrm{Cov}(u_i, X_{3i}) \\ &= \sigma^2 + \beta_3^2 \sigma_{X_3}^2 \end{aligned} \tag{24}$$

donde usamos $\mathrm{Cov}(u_i, X_{3i}) = 0$ (supuesto de exogeneidad) y $\sigma^2_{X_3} = \mathrm{Var}(X_{3i})$. Por tanto:

$$\sigma^2_{u_1} = \sigma^2 + \beta_3^2 \sigma^2_{X_3} \geq \sigma^2 \tag{25}$$

con igualdad solo si $\beta_3 = 0$.

La varianza del estimador simple es:

$$\mathrm{Var}(\hat{\alpha}_2) = \frac{\sigma^2_{u_1}}{\sum x^2_{2i}} = \frac{\sigma^2 + \beta_3^2 \sigma^2_{X_3}}{\sum x^2_{2i}} \tag{26}$$

3.3. Comparacion directa

Restando (**??**) de (**??**):

$$\mathrm{Var}(\hat{\alpha}_2) - \mathrm{Var}(\hat{\beta}_2) = \frac{\sigma^2 + \beta_3^2 \sigma^2_{X_3}}{\sum x^2_{2i}} - \frac{\sigma^2}{\sum x^2_{2i}} = \frac{\beta_3^2 \sigma^2_{X_3}}{\sum x^2_{2i}} \geq 0 \tag{27}$$

Por tanto:

$$\boxed{\mathrm{Var}(\hat{\alpha}_2) \geq \mathrm{Var}(\hat{\beta}_2)} \tag{28}$$

con igualdad si y solo si $\beta_3 = 0$ (la variable omitida es irrelevante).

3.4. Mismo resultado para $\hat{\gamma}_3$ y $\hat{\beta}_3$

Por simetria del argumento, el error de la regresion simple (**??**) es $u_{2i} = u_i + \beta_2 X_{2i}$, con varianza:

$$\sigma^2_{u_2} = \sigma^2 + \beta_2^2 \sigma^2_{X_2} \geq \sigma^2 \tag{29}$$

y por tanto:

$$\mathrm{Var}(\hat{\gamma}_3) = \frac{\sigma^2_{u_2}}{\sum x^2_{3i}} \geq \frac{\sigma^2}{\sum x^2_{3i}} = \mathrm{Var}(\hat{\beta}_3) \tag{30}$$

Aunque los estimadores puntuales de las pendientes son identicos ($\hat{\alpha}_2 = \hat{\beta}_2$ y $\hat{\gamma}_3 = \hat{\beta}_3$), las varianzas **no lo son**. La regresion multiple es siempre mas eficiente:

$$\mathrm{Var}(\hat{\alpha}_2) \geq \mathrm{Var}(\hat{\beta}_2), \qquad \mathrm{Var}(\hat{\gamma}_3) \geq \mathrm{Var}(\hat{\beta}_3)$$

La razon es que el modelo multiple "sabe" que X_3 ya esta controlada, mientras que el modelo simple lo ignora y su error absorbe la influencia de X_3, inflando la varianza del estimador.

4. Sintesis

Cuadro 1: Comparacion entre modelo multiple y regresiones simples bajo $r_{23} = 0$

Cantidad	**Modelo multiple**	**Regresion simple**	**Igualdad?**
Coeficiente de X_2	$\hat{\beta}_2 = \frac{\sum x_{2i} y_i}{\sum x_{2i}^2}$	$\hat{\alpha}_2 = \frac{\sum x_{2i} y_i}{\sum x_{2i}^2}$	**Si**
Coeficiente de X_3	$\hat{\beta}_3 = \frac{\sum x_{3i} y_i}{\sum x_{3i}^2}$	$\hat{\gamma}_3 = \frac{\sum x_{3i} y_i}{\sum x_{3i}^2}$	**Si**
Intercepto	$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}_2 - \hat{\beta}_3 \bar{X}_3$	$\hat{\alpha}_1 = \bar{Y} - \hat{\alpha}_2 \bar{X}_2$	No (en gral.)
Varianza de $\hat{}_2$	$\frac{\sigma^2}{\sum x_{2i}^2}$	$\frac{\sigma^2 + \beta_3^2 \sigma_{X_3}^2}{\sum x_{2i}^2}$	No: simple $\geq$ multiple
Varianza de $\hat{}_3$	$\frac{\sigma^2}{\sum x_{3i}^2}$	$\frac{\sigma^2 + \beta_2^2 \sigma_{X_2}^2}{\sum x_{3i}^2}$	No: simple $\geq$ multiple

A. Demostracion matricial bajo ortogonalidad

La matriz de productos cruzados del modelo multiple es:

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum X_{2i} & \sum X_{3i} \\ \sum X_{2i} & \sum X_{2i}^2 & \sum X_{2i} X_{3i} \\ \sum X_{3i} & \sum X_{2i} X_{3i} & \sum X_{3i}^2 \end{pmatrix} \tag{31}$$

Trabajando en desviaciones respecto a la media, la submatriz relevante es:

$$\mathbf{S} = \begin{pmatrix} \sum x_{2i}^2 & \sum x_{2i}x_{3i} \\ \sum x_{2i}x_{3i} & \sum x_{3i}^2 \end{pmatrix} \tag{32}$$

Bajo ortogonalidad, $\sum x_{2i}x_{3i} = 0$ y la matriz se vuelve diagonal:

$$\mathbf{S} = \begin{pmatrix} \sum x_{2i}^2 & 0 \\ 0 & \sum x_{3i}^2 \end{pmatrix} \tag{33}$$

Su inversa es trivial:

$$\mathbf{S}^{-1} = \begin{pmatrix} 1/\sum x_{2i}^2 & 0 \\ 0 & 1/\sum x_{3i}^2 \end{pmatrix} \tag{34}$$

El estimador MCO es $\hat{\boldsymbol{\beta}} = \mathbf{S}^{-1}\mathbf{S}_y$ donde $\mathbf{S}_y = (\sum x_{2i}y_i, \sum x_{3i}y_i)'$:

$$\begin{pmatrix} \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix} = \begin{pmatrix} 1/\sum x_{2i}^2 & 0 \\ 0 & 1/\sum x_{3i}^2 \end{pmatrix} \begin{pmatrix} \sum x_{2i}y_i \\ \sum x_{3i}y_i \end{pmatrix} = \begin{pmatrix} \sum x_{2i}y_i / \sum x_{2i}^2 \\ \sum x_{3i}y_i / \sum x_{3i}^2 \end{pmatrix} \tag{35}$$

Cada componente es exactamente el estimador de la regresion simple correspondiente. La matriz de varianzas-covarianzas es:

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2\mathbf{S}^{-1} = \begin{pmatrix} \sigma^2/\sum x_{2i}^2 & 0 \\ 0 & \sigma^2/\sum x_{3i}^2 \end{pmatrix} \tag{36}$$

Los estimadores de las dos pendientes son no correlacionados entre si ($\mathrm{Cov}(\hat{\beta}_2, \hat{\beta}_3) = 0$), propiedad que solo se da bajo ortogonalidad. Esto confirma que los resultados del modelo multiple y de las dos regresiones simples coinciden *en los coeficientes de pendiente* pero difieren en las varianzas porque el σ^2 del modelo multiple es menor que las varianzas de los errores de las regresiones simples.

B. Magnitud del exceso de varianza en la regresion simple

El exceso de varianza relativo del estimador simple respecto al multiple es:

$$\frac{\mathrm{Var}(\hat{\alpha}_2) - \mathrm{Var}(\hat{\beta}_2)}{\mathrm{Var}(\hat{\beta}_2)} = \frac{\beta_3^2 \sigma_{X_3}^2}{\sigma^2} = \beta_3^2 \cdot \mathrm{SNR}_{X_3} \tag{37}$$

donde $\mathrm{SNR}_{X_3} = \sigma_{X_3}^2/\sigma^2$ es la razon senal-ruido de X_3. El exceso de varianza es mayor cuando:

1. $|\beta_3|$ es grande (efecto real de la variable omitida sobre Y).
2. $\sigma_{X_3}^2$ es grande (mucha variacion en la variable omitida).
3. σ^2 es pequeno (modelo con poco ruido, donde la omision importa relativamente mas).

Nota. Los resultados del inciso (a) generalizan al caso de k regresores: si todos los pares de regresores son ortogonales (es decir, $\mathbf{X}'\mathbf{X}$ es diagonal en desviaciones), entonces cada coeficiente MCO del modelo multiple coincide con el de la regresion simple de Y sobre ese unico regresor. Este es el principio que subyace al diseno de experimentos con bloques completos aleatorizados y factores ortogonales.