Regresion por Pasos: Seleccion de Variables, Multicolinealidad y sus Problemas Formales

Por que los procedimientos mecanicos de seleccion son inadecuados

---

Ejercicio 10.11 — *Econometria*, Gujarati & Porter, 5.a ed.

Analisis formal: sesgo por pretesting, no monotonía de la SCE, inflacion del error tipo I y alternativas validas

Planteamiento. La **regresion por pasos** (*stepwise regression*) es un procedimiento automatico de seleccion de variables que opera de dos formas:

- **Hacia delante** (*forward*): se parte del modelo vacio y se agrega una variable a la vez, eligiendo en cada paso la que mas incrementa la SCE, siempre que el estadistico F correspondiente supere un umbral predefinido.
- **Hacia atras** (*backward*): se parte del modelo completo con todas las variables disponibles y se elimina una a la vez, comenzando por la de menor contribucion marginal a la SCE, hasta que todas las variables restantes sean significativas segun la prueba F.

Se pregunta si estos procedimientos son recomendables a la luz de lo que se sabe sobre multicolinealidad.

Respuesta directa: no se recomiendan, por razones formales que se desarrollan a continuacion.

1. La logica de la regresion por pasos: criterio de la SCE

1.1. El estadistico F incremental

En cada paso del procedimiento hacia delante, se evalua si agregar la variable X_j mejora significativamente el ajuste. El estadistico F incremental compara el modelo sin X_j (restringido, con R_R^2) contra el modelo con X_j (no restringido, con R_{NR}^2):

$$F^* = \frac{(R_{NR}^2 - R_R^2)/1}{(1 - R_{NR}^2)/(n-k)} \tag{1}$$

Si $F^* > F_c$ (valor critico al nivel α), X_j se incluye. Este estadistico es equivalente al cuadrado del estadistico t individual de X_j en el modelo que ya incluye las demas variables. El procedimiento es entonces secuencial: cada decision depende del conjunto de variables que ya estan en el modelo.

1.2. La SCE como criterio de seleccion

La suma de cuadrados explicada (SCE) del modelo con k regresores es:

$$\text{SCE}_k = \sum_{i=1}^{n} (\hat{Y}_i - \bar{Y})^2 \tag{2}$$

Agregar cualquier variable al modelo nunca puede reducir la SCE, porque MCO minimiza la suma de cuadrados residual y la SCE es su complemento. Por tanto:

$$\text{SCE}_{k+1} \geq \text{SCE}_k \quad \text{siempre} \tag{3}$$

El procedimiento por pasos elige las variables que maximizan el incremento marginal en la SCE en cada paso. El problema es que bajo multicolinealidad, este criterio depende criticamente del orden de entrada, como se demuestra a continuacion.

2. Problema 1: dependencia del orden y arbitrariedad

2.1. Demostracion de la no unicidad del resultado

Sea un modelo con tres variables candidatas: X_2, X_3 y X_4, donde r_{23} es alta. La contribucion marginal de X_3 al agregar al modelo que ya contiene X_2 es:

$$\Delta\text{SCE}(X_3|X_2) = \text{SCE}(X_2, X_3) - \text{SCE}(X_2) \tag{4}$$

Pero si en cambio se agrega X_3 primero y luego se evalua X_2:

$$\Delta\text{SCE}(X_2|X_3) = \text{SCE}(X_2, X_3) - \text{SCE}(X_3) \tag{5}$$

En general, $\Delta\text{SCE}(X_3|X_2) \neq \Delta\text{SCE}(X_3)$ porque el efecto marginal de X_3 cambia segun que otras variables esten ya en el modelo. Con colinealidad alta ($r_{23} \approx 1$), la contribucion marginal de X_3 dado X_2 es casi cero (ambas explican casi lo mismo), mientras que la contribucion marginal de X_3 sin X_2 puede ser grande.

2.2. Implicacion para la seleccion de modelos

Suponga que se tienen dos posibles modelos equivalentes en ajuste:

$$\text{Modelo A:} \quad Y = \beta_1 + \beta_2 X_2 + u \tag{6}$$

$$\text{Modelo B:} \quad Y = \gamma_1 + \gamma_3 X_3 + v \tag{7}$$

con $r_{23} = 0{,}98$ y $R_A^2 \approx R_B^2$. El procedimiento hacia delante elegira uno u otro dependiendo unicamente de cual explique marginalmente un poco mas en el primer paso, aunque ambos sean virtualmente equivalentes en ajuste y en contenido informativo. La eleccion es arbitraria y no tiene ningun respaldo teorico.

Bajo multicolinealidad, la contribucion marginal de una variable a la SCE depende criticamente del conjunto de variables ya incluidas. El resultado del procedimiento por pasos varia con el orden de entrada o salida, produciendo selecciones arbitrarias de modelos.

3. Problema 2: inflacion del error tipo I por pruebas multiples

3.1. El problema del pretesting

Cuando se realizan m pruebas de hipotesis secuenciales sobre los mismos datos, el nivel de significancia nominal α de cada prueba individual ya no refleja la probabilidad real de cometer un error tipo I en el proceso total. Si cada prueba tiene nivel α, la probabilidad de cometer al menos un error tipo I en m pruebas independientes es:

$$P(\text{al menos un error tipo I}) = 1 - (1 - \alpha)^m \tag{8}$$

Para $\alpha = 0{,}05$ y $m = 10$ variables candidatas:

$$1 - (1 - 0{,}05)^{10} = 1 - 0{,}5987 \approx 0{,}40 \tag{9}$$

Con nivel nominal del 5 % por prueba, la probabilidad real de incluir al menos una variable irrelevante en 10 pasos es del 40 %.

3.2. Distribucion del estadistico bajo seleccion

El estadistico t del j-esimo coeficiente en el modelo final seleccionado por el procedimiento por pasos **no sigue la distribucion t de Student** con los grados de libertad habituales. La razon es que el modelo fue elegido precisamente porque los estadisticos t superaron un umbral: los t del modelo seleccionado estan condicionados a haber sido seleccionados, lo que sesga su distribucion hacia valores grandes:

$$\mathbb{E}[|t_j| \mid \text{variable seleccionada}] > \mathbb{E}[|t_j|] \tag{10}$$

Esto invalida la inferencia estandar: los errores estandar, intervalos de confianza y p-valores del modelo final son anticonservativos.

3.3. El problema del data mining

Buscar el "mejor" modelo entre todos los subconjuntos posibles de k variables candidatas implica evaluar hasta $2^k - 1$ modelos. Para $k = 10$: $2^{10} - 1 = 1023$ modelos. Cada uno es una prueba implicita de hipotesis. La probabilidad de encontrar un modelo con R^2 alto por pura casualidad —incluso si todas las variables son irrelevantes— es alta. Este fenomeno se denomina **sobreajuste por seleccion** (*selection overfitting*).

> Los procedimientos por pasos realizan multiples pruebas de hipotesis sobre los mismos datos. El nivel nominal α no refleja la probabilidad real de error tipo I, que puede superar el 40 % con 10 variables candidatas. La inferencia del modelo seleccionado es invalida.

4. Problema 3: sesgo por variable omitida bajo multicolinealidad

---

4.1. Mecanismo del sesgo

Si una variable teoricamente relevante X_j esta altamente correlacionada con otras variables ya en el modelo, su contribucion marginal a la SCE es pequena, pues las otras variables ya "explican" gran parte de su variacion. En el procedimiento hacia delante, X_j puede no ser seleccionada aunque $\beta_j \neq 0$. En el procedimiento hacia atras, puede ser eliminada porque su estadistico t no es significativo (inflado por colinealidad).

La formula del sesgo por variable omitida (derivada en ejercicios anteriores) se aplica aqui de forma directa:

$$\mathbb{E}[\hat{\beta}_{\text{red},j}] = \beta_j + \sum_{k \notin \mathcal{M}} \beta_k b_{jk} \tag{11}$$

donde $\mathcal{M}$ es el conjunto de variables omitidas y b_{jk} son los coeficientes de las regresiones auxiliares de las variables omitidas sobre las incluidas. Bajo colinealidad, b_{jk} es grande, amplificando el sesgo.

4.2. Paradoja: eliminacion de variables porque su t es pequeno por colinealidad

La colinealidad infla los errores estandar de todos los regresores correlacionados, reduciendo sus estadisticos t:

$$t_j = \frac{\hat{\beta}_j}{\text{ee}(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{\hat{\sigma}/\sqrt{S_{jj}}} \cdot \frac{1}{\sqrt{\text{VIF}_j}} \tag{12}$$

Con VIF_j alto, t_j puede ser pequeno aunque $\beta_j \neq 0$. El procedimiento por pasos interpretaria esto como evidencia de que X_j es irrelevante y la eliminaria, cuando en realidad es la colinealidad la que impide detectar su efecto. El resultado es la omision de variables relevantes y el sesgo de sus coeficientes en las variables que permanecen.

> En presencia de multicolinealidad, los procedimientos por pasos tienden a eliminar variables teoricamente relevantes porque su efecto individual no es detectado por la prueba F o t, introduciendo sesgo por variable omitida.

5. Problema 4: inestabilidad de los coeficientes

Cuando la multicolinealidad es severa, el estimador MCO es numericamente inestable: pequenas perturbaciones en los datos producen cambios grandes en los coeficientes. La adicion o eliminacion de una variable en el procedimiento por pasos puede desencadenar cambios drasticos en todos los demas coeficientes del modelo:

$$\frac{\partial \hat{\beta}_j}{\partial X_{ki}} \propto [(\mathbf{X}'\mathbf{X})^{-1}]_{jk} \tag{13}$$

Con $\det(\mathbf{X}'\mathbf{X}) \approx 0$, los elementos de $(\mathbf{X}'\mathbf{X})^{-1}$ son grandes y la sensibilidad es extrema. El modelo seleccionado en una muestra puede ser muy diferente del que se seleccionaria en una muestra ligeramente diferente del mismo fenomeno.

6. Alternativas recomendadas

Dado que los procedimientos mecanicos son inadecuados, se presentan las alternativas metodologicamente correctas.

6.1. Especificacion teorica del modelo

La especificacion debe basarse en la teoria economica, no en criterios estadisticos. Un modelo con k variables relevantes es preferible a uno con $k' < k$ variables aunque el segundo tenga menor varianza de estimacion, porque el primero es insesgado y el segundo no.

6.2. Criterios de informacion penalizados

Los criterios de informacion penalizan la complejidad del modelo y son apropiados para comparar modelos con diferente numero de parametros:

$$\text{AIC} = -2\ell(\hat{\boldsymbol{\beta}}) + 2k \tag{14}$$

$$\text{BIC} = -2\ell(\hat{\boldsymbol{\beta}}) + k \ln n \tag{15}$$

donde ℓ es el logaritmo de la verosimilitud maximizada y k es el numero de parametros. El BIC penaliza mas que el AIC y tiende a seleccionar modelos mas parsimoniosos. A diferencia del procedimiento por pasos, estos criterios comparan modelos *globalmente* sin sesgo de pretesting.

6.3. Validacion cruzada

Para evitar el sobreajuste, se puede usar validacion cruzada (*cross-validation*): dividir la muestra en subconjuntos de entrenamiento y prueba, estimar el modelo en el subconjunto de entrenamiento y evaluar su ajuste en el de prueba. El modelo que minimiza el error de prediccion fuera de muestra es preferido.

6.4. Regularizacion: regresion Ridge y LASSO

Los metodos de regularizacion encogen los coeficientes hacia cero de forma controlada, resolviendo simultaneamente el problema de multicolinealidad y la seleccion de variables:

$$\hat{\boldsymbol{\beta}}^{\text{Ridge}} = \arg\min_{\boldsymbol{\beta}} \left\{ \sum_i (Y_i - \mathbf{x}_i'\boldsymbol{\beta})^2 + \lambda \sum_j \beta_j^2 \right\} \tag{16}$$

$$\hat{\boldsymbol{\beta}}^{\text{LASSO}} = \arg\min_{\boldsymbol{\beta}} \left\{ \sum_i (Y_i - \mathbf{x}_i'\boldsymbol{\beta})^2 + \lambda \sum_j |\beta_j| \right\} \tag{17}$$

El LASSO produce soluciones con coeficientes exactamente iguales a cero para variables irrelevantes (seleccion automatica) pero con fundamento estadistico riguroso, sin los problemas de pretesting del procedimiento por pasos.

7. Sintesis: cuadro comparativo

Conclusion. La regresion por pasos **no se recomienda** en econometria aplicada, especialmente bajo multicolinealidad, por cuatro razones formales: (1) el resultado depende arbitrariamente del orden de entrada o salida; (2) la realizacion de multiples pruebas de hipotesis secuenciales infla el error tipo I hasta valores del 40 % o mas; (3) las variables relevantes pueden ser eliminadas porque la colinealidad reduce sus estadisticos t, introduciendo sesgo por variable omitida; (4) los coeficientes del modelo seleccionado son inestables y la inferencia estandar

Cuadro 1: Comparacion de metodos de seleccion de variables

Criterio	**Regresion por pasos**	**AIC/BIC**	**LASSO**
Sesgo por pretesting	Alto (pruebas multiples)	Bajo (comparacion global)	Ninguno
Efecto de la colinealidad	Elimina variables relevantes	Penaliza complejidad; no resuelve colinealidad	Encoge coeficientes; maneja colinealidad
Unicidad del resultado	No: depende del orden	Si: criterio unico	Si: para λ fijo
Validez de inferencia	Invalida (distribucion t sesgada)	Valida si se escoge correctamente	Requiere inferencia post-seleccion
Base teorica	Ninguna: puramente mecanico	Teoria de la informacion	Teoria estadistica de regularizacion

es invalida. Las alternativas correctas son: especificacion teorica previa, criterios AIC/BIC, validacion cruzada y metodos de regularizacion como Ridge o LASSO.

A. Demostracion de la inflacion del error tipo I bajo seleccion secuencial

Sean m variables candidatas independientes (para simplificar). La hipotesis nula para cada una es $H_{0j} : \beta_j = 0$. La probabilidad de no cometer un error tipo I en ninguna de las m pruebas es:

$$P(\text{ningun error tipo I}) = (1 - \alpha)^m \tag{18}$$

Por tanto, la probabilidad de cometer al menos un error tipo I es:

$$\alpha_{\text{exp}} = 1 - (1 - \alpha)^m \tag{19}$$

Esta es la **tasa de error familiar** (*familywise error rate*, FWER). Para controlarla al nivel α se debe usar la correccion de Bonferroni: realizar cada prueba al nivel α/m, de modo que:

$$\alpha_{\text{exp}} \leq 1 - \left(1 - \frac{\alpha}{m}\right)^m \approx \alpha \tag{20}$$

El procedimiento por pasos no aplica ninguna correccion de este tipo, lo que hace que su FWER sea sistematicamente superior al nivel nominal. Los p-valores reportados en el modelo final deben interpretarse con extrema cautela.

B. No monotonia de las contribuciones marginales bajo colinealidad

---

Sea el modelo verdadero $Y = \beta_2 X_2 + \beta_3 X_3 + u$ con $r_{23} = r$. La contribucion marginal de X_3 dado X_2 es:

$$\Delta R^2(X_3|X_2) = \frac{r^2_{Y,X_3 \cdot X_2}(1 - R^2_{Y,X_2})}{1} \tag{21}$$

donde $r_{Y,X_3 \cdot X_2}$ es la correlacion parcial de Y con X_3 dado X_2. Esta correlacion parcial puede ser muy diferente de la correlacion simple r_{Y,X_3} cuando r_{23} es alta, incluso si $\beta_3 \neq 0$. Con $r_{23} \approx 1$, la correlacion parcial tiende a cero y X_3 no sera seleccionada en el segundo paso, aunque sea relevante. Esta es la manifestacion formal de por que el orden importa.

Nota. La critica a los metodos de regresion por pasos esta bien documentada en la literatura econometrica y estadistica. Hocking (1976), Derksen y Keselman (1992) y Harrell (2001) documentan empiricamente las altas tasas de inclusion de variables irrelevantes y exclusion de variables relevantes bajo estos procedimientos. Para seleccion formal de variables con control del error tipo I, se recomienda el procedimiento de Benjamini-Hochberg (1995) para controlar la tasa de falsos descubrimientos (*False Discovery Rate*).