Verdadero, Falso o Incierto: Nueve Afirmaciones sobre Multicolinealidad

Justificacion formal con algebra y demostraciones

Ejercicio 10.12 — *Econometria*, Gujarati & Porter, 5.a ed.

Con derivaciones matriciales, formulas de varianza y analisis de casos limite

Nota preliminar. El modelo de referencia en todos los incisos es:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \cdots + \beta_k X_{ki} + u_i \tag{1}$$

bajo los supuestos clasicos de MCO: errores $u_i \overset{\text{iid}}{\sim} (0, \sigma^2)$, regresores no estocasticos y no singularidad de $\mathbf{X}'\mathbf{X}$. La multicolinealidad *perfecta* es el caso limite en que $\det(\mathbf{X}'\mathbf{X}) = 0$; la multicolinealidad *imperfecta* o *alta* es cuando $\det(\mathbf{X}'\mathbf{X}) \approx 0$ pero > 0.

Inciso (a) — FALSO

A pesar de la multicolinealidad perfecta, los estimadores de MCO son MELI.

Justificacion

El estimador MCO es $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$. Bajo multicolinealidad perfecta existe $\boldsymbol{\lambda} \neq \mathbf{0}$ tal que $\mathbf{X}\boldsymbol{\lambda} = \mathbf{0}$, lo que implica:

$$\det(\mathbf{X}'\mathbf{X}) = 0 \tag{2}$$

La matriz $\mathbf{X}'\mathbf{X}$ es singular y **no tiene inversa**. Por tanto, el estimador $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ **no existe** como objeto matematico unico. Hay infinitos vectores $\boldsymbol{\beta}$ que minimizan la suma de cuadrados de los residuos.

El teorema de Gauss-Markov establece que el estimador MCO es MELI (*Best Linear Unbiased Estimator*, BLUE) bajo los supuestos clasicos, que incluyen explicitamente que $\mathbf{X}'\mathbf{X}$ sea invertible (rango completo de $\mathbf{X}$). Al violarse este supuesto, el teorema

no aplica. Los estimadores individuales $\hat{\beta}_j$ son indeterminados con varianza infinita, condicion que es incompatible con ser "mejor" en el sentido de minima varianza.

$$\mathrm{Var}(\hat{\beta}_j) = \sigma^2[(\mathbf{X}'\mathbf{X})^{-1}]_{jj} \xrightarrow{\det(\mathbf{X}'\mathbf{X})\to 0} \infty \tag{3}$$

Conclusion: Falso. Bajo multicolinealidad perfecta, el estimador MCO no existe, por lo que no puede ser MELI.

Inciso (b) — INCIERTO

En los casos de alta multicolinealidad, no es posible evaluar la significancia individual de uno o mas coeficientes de regresion parcial.

Justificacion

El estadistico t del j-esimo coeficiente es:

$$t_j = \frac{\hat{\beta}_j}{\mathrm{ee}(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{\hat{\sigma}/\sqrt{S_{jj}}} \cdot \frac{1}{\sqrt{\mathrm{VIF}_j}} \tag{4}$$

Con VIF_j alto, el denominador se infla y $|t_j|$ se reduce, lo que *tiende* a producir no rechazo de $H_0 : \beta_j = 0$ aunque $\beta_j \neq 0$ (error tipo II). Sin embargo:

- El estadistico t *puede calcularse siempre* que $\mathbf{X}'\mathbf{X}$ sea invertible (colinealidad imperfecta). No es que sea imposible evaluarlo; es que el resultado puede ser no significativo por razones de colinealidad, no de irrelevancia.
- Si el efecto real β_j es suficientemente grande o el tamano muestral n es suficientemente grande, el coeficiente puede seguir siendo significativo incluso con VIF elevado, como se demostro en el ejercicio 10.9.

La afirmacion es verdadera en el sentido de que la prueba t *pierde poder* bajo alta colinealidad, pero es falsa si se interpreta como que la evaluacion es imposible. La palabra "no es posible" hace la afirmacion incorrecta.

Conclusion: Incierto. La prueba t se puede calcular pero su poder se reduce severamente; puede ser significativa si el efecto real es grande.

Inciso (c) — VERDADERO

Si una regresion auxiliar muestra que una R_j^2 particular es alta, hay evidencia clara de alta colinealidad.

Justificacion

La regresion auxiliar de X_j sobre los demas $k-1$ regresores produce un R_j^2. El VIF se define como:

$$\text{VIF}_j = \frac{1}{1-R_j^2} \geq 1 \tag{5}$$

Un R_j^2 alto significa que X_j es bien explicada por una combinacion lineal de los otros regresores, es decir, que X_j es aproximadamente redundante en el modelo. Concretamente:

- $R_j^2 = 0{,}9 \Rightarrow \text{VIF} = 10$: colinealidad severa.
- $R_j^2 = 0{,}99 \Rightarrow \text{VIF} = 100$: colinealidad muy severa.
- $R_j^2 \to 1 \Rightarrow \text{VIF} \to \infty$: aproximacion a multicolinealidad perfecta.

La varianza de $\hat{\beta}_j$ escala con VIF_j:

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{S_{jj}} \cdot \text{VIF}_j \tag{6}$$

Un R_j^2 alto implica directamente VIF alto y varianzas infladas. Esta es la tecnica de diagnostico de Klein (1962): si $R_j^2 > R^2$ del modelo principal, la colinealidad es problematica.

Conclusion: Verdadero. Un R_j^2 alto en la regresion auxiliar es evidencia directa de alta colinealidad de X_j con los demas regresores.

Inciso (d) — FALSO

Las correlaciones altas entre parejas de regresoras no sugieren una alta multicolinealidad.

Justificacion

Las correlaciones de orden cero r_{jk} entre pares de regresores son una **condicion suficiente** para la existencia de multicolinealidad. Si $r_{jk} \approx 1$, la relacion lineal aproximada $X_j \approx aX_k + b$ implica que $\mathbf{X}'\mathbf{X}$ se aproxima a la singularidad. En el caso de dos regresores, el determinante de la submatriz de productos cruzados es:

$$\det(\mathbf{S}) = S_{22}S_{33} - S_{23}^2 = S_{22}S_{33}(1 - r_{23}^2) \tag{7}$$

Cuando $r_{23} \to 1$, $\det(\mathbf{S}) \to 0$: multicolinealidad perfecta. Por tanto, correlaciones altas por pares *si sugieren* alta colinealidad.

La aclaracion importante es que correlaciones bajas *no garantizan* ausencia de colinealidad: en modelos con $k \geq 3$ regresores puede existir colinealidad entre combinaciones lineales de varios regresores aunque cada par individual tenga correlacion baja. Pero eso no cambia la afirmacion: correlaciones altas *si* sugieren colinealidad, lo cual hace la afirmacion del inciso *falsa*.

Conclusion: Falso. Correlaciones altas entre pares de regresores son condicion suficiente para la existencia de multicolinealidad.

Inciso (e) — INCIERTO

La multicolinealidad es inofensiva si el objetivo del analisis es solo la prediccion.

Justificacion

Para la prediccion, el objeto de interes es $\hat{Y}_0 = \mathbf{x}_0'\hat{\boldsymbol{\beta}}$, no los coeficientes individuales. La varianza del error de prediccion es:

$$\mathrm{Var}(\hat{Y}_0 - Y_0) = \sigma^2 \left(1 + \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0\right) \tag{8}$$

La multicolinealidad infla $(\mathbf{X}'\mathbf{X})^{-1}$, pero si el vector de prediccion $\mathbf{x}_0$ cae dentro del espacio de colinealidad de los datos de entrenamiento, el segundo termino puede seguir siendo pequeno. Formalmente, si la estructura de colinealidad de los datos futuros es identica a la de la muestra original, las predicciones son precisas aunque los coeficientes individuales sean imprecisos.

Sin embargo, la afirmacion es *incierta* porque:

- Si $\mathbf{x}_0$ contiene valores de los regresores que rompen la estructura de colinealidad del entrenamiento, la prediccion sera muy imprecisa.
- En la practica, la colinealidad cambia a lo largo del tiempo y los nuevos datos rara vez obedecen exactamente la misma estructura lineal.
- Incluso para prediccion, los intervalos de prediccion son mas amplios bajo alta colinealidad, reduciendo la utilidad practica.

Conclusion: Incierto. La multicolinealidad es inofensiva para la prediccion *solo si* la estructura de colinealidad se mantiene en los datos de prediccion. En la practica, esto raramente se garantiza.

Inciso (f) — VERDADERO

Entre mayor sea el FIV, ceteris paribus, mas grandes seran las varianzas de los estimadores de MCO.

Justificacion

Por definicion del VIF (Factor de Inflacion de la Varianza), la varianza del estimador MCO de β_j es:

$$\mathrm{Var}(\hat{\beta}_j) = \frac{\sigma^2}{S_{jj}(1 - R_j^2)} = \frac{\sigma^2}{S_{jj}} \cdot \mathrm{VIF}_j \tag{9}$$

donde $S_{jj} = \sum_i x_{ji}^2$ y R_j^2 es el R^2 de la regresion auxiliar de X_j sobre los demas regresores. La relacion es **lineal y directa**: duplicar el VIF duplica la varianza, todo lo demas constante. La desigualdad es estricta:

$$\mathrm{VIF}_j \geq 1 \quad \forall j, \quad \text{con igualdad solo si } R_j^2 = 0 \text{ (ortogonalidad)} \tag{10}$$

El VIF cuantifica exactamente cuanto se infla la varianza respecto al escenario ideal de regresores ortogonales. Un VIF de 10 significa que la varianza es 10 veces mayor de lo que seria con ortogonalidad.

Conclusion: Verdadero. La varianza de $\hat{\beta}_j$ es directamente proporcional a VIF_j, por definicion.

Inciso (g) — FALSO

La tolerancia (TOL) es una medida de multicolinealidad mejor que el FIV.

Justificacion

La tolerancia se define como:

$$\mathrm{TOL}_j = 1 - R_j^2 \tag{11}$$

y su relacion con el VIF es exactamente:

$$\mathrm{TOL}_j = \frac{1}{\mathrm{VIF}_j} \tag{12}$$

Dado que TOL y VIF son funciones biunivocas una de la otra (transformacion monotona decreciente), contienen **exactamente la misma informacion**. Conocer uno equivale a conocer el otro:

$$\mathrm{TOL}_j = 0{,}10 \iff \mathrm{VIF}_j = 10 \quad \text{(colinealidad severa)} \tag{13}$$

$$\mathrm{TOL}_j = 0{,}01 \iff \mathrm{VIF}_j = 100 \quad \text{(colinealidad muy severa)} \tag{14}$$

No existe ninguna situacion en la que TOL revele informacion que VIF no revele, ni viceversa. Decir que una es "mejor" que la otra carece de sentido matematico. Son dos escales distintas para medir lo mismo.

Conclusion: Falso. TOL y VIF son el inverso multiplicativo una de la otra. Proveen identica informacion; ninguna es superior.

Inciso (h) — FALSO

No podra obtener un valor R^2 elevado en una regresion multiple si todos los coeficientes parciales de pendiente no son estadisticamente significativos, en lo individual, con base en la prueba t usual.

Justificacion

La afirmacion es **falsa**: la combinacion de R^2 alto con todos los t_j no significativos es precisamente el *sintoma clasico* de multicolinealidad severa. La compatibilidad de estas dos situaciones se demuestra formalmente a continuacion.

El estadistico F del modelo completo contrasta $H_0 : \beta_2 = \cdots = \beta_k = 0$:

$$F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \tag{15}$$

Un R^2 alto implica un F global significativo, lo que rechaza H_0 conjuntamente. Sin embargo, cada estadistico t individual es:

$$t_j = \frac{\hat{\beta}_j}{\hat{\sigma}\sqrt{[(\mathbf{X}'\mathbf{X})^{-1}]_{jj}}} \tag{16}$$

Bajo colinealidad, $[(\mathbf{X}'\mathbf{X})^{-1}]_{jj}$ es grande (VIF elevado), inflando el denominador de cada t_j y haciendolo no significativo. La varianza del error $\hat{\sigma}^2$ puede ser pequena (buen ajuste global), pero los errores estandar individuales pueden ser grandes simultaneamente.

Estas dos condiciones son perfectamente compatibles:

$$R^2 \approx 1 \quad \text{y} \quad |t_j| < t_c \quad \forall j \tag{17}$$

Es la paradoja del R^2 alto con t's insignificantes, documentada en el ejemplo 10.1 de Gujarati con $R^2 = 0{,}9608$ y ambos t's menores que 2.

Conclusion: Falso. Es completamente posible tener R^2 elevado con todos los t_j no significativos. Esa combinacion es de hecho el indicador mas conspicuo de multicolinealidad severa.

Inciso (i) — VERDADERO

En la regresion de Y sobre X_2 y X_3, poca variabilidad en X_3 aumenta $\text{Var}(\hat{\beta}_3)$. En el extremo, si todas las X_3 son identicas, $\text{Var}(\hat{\beta}_3)$ seria infinita.

Justificacion

La varianza del estimador MCO de β_3 en la regresion multiple es:

$$\text{Var}(\hat{\beta}_3) = \frac{\sigma^2}{\sum x_{3i}^2 \cdot (1 - r_{23}^2)} = \frac{\sigma^2}{S_{33}} \cdot \text{VIF}_3 \tag{18}$$

donde $S_{33} = \sum_i (X_{3i} - \bar{X}_3)^2$ es la varianza muestral total de X_3 (multiplicada por $n-1$). La varianza de $\hat{\beta}_3$ es **inversamente proporcional a** S_{33}:

- Si la variabilidad de X_3 es pequena (S_{33} pequeno), $\mathrm{Var}(\hat{\beta}_3)$ es grande: hay poca informacion para estimar β_3.
- En el extremo, si todas las X_{3i} son identicas ($S_{33} = 0$):

$$\mathrm{Var}(\hat{\beta}_3) = \frac{\sigma^2}{0 \cdot (1 - r_{23}^2)} \to \infty \tag{19}$$

  Ademas, si X_3 es constante, es perfectamente colineal con la constante del modelo (columna de unos), $\det(\mathbf{X}'\mathbf{X}) = 0$ y el estimador no existe.

Este fenomeno —variabilidad insuficiente en un regresor— se denomina **micronumerosidad** y es conceptualmente analogo a la multicolinealidad. La intuicion es clara: para estimar el efecto de X_3 sobre Y se necesita variacion en X_3. Sin variacion, no hay informacion.

Conclusion: Verdadero. La varianza de $\hat{\beta}_3$ es inversamente proporcional a S_{33}; con $S_{33} = 0$ la varianza es infinita y el estimador no existe.

1. Tabla resumen

A. Demostracion de la compatibilidad de R^2 alto con t's insignificantes

---

Sea el modelo $Y = \beta_1 + \beta_2 X_2 + \beta_3 X_3 + u$ con $r_{23} = r$ cercano a 1. Los estadisticos t son:

$$t_2 = \frac{\hat{\beta}_2}{\hat{\sigma}} \cdot \sqrt{\frac{S_{22}(1-r^2)}{1}} = \frac{\hat{\beta}_2}{\hat{\sigma}/\sqrt{S_{22}}} \cdot \sqrt{1-r^2} \tag{20}$$

Cuando $r \to 1$: $\sqrt{1-r^2} \to 0$, por lo que $t_2 \to 0$ aunque $\hat{\beta}_2 \neq 0$. El R^2 del modelo,

Cuadro 1: Veredictos del ejercicio 10.12

Inciso	Veredicto	Razon principal
(a)	Falso	Con multicolinealidad perfecta $(\mathbf{X}'\mathbf{X})^{-1}$ no existe; el estimador MCO es indeterminado y no puede ser MELI.
(b)	Incierto	La prueba t se puede calcular pero pierde poder; bajo efectos muy grandes puede ser significativa.
(c)	Verdadero	R_j^2 alto en regresion auxiliar $\Rightarrow$ VIF_j alto $\Rightarrow$ varianza inflada; evidencia directa de colinealidad.
(d)	Falso	Correlaciones altas son condicion suficiente (no necesaria) de colinealidad; si la sugieren.
(e)	Incierto	Inofensiva para prediccion solo si la estructura de colinealidad se mantiene en datos futuros.
(f)	Verdadero	$\mathrm{Var}(\hat{\beta}_j) = (\sigma^2/S_{jj})\cdot\mathrm{VIF}_j$; relacion directa y proporcional por definicion.
(g)	Falso	TOL = 1/VIF; contienen identica informacion; ninguna es superior.
(h)	Falso	R^2 alto con t's insignificantes es el sintoma clasico de multicolinealidad. Son perfectamente compatibles.
(i)	Verdadero	$\mathrm{Var}(\hat{\beta}_3) \propto 1/S_{33}$; si $S_{33} = 0$ la varianza es infinita y el estimador no existe.

en cambio, depende de la variacion total explicada y puede permanecer alto incluso cuando $r \to 1$, pues las variables en conjunto siguen explicando bien a Y.

B. Relacion entre varianza de prediccion y colinealidad

Para el vector de prediccion $\mathbf{x}_0$, la varianza es:

$$\mathrm{Var}(\hat{Y}_0) = \sigma^2 \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0 \tag{21}$$

Si $\mathbf{x}_0$ es una combinacion lineal de los vectores de entrenamiento (es decir, cae dentro del espacio columna de $\mathbf{X}$), la varianza puede ser pequena incluso con colinealidad alta. Pero si $\mathbf{x}_0$ se aleja de ese espacio, la varianza puede ser enorme. Esto es lo que hace que la afirmacion del inciso (e) sea incierta en la practica.

Nota. Los resultados de este ejercicio constituyen un resumen de los conceptos centrales del capitulo 10 de Gujarati & Porter (2010). El inciso (h) reproduce la paradoja del ejemplo 10.1 (consumo, ingreso y riqueza), donde $R^2 = 0{,}9608$ y los estadisticos t son 1,14 y $-0{,}52$, ninguno significativo al 5 %.