Multicolinealidad en el Modelo de Regresión Lineal Múltiple

Problemas 10.1, 10.2 y 10.3 — Gujarati & Porter

Emanuel Quintana Silva
Econometría — Universidad Pedagógica y Tecnológica de Colombia, UPTC

Resumen. *Se demuestra, con rigor algebraico y verificación numérica explícita, que la multicolinealidad perfecta hace imposible la estimación MCO de los coeficientes individuales (Prob. 10.1); se identifican las funciones estimables que sí pueden recuperarse y se calculan explícitamente (Prob. 10.2); finalmente, se analiza el modelo de Mortalidad Infantil ampliado con la Tasa de Fecundidad Total, estudiando el sesgo por omisión de variable, la pertinencia de la nueva variable y la relación entre significancia individual y colinealidad imperfecta (Prob. 10.3).*

Problema 10.1

Multicolinealidad Perfecta

ENUNCIADO DEL PROBLEMA 10.1

Enunciado 10.1 — Gujarati & Porter

En el modelo de regresión lineal de k variables, hay k ecuaciones normales para estimar las k incógnitas. Suponga que X_k es una combinación lineal perfecta de las variables X restantes. **¿Cómo se demostraría que en este caso es imposible estimar los k coeficientes de regresión?**

Se dispone de los siguientes datos ($n = 11$ observaciones):

i	Y_i	X_{2i}	X_{3i}
1	-10	1	1
2	-8	2	3
3	-6	3	5
4	-4	4	7
5	-2	5	9
6	0	6	11
7	2	7	13
8	4	8	15
9	6	9	17
10	8	10	19
11	10	11	21
Σ	**0**	**66**	**121**

Cuadro 1: *Datos del Problema 10.1*

MARCO TEÓRICO

Estimador MCO Matricial

El modelo $\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{u}$ admite estimación MCO única si y solo si $\text{rg}(\boldsymbol{X}) = k$.

Definición

Bajo los supuestos de Gauss-Markov ($\mathrm{E}[\boldsymbol{u}|\boldsymbol{X}] = \mathbf{0}$, $\mathrm{Var}[\boldsymbol{u}|\boldsymbol{X}] = \sigma^2 \boldsymbol{I}_n$, $\mathrm{rg}(\boldsymbol{X}) = k$), el estimador MCO es:

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y}$$

El supuesto $\mathrm{rg}(\boldsymbol{X}) = k$ es *indispensable* para que $(\boldsymbol{X}'\boldsymbol{X})^{-1}$ exista.

Las k Ecuaciones Normales

La condición de primer orden $\partial \mathrm{SRC}/\partial \boldsymbol{\beta} = \mathbf{0}$ produce $\boldsymbol{X}'\boldsymbol{X}\hat{\boldsymbol{\beta}} = \boldsymbol{X}'\boldsymbol{Y}$. En desviaciones respecto a la media, con dos regresores:

$$\begin{pmatrix} \sum_{i=1}^n x_{2i}^2 & \sum_{i=1}^n x_{2i}x_{3i} \\ \sum_{i=1}^n x_{2i}x_{3i} & \sum_{i=1}^n x_{3i}^2 \end{pmatrix} \begin{pmatrix} \hat{\beta}_2 \\ \hat{\beta}_3 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n x_{2i}y_i \\ \sum_{i=1}^n x_{3i}y_i \end{pmatrix} \tag{1}$$

IDENTIFICACIÓN DE LA DEPENDENCIA LINEAL

Detección Empírica

i	X_{2i}	$2X_{2i} - 1$	X_{3i}
1	1	1	1
6	6	11	11
11	11	21	21
Patrón idéntico en **todas** las 11 obs.			

Resultado Crítico

Sin excepción en ninguna observación:

$$X_{3i} = 2X_{2i} - 1, \qquad \forall\, i = 1, \ldots, 11$$

Equivalentemente, sobre las columnas de $\boldsymbol{X}$:

$$\boxed{-1 \cdot X_{1i} - 2 \cdot X_{2i} + 1 \cdot X_{3i} = 0}$$

con $(\lambda_1, \lambda_2, \lambda_3) = (-1, -2, 1) \neq \mathbf{0}$.

Reformulación en Desviaciones

Las medias son $\bar{Y} = 0$, $\bar{X}_2 = 6$, $\bar{X}_3 = 11$. En desviaciones: $x_{2i} = X_{2i} - 6$, $x_{3i} = X_{3i} - 11$. Dado que $X_{3i} = 2X_{2i} - 1$:

$$x_{3i} = (2X_{2i} - 1) - 11 = 2(X_{2i} - 6) = 2x_{2i}$$

Relación en desviaciones

$$x_{3i} = 2x_{2i}, \quad \forall\, i \qquad (\lambda = 2)$$

Cálculo de Momentos Muestrales

i	y_i	x_{2i}	x_{3i}	x_{2i}^2	x_{3i}^2	$x_{2i}x_{3i}$
1	−10	−5	−10	25	100	50
2	−8	−4	−8	16	64	32
3	−6	−3	−6	9	36	18
4	−4	−2	−4	4	16	8
5	−2	−1	−2	1	4	2
6	0	0	0	0	0	0
7	2	1	2	1	4	2
8	4	2	4	4	16	8
9	6	3	6	9	36	18
10	8	4	8	16	64	32
11	10	5	10	25	100	50
Σ	0	0	0	**110**	**440**	**220**

La matriz de momentos y el vector de productos cruzados son:

$$\boldsymbol{M} = \boldsymbol{X}'\boldsymbol{X} = \begin{pmatrix} 110 & 220 \\ 220 & 440 \end{pmatrix}, \quad \boldsymbol{X}'\boldsymbol{Y} = \begin{pmatrix} 220 \\ 440 \end{pmatrix} \tag{2}$$

DEMOSTRACIÓN: IMPOSIBILIDAD DE ESTIMACIÓN

Proposición Central

Proposición 4.1 (Indeterminación bajo Multicolinealidad Perfecta)**.** *Si existe $\boldsymbol{c} \neq \mathbf{0}$ tal que $\boldsymbol{X}\boldsymbol{c} = \mathbf{0}$, entonces $\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y}$* ***no existe****.*

Demostración. ***Paso 1. Singularidad de $\boldsymbol{X}'\boldsymbol{X}$.*** *Si $\boldsymbol{X}\boldsymbol{c} = \mathbf{0}$, premultiplicando por $\boldsymbol{X}'$:*

$$(\boldsymbol{X}'\boldsymbol{X})\boldsymbol{c} = \mathbf{0}, \quad \boldsymbol{c} \neq \mathbf{0} \implies \det(\boldsymbol{X}'\boldsymbol{X}) = 0$$

Paso 2. Inversa indefinida. $\det(\boldsymbol{X}'\boldsymbol{X}) = 0 \Rightarrow (\boldsymbol{X}'\boldsymbol{X})^{-1}$ *no existe.*

Paso 3. Infinitas soluciones. *Sea $\hat{\boldsymbol{\beta}}^*$ una solución particular. Para todo $\alpha \in \mathbb{R}$:*

$$\boldsymbol{X}'\boldsymbol{X}(\hat{\boldsymbol{\beta}}^* + \alpha\boldsymbol{c}) = \boldsymbol{X}'\boldsymbol{Y} + \alpha\underbrace{(\boldsymbol{X}'\boldsymbol{X})\boldsymbol{c}}_{=\mathbf{0}} = \boldsymbol{X}'\boldsymbol{Y}$$

Existe una ***familia infinita*** *de soluciones: los coeficientes individuales son inidentificables.* □

Vía Rango y el Teorema de la Dimensión

Rango de $\boldsymbol{X}'\boldsymbol{X}$

Para toda matriz $\boldsymbol{X}$: $\mathrm{rg}(\boldsymbol{X}'\boldsymbol{X}) = \mathrm{rg}(\boldsymbol{X})$.

Columnas linealmente dependientes $\Rightarrow \mathrm{rg}(\boldsymbol{X}) < k \Rightarrow \mathrm{rg}(\boldsymbol{X}'\boldsymbol{X}) < k \Rightarrow \det(\boldsymbol{X}'\boldsymbol{X}) = 0$.

Vía Desigualdad de Cauchy-Schwarz

$$D = \det(\boldsymbol{M}) = \left(\sum_{i=1}^n x_{2i}^2\right)\left(\sum_{i=1}^n x_{3i}^2\right) - \left(\sum_{i=1}^n x_{2i}x_{3i}\right)^2 \tag{3}$$

La igualdad de Cauchy-Schwarz se alcanza $\Leftrightarrow x_{3i} = \lambda x_{2i}$ (proporcionalidad exacta):

Resultado Crítico

Cuando $x_{3i} = \lambda x_{2i}$:

$$D = \lambda^2\left(\sum_{i=1}^n x_{2i}^2\right)^2 - \lambda^2\left(\sum_{i=1}^n x_{2i}^2\right)^2 = 0$$

$\boldsymbol{M}$ es singular: **estimadores MCO indeterminados.**

VERIFICACIÓN NUMÉRICA

Cálculo del Determinante

$$\begin{aligned} D &= (110)(440) - (220)^2 \\ &= 48{,}400 - 48{,}400 = \boxed{0} \end{aligned} \tag{4}$$

Directamente con $\lambda = 2$:

$$\sum x_{3i}^2 = 4 \times 110 = 440 \checkmark, \quad \sum x_{2i}x_{3i} = 2 \times 110 = 220 \checkmark$$

Coeficiente de Correlación r_{23}

$$r_{23} = \frac{220}{\sqrt{110 \times 440}} = \frac{220}{220} = \mathbf{1} \tag{5}$$

Regla de Cramer: Forma $0/0$

Aplicando la Regla de Cramer:

$$\hat{\beta}_2 = \frac{(220)(440) - (440)(220)}{0} = \frac{0}{0} \tag{6}$$

$$\hat{\beta}_3 = \frac{(440)(110) - (220)(220)}{0} = \frac{0}{0} \tag{7}$$

Resultado Crítico

$0/0$ es una **indeterminación matemática**: no existe ningún método aritmético que la resuelva. El estimador MCO es **algebraicamente imposible**.

Infinitas Soluciones

La primera ecuación normal se reduce a:

$$110\hat{\beta}_2 + 220\hat{\beta}_3 = 220 \;\Leftrightarrow\; \hat{\beta}_2 + 2\hat{\beta}_3 = 2$$

Su solución general, parametrizada por $\alpha \in \mathbb{R}$:

$$\hat{\beta}_2 = 2 - 2\alpha, \quad \hat{\beta}_3 = \alpha \tag{8}$$

α	$\hat{\beta}_2$	$\hat{\beta}_3$
0	2	0
1	0	1
1/2	1	1/2
-1	4	-1

Corolario

Todos los pares $(2 - 2\alpha, \alpha)$ producen el **mismo ajuste**:

$$\hat{y}_i = (2 - 2\alpha)x_{2i} + \alpha(2x_{2i}) = 2x_{2i}$$

La función ajustada es única; los coeficientes individuales, no.

CONSECUENCIAS ESTADÍSTICAS

Varianzas Infinitas

$$\mathrm{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum_{i=1}^n x_{2i}^2\,(1 - r_{23}^2)} = \frac{\sigma^2}{110 \times 0} \longrightarrow +\infty \tag{9}$$

Análisis Espectral de la Matriz M

Ecuación característica: $\mu(\mu - 550) = 0$. Eigenvalores: $\mu_1 = 0$, $\mu_2 = 550$.

Interpretación Espectral

$\mu_1 = 0$ confirma singularidad: $\det(\boldsymbol{M}) = 0 \times 550 = 0$, $\mathrm{rg}(\boldsymbol{M}) = 1 < 2$. Número de condición: $\kappa = 550/0 = +\infty$ (señal definitiva).

Las Tres Consecuencias Formales

1. **Indeterminación:** $(\boldsymbol{X}'\boldsymbol{X})^{-1}$ indefinida; infinitas soluciones.
2. **Varianzas infinitas:** $\mathrm{Var}(\hat{\beta}_j) \to +\infty$; intervalos $(-\infty, +\infty)$.
3. **Fallo de identificación:** imposible separar efecto de X_2 y X_3.

GENERALIZACIÓN AL MODELO DE K VARIABLES

Proposición 7.1 (Caso General)**.** *Si* $X_k = \sum_{j=1}^{k-1} \lambda_j X_j$ *con algún* $\lambda_j \neq 0$*, entonces: (a) columnas de* $\boldsymbol{X}$ *son linealmente dependientes; (b)* $\mathrm{rg}(\boldsymbol{X}) < k$ *y* $\mathrm{rg}(\boldsymbol{X}'\boldsymbol{X}) < k$*; (c)* $\det(\boldsymbol{X}'\boldsymbol{X}) = 0$ *e* $(\boldsymbol{X}'\boldsymbol{X})^{-1}$ *no existe; (d) infinitas soluciones a las* k *ecuaciones normales; (e)* $\mathrm{Var}(\hat{\beta}_j) \to +\infty$ *para todo* j *afectado.*

Si X_k es combinación lineal de las demás, la última fila de la matriz de coeficientes normales es combinación lineal de las otras filas, haciendo el sistema **compatible indeterminado** en vez de **compatible determinado** (requerido para MCO).

Conclusión Problema 10.1

La multicolinealidad perfecta $X_{3i} = 2X_{2i} - 1$ implica $D = 48{,}400 - 48{,}400 = 0$, $r_{23} = 1$, eigenvalores $\{0, 550\}$, y formas $0/0$ para $\hat{\beta}_2$ y $\hat{\beta}_3$. La estimación MCO individual es **algebraica y estadísticamente**

imposible.

Problema 10.2

Funciones Estimables bajo Multicolinealidad

ENUNCIADO DEL PROBLEMA 10.2

Enunciado 10.2 — Gujarati & Porter

Considere el mismo conjunto de datos del Problema 10.1. Se desea ajustar:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

(a) ¿Puede estimar las tres incógnitas $\beta_1, \beta_2, \beta_3$? ¿Por qué?

(b) Si no se puede, ¿qué *funciones lineales* de estos parámetros (funciones estimables) sí pueden estimarse? Muestre los cálculos necesarios.

PARTE (A): IMPOSIBILIDAD DE ESTIMACIÓN INDIVIDUAL

Del análisis del Problema 10.1 sabemos que los datos satisfacen la relación de dependencia perfecta:

$$\boldsymbol{X}_3 = 2\boldsymbol{X}_2 - \boldsymbol{X}_1 \iff -\boldsymbol{X}_1 - 2\boldsymbol{X}_2 + \boldsymbol{X}_3 = \boldsymbol{0}$$

Resultado Crítico

No, no es posible estimar individualmente $\beta_1, \beta_2, \beta_3$. La matriz $\boldsymbol{X}_{11\times 3}$ tiene rango 2 (en vez de 3), $\det(\boldsymbol{X}'\boldsymbol{X}) = 0$, $(\boldsymbol{X}'\boldsymbol{X})^{-1}$ no existe y las ecuaciones normales tienen infinitas soluciones.

Consecuencia Geométrica

El espacio columna de $\boldsymbol{X}$ es bidimensional:

$$\mathrm{col}(\boldsymbol{X}) = \mathrm{span}\{\boldsymbol{X}_1, \boldsymbol{X}_2, \boldsymbol{X}_3\} = \mathrm{span}\{\boldsymbol{X}_1, \boldsymbol{X}_2\}$$

El modelo tiene tres parámetros pero solo **dos grados de libertad paramétricos** efectivos.

PARTE (B): FUNCIONES ESTIMABLES

Marco Teórico

Definición

Una combinación lineal $\boldsymbol{\lambda}'\boldsymbol{\beta}$ es **estimable** si existe $\boldsymbol{a}$ tal que $\boldsymbol{a}'\boldsymbol{Y}$ es un estimador lineal insesgado de $\boldsymbol{\lambda}'\boldsymbol{\beta}$. Equivalentemente, $\boldsymbol{\lambda} \in \mathrm{row}(\boldsymbol{X})$.

Derivación Algebraica por Sustitución

Paso 1. Modelo original:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

Paso 2. Sustitución de $X_{3i} = 2X_{2i} - 1$:

$$\begin{aligned} Y_i &= \beta_1 + \beta_2 X_{2i} + \beta_3(2X_{2i} - 1) + u_i \\ &= (\beta_1 - \beta_3) + (\beta_2 + 2\beta_3)X_{2i} + u_i \end{aligned} \tag{10}$$

Paso 3. Modelo reducido:

$$Y_i = \underbrace{(\beta_1 - \beta_3)}_{\alpha_1} + \underbrace{(\beta_2 + 2\beta_3)}_{\alpha_2} X_{2i} + u_i \tag{11}$$

Funciones Estimables Identificadas

Las dos únicas combinaciones lineales independientes estimables son:

$$\alpha_1 = \beta_1 - \beta_3 \quad \text{(intercepto reducido)} \tag{12}$$
$$\alpha_2 = \beta_2 + 2\beta_3 \quad \text{(pendiente reducida)} \tag{13}$$

CÁLCULO NUMÉRICO

Estimadores MCO del Modelo Reducido

Datos de cálculo en desviaciones ($\bar{Y} = 0$, $\bar{X}_2 = 6$):

i	y_i	x_{2i}	$x_{2i}y_i$
1	−10	−5	50
2	−8	−4	32
3	−6	−3	18
4	−4	−2	8
5	−2	−1	2
6	0	0	0
7	2	1	2
8	4	2	8
9	6	3	18
10	8	4	32
11	10	5	50
Σ	0	0	**220**

Pendiente:

$$\hat{\alpha}_2 = \frac{\sum x_{2i}y_i}{\sum x_{2i}^2} = \frac{220}{110} = \boxed{2} \tag{14}$$

Intercepto:

$$\hat{\alpha}_1 = \bar{Y} - \hat{\alpha}_2\bar{X}_2 = 0 - 2 \times 6 = \boxed{-12} \tag{15}$$

Ecuación de Regresión Estimada

$$\hat{Y}_i = -12 + 2X_{2i} \tag{16}$$

Verificación: Ajuste Perfecto

i	Y_i	$\hat{Y}_i = -12 + 2X_{2i}$
1	−10	$-12 + 2(1) = -10$
6	0	$-12 + 2(6) = 0$
11	10	$-12 + 2(11) = 10$
Todos		$\hat{u}_i = 0\ \forall\, i$

Corolario

Todos los residuos son exactamente cero: SRC = 0, $R^2 = 1$. El ajuste perfecto es consecuencia directa de la multicolinealidad: los datos yacen en un subespacio de dimensión inferior.

INTERPRETACIÓN DE LAS FUNCIONES ESTIMABLES

Lo que Sí Podemos Saber

$$\hat{\beta}_1 - \hat{\beta}_3 = -12 \tag{17}$$
$$\hat{\beta}_2 + 2\hat{\beta}_3 = 2 \tag{18}$$

Lo que No Podemos Saber

Dos ecuaciones con tres incógnitas; solución general con $t \in \mathbb{R}$:

$$\beta_1 = -12 + t, \quad \beta_2 = 2 - 2t, \quad \beta_3 = t \tag{19}$$

t	β_1	β_2	β_3	$\beta_1-\beta_3$	$\beta_2+2\beta_3$
0	−12	2	0	−12	2
1	−11	0	1	−12	2
−1	−13	4	−1	−12	2
3	−9	−4	3	−12	2

Resultado Crítico

Las funciones $\beta_1 - \beta_3$ y $\beta_2 + 2\beta_3$ son **invariantes** al parámetro libre t: son las únicas invariantes que los datos pueden identificar.

Conclusión Problema 10.2

(a) No es posible estimar $\beta_1, \beta_2, \beta_3$ individualmente.

(b) Las dos funciones estimables independientes son:

$$\hat{\alpha}_1 = \hat{\beta}_1 - \hat{\beta}_3 = \mathbf{-12}$$

$$\hat{\alpha}_2 = \hat{\beta}_2 + 2\hat{\beta}_3 = \mathbf{2}$$

produciendo $\hat{Y}_i = -12 + 2X_{2i}$ con $R^2 = 1$ y SRC = 0.

Problema 10.3

Mortalidad Infantil, Fecundidad y Colinealidad Imperfecta

ENUNCIADO DEL PROBLEMA 10.3

Enunciado 10.3 — Gujarati & Porter

Consulte el ejemplo de la mortalidad infantil del Cap. 8 (Ec. 8.1.4), que regresaba MI sobre PIBPC y TAM. Ahora se añade la TFT. Los resultados son los de la Tabla 2.

(a) Compare con la Ec. (8.1.4). ¿Qué cambios observa? ¿Cómo los explica?

(b) ¿Vale la pena añadir TFT al modelo? ¿Por qué?

(c) Como todos los coeficientes t son significativos, ¿podemos decir que no existe colinealidad?

Variable	Coef.	EE	t
C	168.307	32.892	5.117
PIBPC	−0.00551	0.00188	−2.934
TAM	−1.768	0.248	−7.129
TFT	12.869	4.191	3.071
$R^2 = 0.7474$; $\bar{R}^2 = 0.7347$; $F = 59.17$ ($p < 0.0001$)			
SRC = 91,875; $\hat{\sigma} = 39.13$; $n \approx 64$			

Cuadro 2: *Regresión ampliada: MI sobre PIBPC, TAM y TFT*

MARCO TEÓRICO: MODELO AMPLIADO

Especificación

$$MI_i = \beta_1 + \beta_2\,\text{PIBPC}_i + \beta_3\,\text{TAM}_i + \beta_4\,\text{TFT}_i + u_i \quad (20)$$

En matricial: $\boldsymbol{y} = \boldsymbol{X}_{n\times 4}\boldsymbol{\beta} + \boldsymbol{u}$. El estimador MCO, la varianza residual y los errores estándar son:

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y} \quad (21)$$

$$\hat{\sigma}^2 = \frac{\text{SRC}}{n-k} = \frac{91{,}875}{60} \approx 1{,}531 \quad (22)$$

$$\text{Var}(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2(\boldsymbol{X}'\boldsymbol{X})^{-1} \quad (23)$$

PARTE (A): COMPARACIÓN CON EC. 8.1.4

El modelo original regresaba MI solo sobre PIBPC y TAM. Al incorporar la TFT se producen tres cambios observables.

Mejora en la Bondad de Ajuste

$$\Delta R^2 = 0.7474 - 0.7077 = 0.0397 \quad (24)$$

Una ganancia del 3.97% adicional de varianza explicada. El $\bar{R}^2$ también aumenta (de 0.6981 a 0.7347), confirmando que la mejora no es un artefacto del número de parámetros.

Cambio en el Coeficiente de TAM

$$\Delta\hat{\beta}_{\text{TAM}} = -1.7680 - (-2.2316) = +0.4636 \quad (25)$$

Una *atenuación* del 20.8% en valor absoluto. El coeficiente del PIBPC permaneció relativamente estable ($-0.00560 \to -0.00551$).

Explicación: Sesgo por Omisión (OVB)

Definición

Cuando se omite la variable X_2 (TFT) del modelo verdadero $\boldsymbol{y} = \boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{X}_2\boldsymbol{\beta}_2 + \boldsymbol{u}$, el estimador del parámetro de $\boldsymbol{X}_1$ (TAM) satisface:

$$\text{plim}\,\hat{\boldsymbol{\beta}}_1^{\text{corto}} = \boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\,\boldsymbol{\beta}_2$$

El sesgo es $(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\,\boldsymbol{\beta}_2 \neq \boldsymbol{0}$ cuando TFT y TAM están correlacionadas **y** TFT es relevante ($\beta_4 \neq 0$).

Dado que $\hat{\beta}_{\text{TFT}} = +12.87 > 0$ (mayor fecundidad $\Rightarrow$ mayor MI) y la correlación TAM-TFT es negativa (mayor alfabetización $\Rightarrow$ menor fecundidad), el producto del sesgo era negativo, haciendo que el coeficiente de TAM apareciera **más negativo** de lo real. La incorporación de TFT corrige este sesgo.

Resumen de Cambios (a)

	Ec. 8.1.4	Ec. 10.3
R^2	0.7077	0.7474
$\hat{\beta}_{\text{PIBPC}}$	−0.00560	−0.00551
$\hat{\beta}_{\text{TAM}}$	−2.2316	−1.7680
TFT incluida	No	Sí

PARTE (B): ¿VALE LA PENA INCLUIR TFT?

Criterio del Estadístico t

$$t_{\hat{\beta}_4} = \frac{12.869}{4.191} = 3.071, \quad p = 0.0032 < 0.05 \quad (26)$$

Con $\nu = n-k = 60$ g.l., $t_{0.025,60} \approx 2.00$. Como $|3.071| > 2.00$, se **rechaza** $H_0 : \beta_4 = 0$.

Criterio del $\bar{R}^2$

Definición

$\bar{R}^2 = 1 - \dfrac{(1-R^2)(n-1)}{n-k}$ aumenta al añadir X_j si y solo si $|t_j| > 1$.

Como $|t_{\text{TFT}}| = 3.071 > 1$, el $\bar{R}^2$ aumentó de 0.6981 a 0.7347. ✓

Criterios de Información

$$\text{AIC} = \ln\left(\frac{\text{SRC}}{n}\right) + \frac{2k}{n} \tag{27}$$

$$\text{BIC} = \ln\left(\frac{\text{SRC}}{n}\right) + \frac{k \ln n}{n} \tag{28}$$

Los valores reportados (AIC = 10.23, BIC = 10.37) deben ser menores al del modelo restringido para confirmar la mejora neta.

Justificación Teórica

La hipótesis *cantidad-calidad* de Becker (1960) establece que familias con mayor fecundidad disponen de menos recursos per cápita por hijo, elevando la mortalidad infantil. La TFT captura directamente este canal causal.

Corolario

Sí vale la pena añadir la TFT. Los cuatro criterios —estadístico t, $\bar{R}^2$, criterios de información y teoría económica— convergen en favorecer su inclusión.

PARTE (C): SIGNIFICANCIA INDIVIDUAL Y COLINEALIDAD

No. La afirmación de que "todos los coeficientes son significativos, luego no hay colinealidad" es un **error conceptual clásico**.

El Factor de Inflación de la Varianza

Definición

El **FIV** del estimador $\hat{\beta}_j$ es:

$$\text{FIV}_j = \frac{1}{1 - R_j^2}, \quad \text{Var}(\hat{\beta}_j) = \frac{\hat{\sigma}^2}{\sum x_{ji}^2} \cdot \text{FIV}_j$$

donde R_j^2 es el R^2 de la regresión auxiliar de X_j sobre los demás regresores.

La colinealidad infla el denominador del estadístico t:

$$t_j = \frac{\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 \cdot [(\boldsymbol{X}'\boldsymbol{X})^{-1}]_{jj}}}$$

Si los t siguen siendo significativos pese a ello, simplemente indica que la colinealidad **no es lo suficientemente severa** para anularlos.

Evidencia Indirecta de Colinealidad

El cambio en $\hat{\beta}_{\text{TAM}}$ al incluir TFT:

$$\frac{|\Delta\hat{\beta}_{\text{TAM}}|}{|\hat{\beta}_{\text{TAM}}^{\text{orig}}|} = \frac{0.4636}{2.2316} \approx 20.8\% \tag{29}$$

Un cambio de esta magnitud indica alta correlación entre TAM y TFT. Formalmente, si $r_{\text{TAM,TFT}}$ es elevada, entonces R^2_{TAM} en la regresión auxiliar es alto y $\text{FIV}_{\text{TAM}} \gg 1$.

Resultado Crítico

Regla de Klein (1962): si R_j^2 (regresión auxiliar) supera R^2 del modelo principal, la colinealidad es problemática. La colinealidad existe y es econométricamente relevante, aunque no impide la estimación.

La Colinealidad es una Cuestión de Grado

La multicolinealidad perfecta ($\det = 0$) hace inviable la estimación. La imperfecta ($0 < |\det| < \infty$) no la impide, pero:

1. Infla errores estándar, reduciendo la potencia de los tests.
2. Hace los estimadores sensibles a cambios muestrales o de especificación.
3. Dificulta atribuir el efecto marginal a una sola variable.

Conclusión Problema 10.3

(a) $R^2 \uparrow$ (+3.97%); $\hat{\beta}_{\text{TAM}}$ menos negativo por corrección del sesgo OVB.

(b) Sí, la TFT debe incluirse: $t = 3.07$ ($p = 0.003$), $\bar{R}^2 \uparrow$, sustento teórico sólido.

(c) No es posible concluir ausencia de colinealidad. El cambio en $\hat{\beta}_{\text{TAM}}$ es evidencia directa de correlación entre regresores. La colinealidad imperfecta existe y afecta las estimaciones sin hacerlas inviables.

Anexo Técnico

Formulario Matemático, Definiciones Econométricas y Fundamentos Teóricos

A.1 Modelo de Regresión Lineal Múltiple

El modelo poblacional con $k-1$ regresores e intercepto:

$$Y_i = \beta_1 + \sum_{j=2}^{k} \beta_j X_{ji} + u_i, \quad i = 1, \ldots, n$$

En matricial: $\boldsymbol{y}_{n\times 1} = \boldsymbol{X}_{n\times k}\boldsymbol{\beta}_{k\times 1} + \boldsymbol{u}_{n\times 1}$.

Supuestos de Gauss-Markov:

I. $\mathrm{E}[\boldsymbol{u}|\boldsymbol{X}] = \boldsymbol{0}$ (media condicional nula)

II. $\mathrm{Var}[\boldsymbol{u}|\boldsymbol{X}] = \sigma^2 \boldsymbol{I}_n$ (homocedasticidad)

III. $\mathrm{rg}(\boldsymbol{X}) = k$ (no multicolinealidad perfecta)

Interpretación económica: cada β_j mide el efecto parcial de X_j sobre Y manteniendo fijos los demás regresores (principio *ceteris paribus*).

A.2 Estimador MCO y sus Propiedades

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$$

Propiedades:

- *Linealidad:* $\hat{\boldsymbol{\beta}} = \boldsymbol{A}\boldsymbol{y}$, $\boldsymbol{A} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'$
- *Insesgadez:* $\mathrm{E}[\hat{\boldsymbol{\beta}}|\boldsymbol{X}] = \boldsymbol{\beta}$
- *Eficiencia (BLUE):* mínima varianza entre estimadores lineales insesgados (Gauss-Markov)

Geometría: $\boldsymbol{X}'\boldsymbol{y}$ proyecta $\boldsymbol{y}$ sobre el espacio columna de $\boldsymbol{X}$; $(\boldsymbol{X}'\boldsymbol{X})^{-1}$ normaliza por la dispersión de los regresores.

A.3 Descomposición de la Varianza

$$\underbrace{\boldsymbol{y}'\boldsymbol{y} - n\bar{y}^2}_{\text{STC}} = \underbrace{\hat{\boldsymbol{\beta}}'\boldsymbol{X}'\boldsymbol{y} - n\bar{y}^2}_{\text{SEC}} + \underbrace{\hat{\boldsymbol{u}}'\hat{\boldsymbol{u}}}_{\text{SRC}}$$

Sigla	Nombre	Significado
STC	Total	Variabilidad total de Y
SEC	Explicada	Explicada por $\boldsymbol{X}$
SRC	Residual	No explicada

A.4 Varianza Residual y Errores Estándar

$$\hat{\sigma}^2 = \frac{\hat{\boldsymbol{u}}'\hat{\boldsymbol{u}}}{n-k} = \frac{\text{SRC}}{n-k}$$

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2(\boldsymbol{X}'\boldsymbol{X})^{-1}$$

$$\mathrm{ee}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 \cdot [(\boldsymbol{X}'\boldsymbol{X})^{-1}]_{jj}}$$

El denominador $n-k$ corrige los grados de libertad consumidos en estimar k parámetros.

Interpretación: $\hat{\sigma} = 39.13$ (Prob. 10.3) implica un error promedio de 39 muertes por 1,000 nacidos vivos al predecir MI.

A.5 Coeficiente de Determinación R^2

$$R^2 = \frac{\text{SEC}}{\text{STC}} = 1 - \frac{\text{SRC}}{\text{STC}} = \frac{\hat{\boldsymbol{\beta}}'\boldsymbol{X}'\boldsymbol{y} - n\bar{y}^2}{\boldsymbol{y}'\boldsymbol{y} - n\bar{y}^2}$$

$$\bar{R}^2 = 1 - \frac{\text{SRC}/(n-k)}{\text{STC}/(n-1)} = 1 - (1-R^2)\frac{n-1}{n-k}$$

Regla de inclusión: añadir X_j aumenta $\bar{R}^2 \Leftrightarrow |t_j| > 1$.

Interpretación: $R^2 = 0.7474$ (Prob. 10.3) implica que el modelo explica el 74.74% de la variabilidad de MI.

A.6 Estadístico t y Test Individual

Para $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$:

$$t_j = \frac{\hat{\beta}_j}{\mathrm{ee}(\hat{\beta}_j)} \sim t_{n-k} \quad \text{bajo } H_0$$

Se rechaza H_0 si $|t_j| > t_{\alpha/2,\, n-k}$.

Para TFT: $t = 12.869/4.191 = 3.071$, $p = 0.0032 < 0.05$.

Interpretación: si $\beta_4 = 0$ en la población, la probabilidad de observar $|t| \geq 3.07$ es solo 0.32%: evidencia muy fuerte de efecto real.

A.7 Estadístico F y Test Global

Para $H_0 : \beta_2 = \cdots = \beta_k = 0$:

$$F = \frac{\text{SEC}/(k-1)}{\text{SRC}/(n-k)} = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \sim F_{k-1,\, n-k}$$

En Prob. 10.3: $F = 59.17$ con $p < 0.0001$.

Interpretación: PIBPC, TAM y TFT explican conjuntamente MI de forma altamente significativa.

A.8 Sesgo por Omisión de Variable (OVB)

Modelo verdadero: $\boldsymbol{y} = \boldsymbol{X}_1\boldsymbol{\beta}_1 + \boldsymbol{X}_2\boldsymbol{\beta}_2 + \boldsymbol{u}$. Si se estima omitiendo $\boldsymbol{X}_2$:

$$\mathrm{plim}\ \hat{\boldsymbol{\beta}}_1^{\text{corto}} = \boldsymbol{\beta}_1 + (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\boldsymbol{X}_2\,\boldsymbol{\beta}_2$$

El sesgo es nulo solo si $\boldsymbol{\beta}_2 = \boldsymbol{0}$ o $\boldsymbol{X}_1 \perp \boldsymbol{X}_2$.

Aplicación (Prob. 10.3): al omitir TFT, el coeficiente de TAM capturaba su efecto indirecto sobre MI a través de la fecundidad, sobreestimando su magnitud en valor absoluto.

A.9 Factor de Inflación de la Varianza (FIV)

$$\mathrm{FIV}_j = \frac{1}{1-R_j^2}, \quad \mathrm{Var}(\hat{\beta}_j) = \frac{\hat{\sigma}^2}{\sum x_{ji}^2} \cdot \mathrm{FIV}_j$$

FIV	Diagnóstico
1	Sin colinealidad
1–5	Moderada
5–10	Alta
> 10	Severa

Interpretación: $\mathrm{FIV}_j = 5$ significa que la varianza de $\hat{\beta}_j$ es 5 veces la que tendría en ausencia de colinealidad.

A.10 Criterios AIC y BIC

$$\mathrm{AIC} = \ln\left(\frac{\mathrm{SRC}}{n}\right) + \frac{2k}{n}$$

$$\mathrm{BIC} = \ln\left(\frac{\mathrm{SRC}}{n}\right) + \frac{k \ln n}{n}$$

BIC penaliza más duramente con muestras grandes ($\ln n > 2$). Se prefiere el modelo con *menor* AIC o BIC.

Ventaja: permiten comparar modelos no anidados, algo que R^2 no puede hacer al aumentar siempre con más regresores.

A.11 Multicolinealidad: Tipos y Consecuencias

Perfecta: $\exists\, \boldsymbol{c} \neq \boldsymbol{0}$: $\boldsymbol{X}\boldsymbol{c} = \boldsymbol{0}$. $\det(\boldsymbol{X}'\boldsymbol{X}) = 0$; estimación imposible.

Imperfecta: correlación alta pero no exacta. No viola supuestos de Gauss-Markov; MCO sigue siendo BLUE. Consecuencias:

1. $\mathrm{Var}(\hat{\beta}_j) \uparrow$; estimadores imprecisos
2. Coeficientes muy sensibles a cambios muestrales
3. Signos o magnitudes potencialmente inconsistentes con la teoría
4. Tests t con baja potencia (pero no necesariamente no significativos)

A.12 Determinante e Invertibilidad de $X'X$

Para la matriz 2×2 de momentos en desviaciones:

$$D = \left(\sum x_{2i}^2\right)\left(\sum x_{3i}^2\right) - \left(\sum x_{2i}x_{3i}\right)^2$$

Por Cauchy-Schwarz: $D \geq 0$, con igualdad $\Leftrightarrow x_{3i} = \lambda x_{2i}$.

Número de condición: $\kappa = \mu_{\max}/\mu_{\min}$. Si $\mu_{\min} = 0$, $\kappa = +\infty$ y la matriz es singular.

Verificación (Prob. 10.1): $D = (110)(440) - (220)^2 = 48{,}400 - 48{,}400 = 0$, $\kappa = 550/0 = +\infty$.

A.13 Glosario de Variables (Probs. 10.1–10.3)

Var.	Definición y unidad
Y	Variable dependiente genérica
X_j	Regresor j-ésimo (incluye intercepto $X_1 \equiv 1$)
MI	Mortalidad Infantil: muertes < 1 año por 1,000 nacidos vivos
PIBPC	PIB per cápita en USD constantes
TAM	Tasa de Alfabetización de Mujeres adultas (%)
TFT	Tasa de Fecundidad Total: hijos promedio por mujer fértil

Signos esperados (Prob. 10.3): $\hat{\beta}_{\mathrm{PIBPC}} < 0$ (riqueza mejora salud); $\hat{\beta}_{\mathrm{TAM}} < 0$ (educación femenina reduce MI); $\hat{\beta}_{\mathrm{TFT}} > 0$ (mayor fecundidad reduce inversión por hijo $\Rightarrow$ mayor MI).

A.14 Funciones Estimables: Teoría General

Definición

$\boldsymbol{\lambda}'\boldsymbol{\beta}$ es **estimable** si existe $\boldsymbol{a}$ tal que $\boldsymbol{a}'\boldsymbol{y}$ es lineal insesgado de $\boldsymbol{\lambda}'\boldsymbol{\beta}$. Equivalentemente: $\boldsymbol{\lambda} \in \mathrm{row}(\boldsymbol{X}) = \mathrm{col}(\boldsymbol{X}')$.

Cuando $\mathrm{rg}(\boldsymbol{X}) = r < k$, el espacio estimable tiene dimensión r. Solo r combinaciones lineales independientes pueden estimarse.

Aplicación (Prob. 10.2): con $\mathrm{rg}(\boldsymbol{X}) = 2 < 3$, solo dos funciones son estimables: $\alpha_1 = \beta_1 - \beta_3 = -12$ y $\alpha_2 = \beta_2 + 2\beta_3 = 2$. La recta de soluciones $(\beta_1, \beta_2, \beta_3) = (-12 + t, 2 - 2t, t)$ produce siempre el mismo ajuste $\hat{Y}_i = -12 + 2X_{2i}$ con $R^2 = 1$.