Heteroscedasticidad

¿Qué ocurre cuando la varianza del error no es constante?

Contenido del documento

§11.1 Naturaleza de la heteroscedasticidad
§11.2 Estimación por MCO bajo heteroscedasticidad
§11.3 Mínimos Cuadrados Generalizados (MCG)
§11.4 Consecuencias formales del uso de MCO
§11.5 Detección de la heteroscedasticidad
§11.6 Medidas remediales
§11.7 Ejemplos finales con datos reales
§11.8 Ejercicios resueltos
§§A Anexo de fórmulas derivadas paso a paso

Documento Académico de Referencia

Teoría · Demostraciones · Ejemplos Numéricos · Ejercicios Resueltos

Contents

Chapter 1

Heteroscedasticidad: Fundamentos, Detección y Corrección

1.1 Naturaleza de la Heteroscedasticidad

1.1.1 El Modelo Lineal Clásico y el Supuesto de Homocedasticidad

El Modelo Lineal Clásico (MLC) de regresión múltiple puede escribirse matricialmente como:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} \tag{1.1}$$

donde $\mathbf{y}$ es el vector $(n \times 1)$ de la variable dependiente, $\mathbf{X}$ es la matriz $(n \times k)$ de regresores (incluyendo la constante), $\boldsymbol{\beta}$ es el vector $(k \times 1)$ de parámetros desconocidos, y $\mathbf{u}$ es el vector $(n \times 1)$ de perturbaciones estocásticas.

Entre los supuestos estándar, el de **homocedasticidad** establece que:

$$\mathbb{E}(u_i^2) = \sigma^2 \quad \forall\, i = 1, 2, \ldots, n \tag{1.2}$$

O de forma matricial, la estructura de varianza-covarianza de las perturbaciones es:

$$\mathbb{E}(\mathbf{u}\mathbf{u}') = \sigma^2 \mathbf{I}_n \tag{1.3}$$

Definición 11.1: Homocedasticidad

Se dice que un modelo presenta **homocedasticidad** cuando la varianza de las perturbaciones es constante e igual a σ^2 para todas las observaciones, indepen-

dientemente de los valores que tomen las variables explicativas. Formalmente: $\mathrm{Var}(u_i \mid X_i) = \sigma^2$ para todo i.

Definición 11.2: Heteroscedasticidad

Se dice que un modelo presenta **heteroscedasticidad** cuando la varianza de las perturbaciones no es constante, sino que varía a lo largo de las observaciones:

$$\mathbb{E}(u_i^2) = \sigma_i^2, \quad \sigma_i^2 \neq \sigma_j^2 \text{ para al menos algún } i \neq j \tag{1.4}$$

La estructura de varianza-covarianza pasa a ser una matriz diagonal no escalar:

$$\mathbb{E}(\mathbf{u}\mathbf{u}') = \mathbf{\Omega} = \begin{pmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n^2 \end{pmatrix} \tag{1.5}$$

1.1.2 Representación Gráfica Comparativa

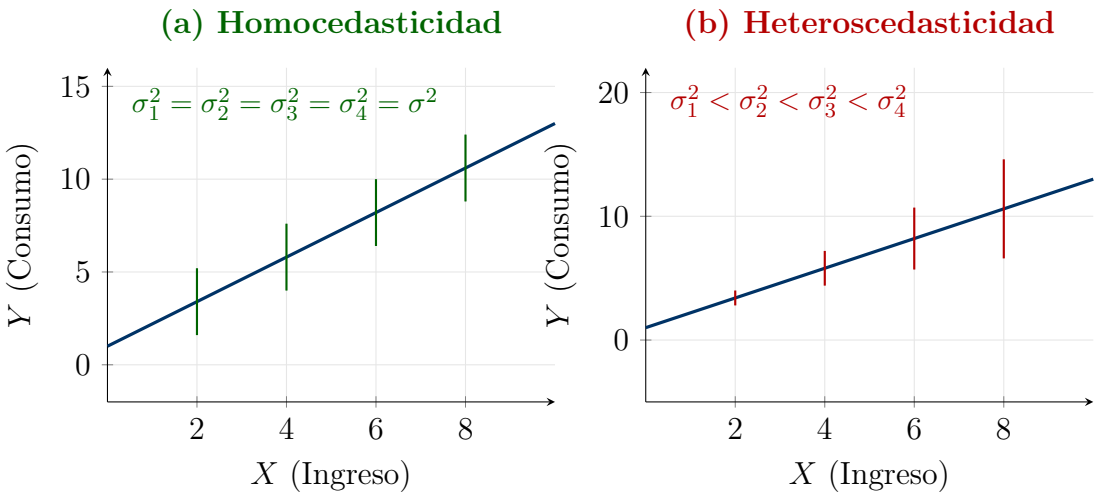

Figure 1.1: Comparación gráfica entre homocedasticidad y heteroscedasticidad. Las barras verticales representan la dispersión condicional de Y dado X. En el panel (a) la dispersión es constante; en el panel (b) crece con X, patrón típico en datos de ingreso-consumo.

1.1.3 Causas Económicas de la Heteroscedasticidad

Causas Principales

1. **Discrecionalidad en el ingreso (Efecto escala):** Las familias con ingresos altos tienen mayor discrecionalidad en su gasto, exhibiendo mayor variabilidad en el consumo que las familias de bajos ingresos. Si $\sigma_i^2 = f(\text{Ingreso}_i)$, con $f' > 0$, la varianza crece con el nivel de ingresos.
2. **Mejora en técnicas de recolección de datos:** A medida que el tiempo avanza y las metodologías estadísticas mejoran (censos, encuestas), los errores de medición se reducen, disminuyendo σ_i^2 a lo largo del tiempo.
3. **Efecto aprendizaje:** En estudios de productividad o errores de predicción, la varianza tiende a decrecer conforme los agentes acumulan experiencia.
4. **Valores atípicos (Outliers):** Una sola observación extrema puede sesgar drásticamente las estimaciones de la varianza, especialmente con muestras pequeñas.
5. **Errores de especificación:** Si el modelo verdadero es $Y_i = \beta_1 + \beta_2 X_i^2 + u_i$ pero se estima $Y_i = \alpha_1 + \alpha_2 X_i + v_i$, el término v_i absorberá el efecto cuadrático omitido, generando una varianza que aumenta con X.
6. **Asimetría distribucional:** Variables como el ingreso, la riqueza, o el tamaño de las empresas tienen distribuciones muy asimétricas hacia la derecha. Las observaciones en la cola derecha son escasas pero de alta variabilidad, induciendo heteroscedasticidad.
7. **Datos de corte transversal (Cross-section):** Cuando se mezclan unidades muy heterogéneas (ej. empresas con ventas de \$1M y otras con ventas de \$50,000M), la varianza naturalmente difiere entre grupos.

1.1.4 Formas Funcionales Comunes de Heteroscedasticidad

En la práctica, se asume que σ_i^2 es una función de las variables explicativas. Las especificaciones más comunes son:

$$\sigma_i^2 = \sigma^2 X_i^\alpha \qquad \text{(Park: potencia)} \tag{1.6}$$

$$\sigma_i^2 = \sigma^2 e^{\alpha X_i} \qquad \text{(exponencial)} \tag{1.7}$$

$$\sigma_i^2 = (\alpha_0 + \alpha_1 X_i)^2 \qquad \text{(lineal en SD)} \tag{1.8}$$

$$\sigma_i^2 = \alpha_0 + \alpha_1 X_i^2 \qquad \text{(Glejser cuadrática)} \tag{1.9}$$

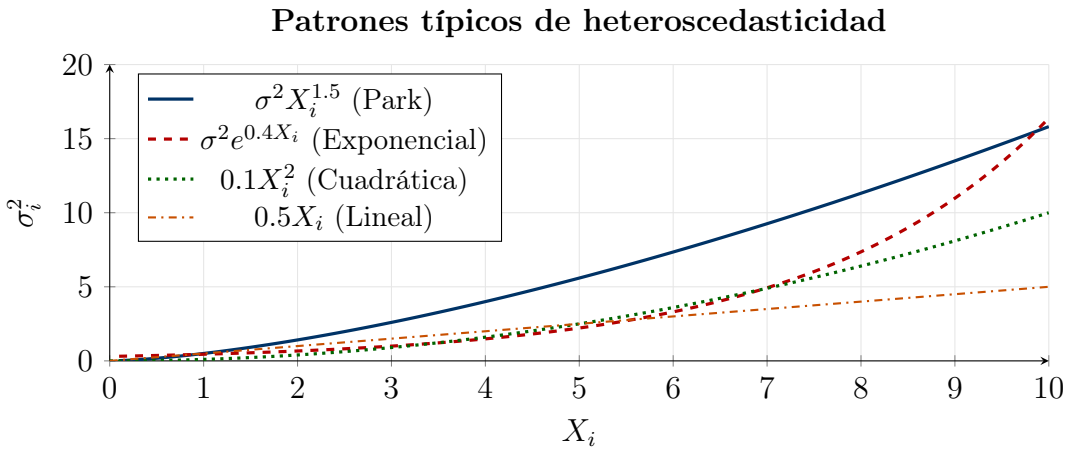

Figure 1.2: Distintas formas funcionales de la varianza heteroscedástica como función de la variable independiente X_i.

1.2 Estimación por MCO en Presencia de Heteroscedasticidad

1.2.1 El Estimador MCO

Para el modelo simple $Y_i = \beta_1 + \beta_2 X_i + u_i$, el estimador de mínimos cuadrados ordinarios minimiza la suma de cuadrados residuales sin ponderar:

$$S(\beta_1, \beta_2) = \sum_{i=1}^{n} \hat{u}_i^2 = \sum_{i=1}^{n} (Y_i - \beta_1 - \beta_2 X_i)^2 \tag{1.10}$$

Derivando e igualando a cero (condiciones de primer orden):

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^{n} (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0 \tag{1.11}$$

$$\frac{\partial S}{\partial \beta_2} = -2 \sum_{i=1}^{n} X_i (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i) = 0 \tag{1.12}$$

Resolviendo el sistema de ecuaciones normales se obtiene:

$$\hat{\beta}_2 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2} = \frac{\sum_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n} (X_i - \bar{X})^2} \tag{1.13}$$

donde $x_i = X_i - \bar{X}$ e $y_i = Y_i - \bar{Y}$ son las desviaciones respecto a la media.

1.2.2 Propiedades del Estimador MCO bajo Heteroscedasticidad

Teorema 11.1: Insesgadez de MCO bajo Heteroscedasticidad

Enunciado: Bajo heteroscedasticidad (pero manteniendo el supuesto de exogeneidad estricta $\mathbb{E}(\mathbf{u} \mid \mathbf{X}) = \mathbf{0}$), el estimador MCO sigue siendo insesgado:

$$\mathbb{E}(\hat{\beta}_{\text{MCO}}) = \boldsymbol{\beta} \tag{1.14}$$

Demostración:

$$\begin{aligned}\hat{\beta}_{\text{MCO}} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) \\ &= \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\end{aligned}$$

Tomando esperanza condicional en $\mathbf{X}$:

$$\mathbb{E}(\hat{\beta}_{\text{MCO}} \mid \mathbf{X}) = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\underbrace{\mathbb{E}(\mathbf{u} \mid \mathbf{X})}_{=\mathbf{0}} = \boldsymbol{\beta} \qquad \blacksquare$$

La insesgadez **no depende** del supuesto de homocedasticidad, sino únicamente de la exogeneidad.

Resultado Crítico: Fórmula de Varianza Incorrecta

Bajo heteroscedasticidad, la verdadera matriz de varianza-covarianza del estimador MCO es:

$$\text{Var}(\hat{\beta}_{\text{MCO}} \mid \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Omega}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \tag{1.15}$$

Esta es la célebre **fórmula sándwich** (sandwich formula). El software estadístico estándar, en cambio, calcula **erróneamente**:

$$\widehat{\text{Var}}_{\text{conv}}(\hat{\beta}_{\text{MCO}}) = \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1} \tag{1.16}$$

La diferencia entre (**??**) y (**??**) **invalida completamente** la inferencia estadística: pruebas t, pruebas F, intervalos de confianza.

Para el caso bivariado, la varianza verdadera de $\hat{\beta}_2$ es:

$$\text{Var}(\hat{\beta}_2) = \frac{\sum_{i=1}^{n} x_i^2\sigma_i^2}{\left(\sum_{i=1}^{n} x_i^2\right)^2} \tag{1.17}$$

mientras que la fórmula convencional (incorrecta) asume:

$$\widehat{\mathrm{Var}}_{\mathrm{conv}}(\hat{\beta}_2) = \frac{\sigma^2}{\sum_{i=1}^{n} x_i^2} \tag{1.18}$$

Teorema 11.2: Ineficiencia de MCO – Gauss-Markov Modificado

Enunciado: Bajo heteroscedasticidad, MCO **ya no es BLUE**. El estimador MCG (definido en la sección siguiente) tiene menor varianza que MCO para todo $\boldsymbol{\beta}$.

Interpretación económica: MCO asigna pesos iguales $w_i = 1/n$ a todas las observaciones. Esto es subóptimo: las observaciones con varianza pequeña (σ_i^2 pequeño) contienen información más precisa sobre la línea de regresión verdadera. Ignorar esta diferencia de calidad informativa produce estimadores menos precisos.

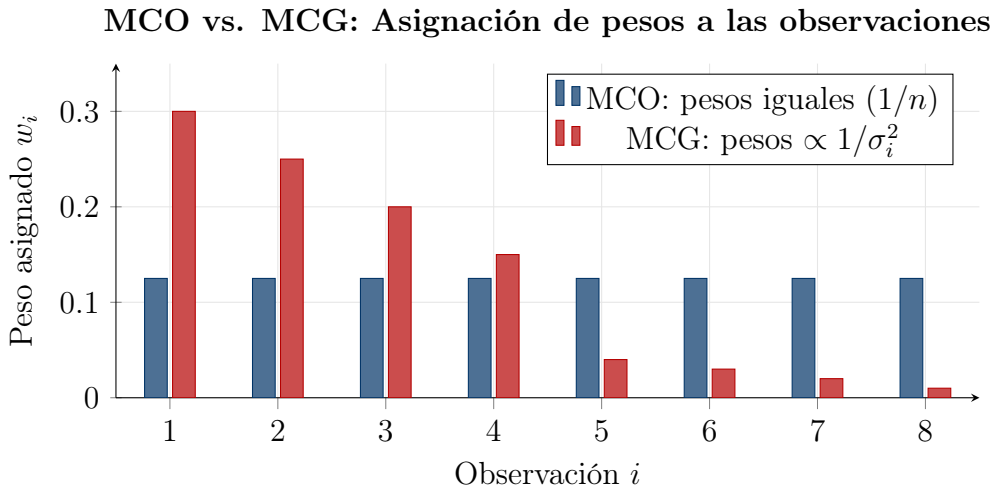

Figure 1.3: Comparación de la asignación de pesos entre MCO y MCG. MCO asigna el mismo peso $1/n$ a todas las observaciones sin importar su variabilidad. MCG asigna mayores pesos a las observaciones de menor varianza (más informativas), siendo más eficiente.

1.3 Mínimos Cuadrados Generalizados (MCG)

1.3.1 Fundamento y Lógica de la Transformación

El **Método de Mínimos Cuadrados Generalizados** (MCG) fue propuesto por Aitken (1935) y constituye la solución óptima al problema de estimación bajo una estructura de perturbaciones no esféricas. La idea central es *transformar* el modelo para que los errores transformados sí cumplan los supuestos del MLC.

Modelo Original (Heteroscedástico)

$$Y_i = \beta_1 + \beta_2 X_i + u_i, \qquad \mathbb{E}(u_i^2) = \sigma_i^2 \tag{1.19}$$

Transformación de Varianza Estabilizadora

Si las varianzas σ_i^2 son conocidas, dividir cada término de la ecuación por σ_i:

$$\underbrace{\frac{Y_i}{\sigma_i}}_{Y_i^*} = \beta_1 \underbrace{\frac{1}{\sigma_i}}_{X_{0i}^*} + \beta_2 \underbrace{\frac{X_i}{\sigma_i}}_{X_i^*} + \underbrace{\frac{u_i}{\sigma_i}}_{u_i^*} \tag{1.20}$$

Verificando la homocedasticidad del modelo transformado:

$$\mathbb{E}\left[(u_i^*)^2\right] = \mathbb{E}\left[\left(\frac{u_i}{\sigma_i}\right)^2\right] = \frac{1}{\sigma_i^2}\mathbb{E}(u_i^2) = \frac{\sigma_i^2}{\sigma_i^2} = 1 \tag{1.21}$$

Por lo tanto, $u_i^* \sim (0, 1)$: el modelo transformado (**??**) satisface el supuesto de homocedasticidad y puede estimarse eficientemente por MCO.

Nota Importante: Pérdida del Intercepto

Nótese que en el modelo transformado (**??**), la "constante" ya no es un escalar sino la variable $1/\sigma_i$, que varía entre observaciones. Por ello, la regresión transformada **no tiene intercepto convencional**, sino que β_1 se estima como el coeficiente de la variable $1/\sigma_i$. El investigador debe ser cuidadoso con los grados de libertad y la interpretación del R^2.

1.3.2 Formulación Matricial General

Matricialmente, el modelo es $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$, donde $\mathbb{E}(\mathbf{u}\mathbf{u}') = \boldsymbol{\Omega}$. Sea $\boldsymbol{\Omega}^{-1/2}$ la raíz cuadrada inversa de $\boldsymbol{\Omega}$ (existe dado que $\boldsymbol{\Omega}$ es definida positiva). Pre-multiplicar por $\boldsymbol{\Omega}^{-1/2}$:

$$\underbrace{\boldsymbol{\Omega}^{-1/2}\mathbf{y}}_{\mathbf{y}^*} = \underbrace{\boldsymbol{\Omega}^{-1/2}\mathbf{X}}_{\mathbf{X}^*}\boldsymbol{\beta} + \underbrace{\boldsymbol{\Omega}^{-1/2}\mathbf{u}}_{\mathbf{u}^*} \tag{1.22}$$

La varianza del error transformado es:

$$\mathbb{E}(\mathbf{u}^*\mathbf{u}^{*'}) = \boldsymbol{\Omega}^{-1/2}\mathbb{E}(\mathbf{u}\mathbf{u}')\boldsymbol{\Omega}^{-1/2} = \boldsymbol{\Omega}^{-1/2}\boldsymbol{\Omega}\boldsymbol{\Omega}^{-1/2} = \mathbf{I}_n \tag{1.23}$$

Aplicando MCO al modelo transformado:

$$\boxed{\hat{\beta}_{\text{MCG}} = (\mathbf{X}^{*'}\mathbf{X}^*)^{-1}\mathbf{X}^{*'}\mathbf{y}^* = (\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{y}} \tag{1.24}$$

La varianza de este estimador es:

$$\mathrm{Var}(\hat{\beta}_{\mathrm{MCG}}) = (\mathbf{X}'\mathbf{\Omega}^{-1}\mathbf{X})^{-1} \tag{1.25}$$

Teorema de Aitken (Gauss-Markov Generalizado)

Enunciado: Bajo el modelo $\mathbf{y} = \mathbf{X}\boldsymbol{\beta}+\mathbf{u}$ con $\mathbb{E}(\mathbf{u}) = \mathbf{0}$ y $\mathbb{E}(\mathbf{u}\mathbf{u}') = \mathbf{\Omega}$ (conocida), el estimador MCG definido en (**??**) es el **Mejor Estimador Lineal Insesgado (BLUE)**.

Demostración (Sketch): Sea $\tilde{\boldsymbol{\beta}} = \mathbf{C}\mathbf{y}$ cualquier estimador lineal insesgado alternativo. La condición de insesgadez requiere $\mathbf{C}\mathbf{X} = \mathbf{I}$. Sea $\mathbf{D} = \mathbf{C} - (\mathbf{X}'\mathbf{\Omega}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{\Omega}^{-1}$. Entonces:

$$\begin{aligned}\mathrm{Var}(\tilde{\boldsymbol{\beta}}) - \mathrm{Var}(\hat{\beta}_{\mathrm{MCG}}) &= \mathbf{C}\mathbf{\Omega}\mathbf{C}' - (\mathbf{X}'\mathbf{\Omega}^{-1}\mathbf{X})^{-1} \\ &= \mathbf{D}\mathbf{\Omega}\mathbf{D}' \succeq \mathbf{0}\end{aligned}$$

puesto que $\mathbf{D}\mathbf{\Omega}\mathbf{D}'$ es semidefinida positiva. ■

1.3.3 Mínimos Cuadrados Ponderados (MCP)

Cuando $\mathbf{\Omega}$ es diagonal (heteroscedasticidad pura sin autocorrelación), MCG se reduce a **Mínimos Cuadrados Ponderados**. El estimador minimiza la suma ponderada de cuadrados residuales:

$$S^* = \sum_{i=1}^{n} w_i(Y_i - \beta_1 - \beta_2 X_i)^2, \qquad w_i = \frac{1}{\sigma_i^2} \tag{1.26}$$

Las condiciones de primer orden conducen a:

$$\sum_{i=1}^{n} w_i(Y_i - \hat{\beta}_1^* - \hat{\beta}_2^* X_i) = 0 \tag{1.27}$$

$$\sum_{i=1}^{n} w_i X_i(Y_i - \hat{\beta}_1^* - \hat{\beta}_2^* X_i) = 0 \tag{1.28}$$

De donde el estimador MCP de la pendiente es:

$$\hat{\beta}_2^* = \frac{\sum w_i x_i y_i}{\sum w_i x_i^2} \tag{1.29}$$

con $x_i = X_i - \bar{X}_w$ y $\bar{X}_w = \frac{\sum w_i X_i}{\sum w_i}$ siendo la media ponderada de X.

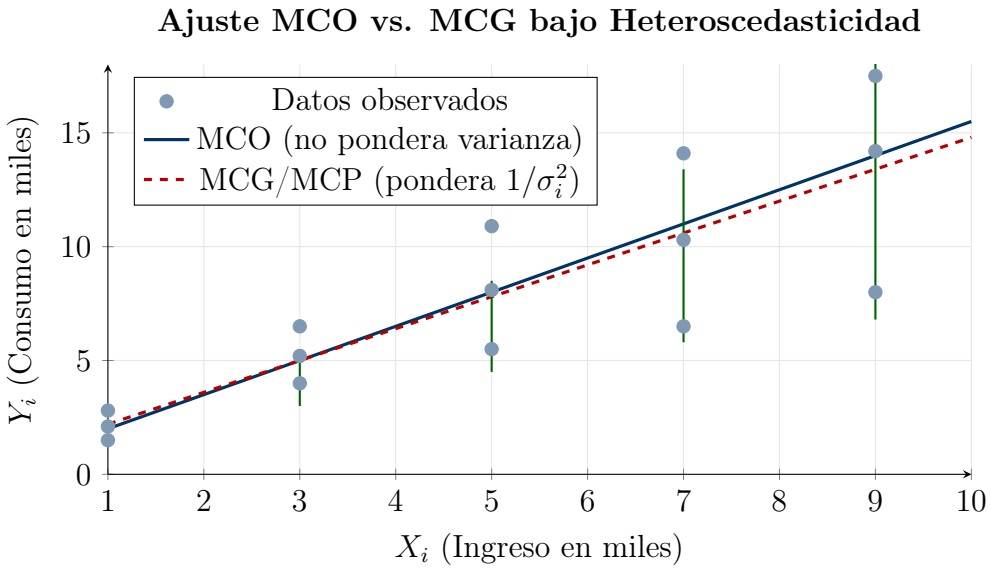

Figure 1.4: MCO y MCG producen líneas similares, pero MCG pondera cada observación inversamente proporcional a su varianza σ_i^2. Las barras verdes representan la dispersión condicional de cada grupo.

1.3.4 El Problema Práctico: Varianzas Desconocidas

En la práctica, σ_i^2 no se conoce. Las soluciones son:

Opción 1: MCG Factible (FGLS): Estimar σ_i^2 a partir de los residuales de una primera regresión MCO, ajustando un modelo para la varianza (ej. Park) y usar las varianzas estimadas como pesos.

Opción 2: Errores Estándar Robustos (White): Mantener el estimador MCO pero corregir la matriz de varianza-covarianza usando el estimador de White.

Opción 3: Transformaciones ad hoc: Si se sospecha que $\sigma_i^2 \propto X_i^2$, dividir por X_i; si $\sigma_i^2 \propto X_i$, dividir por $\sqrt{X_i}$.

1.4 Consecuencias Formales del Uso de MCO

1.4.1 Resumen de Propiedades

Table 1.1: Propiedades del estimador MCO bajo homocedasticidad vs. heteroscedasticidad

Propiedad	**Condición**	**Bajo Homo.**	**Bajo Hetero.**
Lineal	Siempre	✓	✓
Insesgado	Exogeneidad	✓	✓
Consistente	Exog. + regulares	✓	✓
Eficiente (BLUE)	Gauss-Markov	✓	**NO**
Var. correcta	Homocedasticidad	✓	**NO**
Pruebas t/F válidas	Var. correcta	✓	**NO**
Intervalos conf. válidos	Var. correcta	✓	**NO**

1.4.2 El Sesgo en el Estimador de la Varianza

El estimador habitual de σ^2 es:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{u}_i^2}{n-k} = \frac{\mathbf{u}'\mathbf{M}\mathbf{u}}{n-k} \tag{1.30}$$

donde $\mathbf{M} = \mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ es la matriz de proyección ortogonal.

Bajo heteroscedasticidad:

$$\mathbb{E}(\hat{\sigma}^2) = \frac{1}{n-k}\mathbb{E}(\mathbf{u}'\mathbf{M}\mathbf{u}) = \frac{1}{n-k}\mathrm{tr}(\mathbf{M}\boldsymbol{\Omega}) \tag{1.31}$$

Mientras que si hubiera homocedasticidad: $\frac{1}{n-k}\mathrm{tr}(\mathbf{M}\sigma^2\mathbf{I}) = \sigma^2$. Con heteroscedasticidad, $\mathrm{tr}(\mathbf{M}\boldsymbol{\Omega}) \neq (n-k)\sigma^2$, por lo que $\hat{\sigma}^2$ es un estimador **sesgado**.

1.4.3 Consecuencias en las Pruebas de Hipótesis

Invalidez de las Pruebas t y F

Estadístico t convencional:

$$t_j = \frac{\hat{\beta}_j - \beta_j^0}{\widehat{\mathrm{se}}(\hat{\beta}_j)} \tag{1.32}$$

donde $\widehat{\mathrm{se}}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2[(\mathbf{X}'\mathbf{X})^{-1}]_{jj}}$.
Bajo heteroscedasticidad, el numerador tiene distribución normal correcta (insesgadez), pero el denominador es incorrecto. Por tanto, t_j **no sigue una distribución t de Student** con $n-k$ grados de libertad. Las conclusiones sobre significancia estadística son inválidas.

Consecuencias prácticas:

- Si $\widehat{\text{se}}$ subestima el verdadero error estándar $\Rightarrow$ el estadístico t está inflado $\Rightarrow$ se **rechaza** H_0 **con demasiada frecuencia** (tamaño real $>$ nivel nominal α).
- Si $\widehat{\text{se}}$ sobreestima el verdadero error estándar $\Rightarrow$ el estadístico t está desinflado $\Rightarrow$ se **acepta** H_0 **erróneamente** (pérdida de potencia).

1.5 Detección de la Heteroscedasticidad

1.5.1 Métodos Gráficos

Procedimiento Gráfico

Paso 1: Estimar el modelo por MCO y obtener los residuales $\hat{u}_i$.

Paso 2: Graficar $\hat{u}_i$ (o $\hat{u}_i^2$) vs. $\hat{Y}_i$ (valores ajustados) o vs. las variables explicativas X_j.

Paso 3: Si el gráfico muestra un patrón sistemático (embudo, forma cuadrática, etc.), esto sugiere heteroscedasticidad. Si los puntos se dispersan aleatoriamente, no hay evidencia.

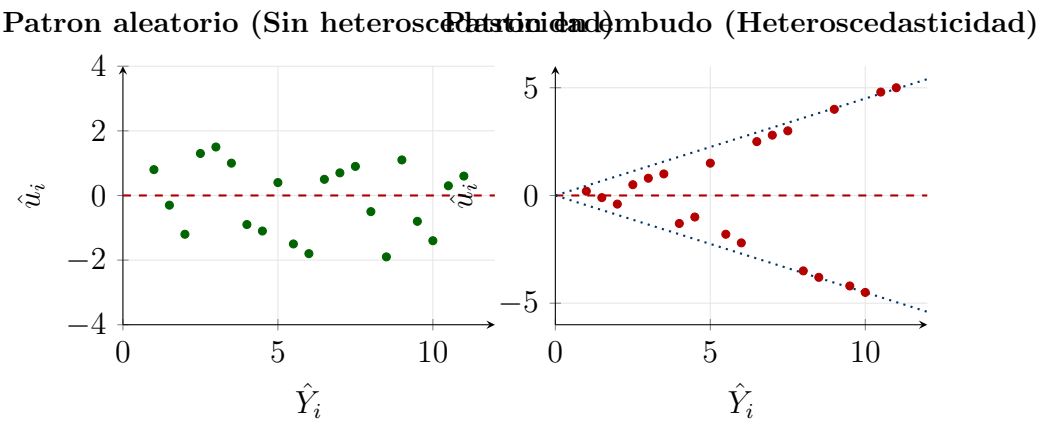

Figure 1.5: Gráficos de residuales vs. valores ajustados. El panel izquierdo muestra dispersión aleatoria (homocedasticidad). El panel derecho muestra el patrón típico en "embudo" de la heteroscedasticidad, donde la dispersión aumenta con $\hat{Y}_i$.

1.5.2 Prueba de Park

Park (1966) propuso modelar la varianza como una función potencial de una variable explicativa:

$$\sigma_i^2 = \sigma^2 X_i^{\delta} e^{v_i} \tag{1.33}$$

Tomando logaritmos:

$$\ln(\sigma_i^2) = \ln(\sigma^2) + \delta \ln(X_i) + v_i \tag{1.34}$$

Como σ_i^2 no es observable, se aproxima con $\hat{u}_i^2$ de la regresión MCO:

$$\ln(\hat{u}_i^2) = \alpha_0 + \delta \ln(X_i) + v_i \tag{1.35}$$

Decisión: Si δ es estadísticamente significativo (prueba t), existe evidencia de heteroscedasticidad. La limitación es que v_i puede no ser bien comportado.

1.5.3 Prueba de Glejser

Glejser (1969) propone regresar el valor absoluto de los residuales sobre las variables explicativas bajo diferentes formas funcionales:

$$|\hat{u}_i| = \alpha_0 + \alpha_1 X_i + v_i \tag{1.36}$$

$$|\hat{u}_i| = \alpha_0 + \alpha_1 \sqrt{X_i} + v_i \tag{1.37}$$

$$|\hat{u}_i| = \alpha_0 + \alpha_1 / X_i + v_i \tag{1.38}$$

$$|\hat{u}_i| = \alpha_0 + \alpha_1 / \sqrt{X_i} + v_i \tag{1.39}$$

Decisión: Si $\alpha_1 \neq 0$ significativamente en alguna especificación, hay heteroscedasticidad.

1.5.4 Prueba de Correlación de Rangos de Spearman

Procedimiento: Correlación de Spearman

Paso 1: Estimar el modelo y obtener $|\hat{u}_i|$.

Paso 2: Ordenar $|\hat{u}_i|$ y X_i de menor a mayor, asignando rangos d_{1i} y d_{2i}.

Paso 3: Calcular las diferencias $d_i = d_{1i} - d_{2i}$.

Paso 4: Computar el coeficiente de correlación de rangos:

$$r_s = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n(n^2 - 1)} \tag{1.40}$$

Paso 5: Bajo H_0: no hay heteroscedasticidad, el estadístico:

$$t = \frac{r_s \sqrt{n-2}}{\sqrt{1 - r_s^2}} \sim t_{n-2} \tag{1.41}$$

Si $|t| > t_{\alpha/2,n-2}$, se rechaza H_0.

1.5.5 Prueba de Goldfeld-Quandt

Diseñada para detectar si la varianza aumenta (o disminuye) con una variable ordenadora X:

Procedimiento: Goldfeld-Quandt

Paso 1: Ordenar las n observaciones según la variable explicativa sospechosa X_i.

Paso 2: Eliminar las c observaciones centrales (generalmente $c \approx n/5$).

Paso 3: Dividir las $n-c$ observaciones restantes en dos grupos: $n_1 = n_2 = (n-c)/2$.

Paso 4: Regresar el modelo por MCO en cada grupo, obteniendo RSS_1 y RSS_2 (con RSS_2 del grupo de mayor X).

Paso 5: Calcular el estadístico:

$$F_{GQ} = \frac{\text{RSS}_2/(n_2-k)}{\text{RSS}_1/(n_1-k)} \sim F_{(n_2-k),(n_1-k)} \tag{1.42}$$

Paso 6: Si $F_{GQ} > F_{\alpha,(n_2-k),(n_1-k)}$, rechazar H_0 (homocedasticidad).

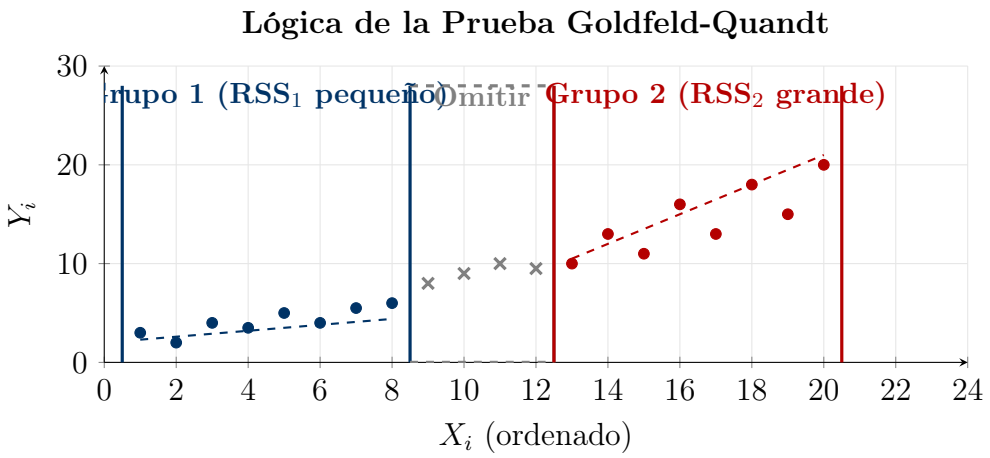

Figure 1.6: Ilustración de la prueba Goldfeld-Quandt. Las observaciones se ordenan por X, se elimina el grupo central y se compara la varianza residual entre los grupos extremos. Si $\text{RSS}_2 \gg \text{RSS}_1$, la varianza crece con X.

1.5.6 Prueba de Breusch-Pagan-Godfrey (BPG)

Breusch y Pagan (1979), y Godfrey (1978) de forma independiente, propusieron una prueba de multiplicadores de Lagrange (LM).

Supuesto: $\sigma_i^2 = f(\alpha_0 + \alpha_1 Z_{1i} + \cdots + \alpha_p Z_{pi})$, donde Z_{ji} son variables que supuestamente causan la heteroscedasticidad.

$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_p = 0$ (homocedasticidad).

Procedimiento: Breusch-Pagan-Godfrey

Paso 1: Estimar el modelo por MCO. Obtener $\hat{u}_i$ y $\hat{\sigma}^2 = \sum \hat{u}_i^2/n$.

Paso 2: Construir la variable:

$$p_i = \frac{\hat{u}_i^2}{\hat{\sigma}^2} \tag{1.43}$$

Paso 3: Regresar p_i sobre las variables Z_{ji}:

$$p_i = \alpha_0 + \alpha_1 Z_{1i} + \cdots + \alpha_p Z_{pi} + \varepsilon_i \tag{1.44}$$

Paso 4: Calcular la suma de cuadrados explicada (SCE) de esta regresión auxiliar.

Paso 5: El estadístico LM:

$$\chi^2_{BPG} = \frac{\text{SCE}}{2} \xrightarrow{d} \chi^2_{(p)} \tag{1.45}$$

1.5.7 Prueba de White

White (1980) propuso una prueba más general que no requiere especificar la forma de la heteroscedasticidad.

Procedimiento: Prueba de White

Paso 1: Estimar el modelo original por MCO. Obtener $\hat{u}_i$.

Paso 2: Regresar $\hat{u}_i^2$ sobre todos los regresores originales, sus cuadrados y productos cruzados. Para el modelo $Y = \beta_1 + \beta_2 X_2 + \beta_3 X_3 + u$:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 X_{2i} + \alpha_2 X_{3i} + \alpha_3 X_{2i}^2 + \alpha_4 X_{3i}^2 + \alpha_5 X_{2i} X_{3i} + v_i \tag{1.46}$$

Paso 3: El estadístico de White:

$$W = n \cdot R^2_{\text{aux}} \xrightarrow{d} \chi^2_{(p)} \tag{1.47}$$

donde p es el número de regresores en (**??**) (excluida la constante).

Paso 4: Rechazar H_0 si $W > \chi^2_{\alpha,p}$.

Versión simplificada (Davidson-MacKinnon): Una alternativa es regresar $\hat{u}_i^2$ sobre $\hat{Y}_i$ y $\hat{Y}_i^2$:

$$\hat{u}_i^2 = \delta_0 + \delta_1 \hat{Y}_i + \delta_2 \hat{Y}_i^2 + v_i \tag{1.48}$$

y usar $n \cdot R^2$ de esta regresión como estadístico $\chi^2_{(2)}$.

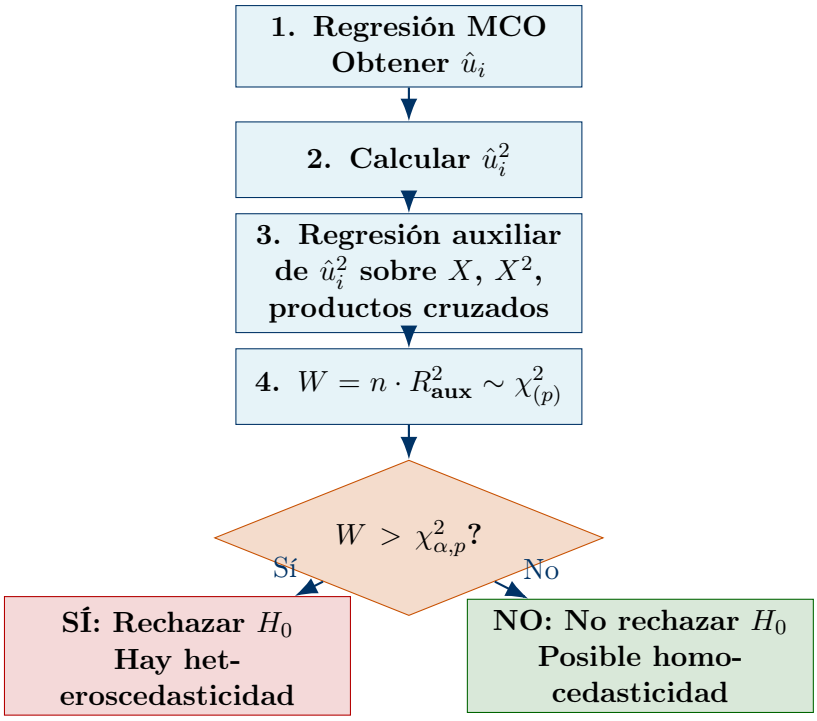

Figure 1.7: Diagrama de flujo de la Prueba de White para heteroscedasticidad.

1.6 Medidas Remediales

1.6.1 Cuando se Conoce σ_i^2: Mínimos Cuadrados Ponderados Exactos

Si se conoce la forma exacta de la heteroscedasticidad, se aplica MCP con $w_i = 1/\sigma_i^2$. Algunos casos especiales:

Table 1.2: Transformaciones MCP según la forma de σ_i^2

Supuesto sobre σ_i^2	Transformación	Modelo transformado
$\sigma_i^2 = \sigma^2 X_i^2$	Dividir por X_i	$Y_i/X_i = \beta_1/X_i + \beta_2 + u_i/X_i$
$\sigma_i^2 = \sigma^2 X_i$	Dividir por $\sqrt{X_i}$	$Y_i/\sqrt{X_i} = \beta_1/\sqrt{X_i} + \beta_2\sqrt{X_i} + u_i/\sqrt{X_i}$
$\sigma_i^2 = \sigma^2 E(Y_i)^2$	Dividir por $\hat{Y}_i$	$Y_i/\hat{Y}_i = \beta_1/\hat{Y}_i + \beta_2 X_i/\hat{Y}_i + u_i/\hat{Y}_i$
$\sigma_i^2 = \sigma^2/n_i$ (grupos)	Multiplicar por $\sqrt{n_i}$	Usar promedios de grupo

1.6.2 Errores Estándar Robustos de White (HC)

Cuando la forma de $\mathbf{\Omega}$ es desconocida pero la muestra es grande, White (1980) propuso el estimador consistente de la varianza-covarianza:

$$\widehat{\mathrm{Var}}_{\mathrm{White}}(\hat{\beta}_{\mathrm{MCO}}) = (\mathbf{X}'\mathbf{X})^{-1}\left(\sum_{i=1}^{n}\hat{u}_i^2\mathbf{x}_i\mathbf{x}_i'\right)(\mathbf{X}'\mathbf{X})^{-1} \tag{1.49}$$

donde $\mathbf{x}_i$ es el vector de regresores de la observación i. Este estimador es consistente bajo heterocedasticidad de forma desconocida para muestras grandes ($n \to \infty$).

Variantes del Estimador Robusto (HC0 a HC3)

- **HC0 (White):** $\hat{u}_i^2$ sin corrección. Puede tener sesgo en muestras pequeñas.
- **HC1:** $\hat{u}_i^2 \cdot n/(n-k)$. Corrección de grados de libertad.
- **HC2:** $\hat{u}_i^2/(1-h_{ii})$ donde h_{ii} son los leverage. Corrige por influencia.
- **HC3:** $\hat{u}_i^2/(1-h_{ii})^2$. Mejor desempeño en muestras pequeñas (MacKinnon-White).

1.6.3 Transformación Logarítmica

Si $Y > 0$ y $X > 0$, la transformación log-log:

$$\ln Y_i = \gamma_1 + \gamma_2 \ln X_i + v_i \tag{1.50}$$

frecuentemente reduce la heteroscedasticidad, ya que el logaritmo comprime la escala de las variables, especialmente en el caso de distribuciones asimétricas.

Justificación estadística: Si $\sigma_i^2 \propto [E(Y_i)]^2$ (varianza proporcional al cuadrado de la media), entonces:

$$\mathrm{CV}(Y_i) = \frac{\sigma_i}{E(Y_i)} = \text{constante} \tag{1.51}$$

En este caso, la transformación logarítmica produce varianza aproximadamente constante, ya que $\mathrm{Var}(\ln Y_i) \approx \mathrm{Var}(Y_i)/[E(Y_i)]^2 = \mathrm{CV}^2$.

1.7 Ejemplos Finales con Datos Reales

1.7.1 Ejemplo 11.9: Mortalidad Infantil Revisitada

Se considera el modelo de regresión múltiple para una muestra de 64 países:

$$CM_i = \beta_1 + \beta_2\mathrm{PGNP}_i + \beta_3\mathrm{FLR}_i + u_i \tag{1.52}$$

donde CM = mortalidad infantil (por mil nacidos vivos), PGNP = PNB per cápita, FLR = tasa de alfabetización femenina.

Resultados MCO:

$$\widehat{CM}_i = 263.64 - 0.0056\,\text{PGNP}_i - 2.2316\,\text{FLR}_i \tag{1.53}$$

Aplicación de Pruebas de Heteroscedasticidad

Prueba de Glejser: Regresión de $|\hat{u}_i|$ sobre $\widehat{CM}_i$:

$$|\hat{u}_i| = 14.28 + 0.22\,\widehat{CM}_i$$
$$t_{\text{pendiente}} = 1.26 \quad (p\text{-valor} > 0.10)$$

Conclusión: El estadístico $t = 1.26$ no es significativo al 10%. No hay evidencia de heteroscedasticidad en este modelo. MCO estándar es adecuado.
Interpretación económica: La heterogeneidad entre países de distintos niveles de desarrollo podría generar heteroscedasticidad. Sin embargo, el modelo ya captura la variabilidad mediante las variables de ingreso y alfabetización. Las perturbaciones restantes son homogéneas.

Residuales Absolutos vs. Valores Ajustados – Mortalidad Infantil (64 países)

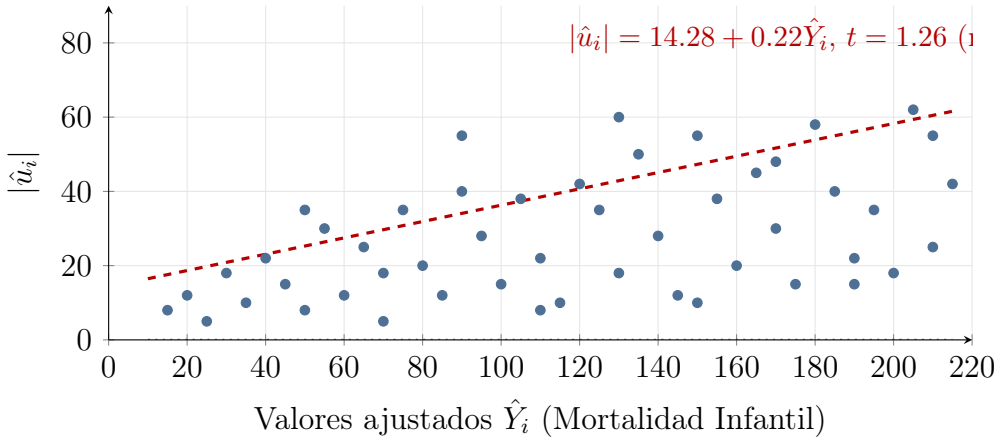

Figure 1.8: Gráfico de residuales absolutos vs. valores ajustados para el modelo de mortalidad infantil. La pendiente de la línea de tendencia no es estadísticamente significativa ($t = 1.26$), indicando ausencia de heteroscedasticidad.

1.7.2 Ejemplo 11.10: Gasto en I+D – Ventas y Utilidades

Se analiza el gasto en Investigación y Desarrollo (I+D) para 18 grupos industriales:

$$\text{I+D}_i = \beta_1 + \beta_2\text{Ventas}_i + \beta_3\text{Utilidades}_i + u_i \tag{1.54}$$

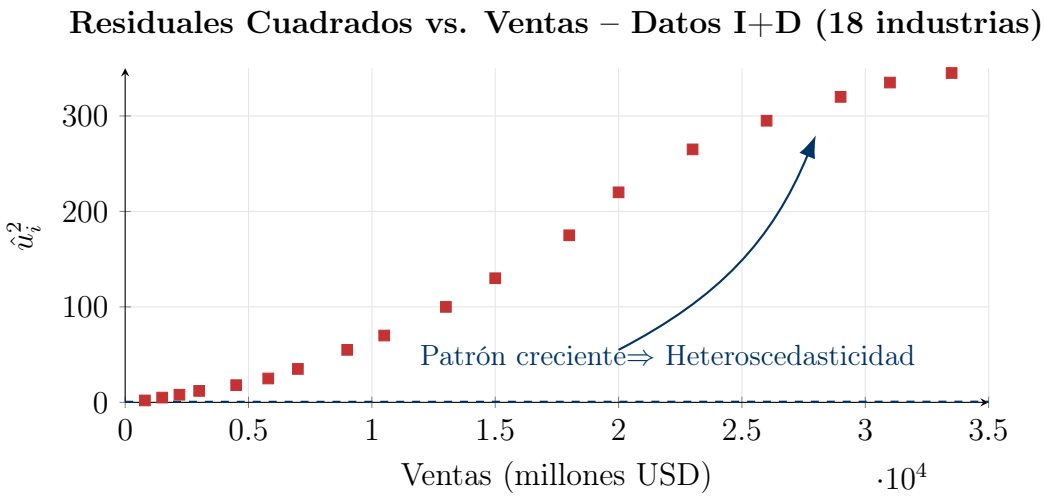

Figure 1.9: Los residuales cuadrados crecen sistemáticamente con el nivel de ventas, confirmando la presencia de heteroscedasticidad. Las grandes industrias tienen mayor variabilidad en el gasto de I+D.

Resultados: Prueba de White y Corrección MCP

Prueba de White:

$$W = n \cdot R^2_{\text{aux}} = 18 \times 0.2896 = 5.2124$$
$$\chi^2_{(5),0.10} = 9.24 \quad \Rightarrow \quad W = 5.21 < 9.24 \text{ al } 5\%$$
$$p\text{-valor} = 0.074 \quad \Rightarrow \quad \text{Significativo al } 10\%$$

Interpretación: Al nivel del 10%, hay evidencia de heteroscedasticidad. Se aplica la transformación $\sqrt{\text{Ventas}_i}$ como ponderación en MCP.

Comparación MCO vs. MCP:

Parámetro	Error Std. MCO	Error Std. MCP
β_2 (Ventas)	0.0083	0.0071
β_3 (Utilidades)	0.0386	0.0310

Mejora en precisión del coeficiente de Ventas: $\approx 14\%$

Interpretación económica: Los sectores industriales más grandes (mayor volumen de ventas) muestran mayor variabilidad en sus decisiones de inversión en I+D, lo cual es esperable dado que tienen mayor discrecionalidad y acceso a capital.

1.8 Ejercicios Resueltos

1.8.1 Ejercicio 11.1 – Verdadero, Falso o Incierto

Ejercicio 11.1 (a): "MCO es sesgado e ineficiente bajo heteroscedasticidad"

Respuesta: FALSO (parcialmente).

a) **¿Es sesgado MCO?** No. La insesgadez requiere únicamente $\mathbb{E}(\mathbf{u} \mid \mathbf{X}) = \mathbf{0}$, que se mantiene bajo heteroscedasticidad. La demostración fue dada en el Teorema 11.1.

b) **¿Es ineficiente MCO?** Sí. MCO ya no minimiza la varianza entre todos los estimadores lineales insesgados. El estimador de varianza mínima es MCG (Teorema de Aitken). Por lo tanto, la parte de "ineficiente" es **verdadera**.

c) **Consecuencia crítica:** La ineficiencia se manifiesta en errores estándar incorrectos, que invalidan las pruebas de hipótesis.

Corrección de la afirmación: "En presencia de heteroscedasticidad, los estimadores de MCO son *insesgados pero ineficientes*."

Ejercicio 11.1 (b): "Las pruebas t y F son inválidas bajo heteroscedasticidad"

Respuesta: VERDADERO.

El estadístico t se construye como:

$$t = \frac{\hat{\beta}_j - \beta_j^0}{\text{se}(\hat{\beta}_j)}$$

Para que $t \sim t_{n-k}$, se requiere que $\text{se}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2[(\mathbf{X}'\mathbf{X})^{-1}]_{jj}}$ sea el error estándar correcto. Bajo heteroscedasticidad, $\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}$ no es la varianza correcta (la correcta es (**??**)), por lo tanto el denominador está mal estimado y la ratio no sigue la distribución t teórica.

Solución: Usar errores estándar robustos de White para corregir las pruebas de hipótesis.

Ejercicio 11.1 (c): "MCO siempre sobreestima los errores estándar"

Respuesta: FALSO.

El signo del sesgo depende de la relación entre $\mathbf{\Omega}$ y $\mathbf{X}$. En la ecuación:

$$\text{Var}_{\text{conv}} - \text{Var}_{\text{verdadera}} = \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{\Omega}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

esta diferencia puede ser positiva (sobreestimación) o negativa (subestimación), dependiendo de la estructura de correlación entre las varianzas σ_i^2 y los valores X_i.

Caso ilustrativo:

- Si la varianza alta está asociada con valores grandes de X (patrón típico), los errores estándar convencionales tienden a **subestimar** la verdadera incertidumbre.
- Si la varianza alta está asociada con valores pequeños de X, los errores pueden sobreestimarse.

1.8.2 Ejercicio 11.21 – Prueba de Goldfeld-Quandt

Ejercicio 11.21: Datos dados $\text{RSS}_1 = 55$, $\text{RSS}_2 = 140$

Datos: Suponga $n = 30$, se eliminan $c = 6$ observaciones centrales, $k = 2$ parámetros.

$$n_1 = n_2 = (30 - 6)/2 = 12$$
$$\text{GL}_{\text{num}} = \text{GL}_{\text{den}} = 12 - 2 = 10$$

Estadístico:

$$F_{GQ} = \frac{\text{RSS}_2/(n_2 - k)}{\text{RSS}_1/(n_1 - k)} = \frac{140/10}{55/10} = \frac{14.0}{5.5} = 2.545$$

Valor crítico: $F_{0.05,10,10} = 2.98$ (tabla F al 5%).
Conclusión: $F_{GQ} = 2.545 < 2.98 = F_{\text{crítico}}$. **No se rechaza** H_0 al 5%. Sin embargo, al 10%, $F_{0.10,10,10} \approx 2.32 < 2.545$, por lo que **sí se rechazaría** al 10%.
Interpretación económica: Existe evidencia *marginal* de heteroscedasticidad. La varianza del grupo con valores altos de X es 2.5 veces mayor que la del grupo con valores bajos. Esto sugiere que la variabilidad del fenómeno estudiado aumenta con el tamaño de las unidades.

1.8.3 Ejercicio 11.22 – Valores Atípicos y Heteroscedasticidad

Ejercicio 11.22: Chile como Valor Atípico

Contexto: Datos de cambios en precios de acciones y precios al consumidor para 20 países. Chile exhibe tasas de inflación extremadamente altas en la muestra (outlier).
Con Chile incluido:

- La alta variabilidad en la observación de Chile eleva artificialmente la varianza residual.
- Las pruebas de heteroscedasticidad pueden rechazar H_0 debido principal-

mente al outlier, no a un patrón sistemático.

- El estimador MCO de la pendiente se "jala" hacia la observación extrema.

Sin Chile:

- La varianza puede tornarse homogénea entre los países restantes.
- La prueba de heteroscedasticidad puede no rechazar H_0.

Lección metodológica: Siempre se debe identificar si la heteroscedasticidad detectada refleja un patrón genuino o es el artefacto de una sola observación influyente. Las estadísticas de Cook, los gráficos de leverage, y los residuales estandarizados son herramientas complementarias.

1.8.4 Ejercicio 11.10 – Varianza Bajo Heteroscedasticidad sin Intercepto

Ejercicio 11.10: Modelo sin intercepto con $\mathrm{Var}(u_i) = \sigma^2 X_i^2$

Modelo: $Y_i = \beta X_i + u_i$, $\mathrm{Var}(u_i) = \sigma^2 X_i^2$.

Estimador MCO:

$$\hat{\beta} = \frac{\sum X_i Y_i}{\sum X_i^2}$$

Varianza verdadera de MCO:

$$\begin{aligned}\mathrm{Var}(\hat{\beta}) &= \mathrm{Var}\left(\frac{\sum X_i Y_i}{\sum X_i^2}\right) = \frac{\sum X_i^2 \mathrm{Var}(u_i)}{\left(\sum X_i^2\right)^2} \\ &= \frac{\sum X_i^2 \cdot \sigma^2 X_i^2}{\left(\sum X_i^2\right)^2} = \frac{\sigma^2 \sum X_i^4}{\left(\sum X_i^2\right)^2}\end{aligned}$$

Varianza convencional (incorrecta):

$$\widehat{\mathrm{Var}}_{\mathrm{conv}}(\hat{\beta}) = \frac{\sigma^2}{\sum X_i^2}$$

Transformación MCP: Dividiendo por X_i: $Y_i/X_i = \beta + u_i/X_i$, el nuevo error $u_i^* = u_i/X_i$ satisface $\mathrm{Var}(u_i^*) = \sigma^2$ (homocedasticidad). El estimador MCP de β:

$$\hat{\beta}^* = \frac{\sum (Y_i/X_i)}{n} = \bar{Y/X}$$

con varianza $\mathrm{Var}(\hat{\beta}^*) = \sigma^2/n$, que es menor que la de MCO cuando $\sum X_i^4/(\sum X_i^2)^2 > 1/n$ (desigualdad de Cauchy-Schwarz garantiza esto).

Anexo A: Derivaciones Completas de Fórmulas

A.1 Derivación del Estimador MCO desde las Condiciones de Primer Orden

Objetivo: Minimizar $S = \sum_{i=1}^{n}(Y_i - \beta_1 - \beta_2 X_i)^2$.

Paso 1: Condiciones necesarias de primer orden.

$$\frac{\partial S}{\partial \beta_1} = -2\sum_{i=1}^{n}(Y_i - \beta_1 - \beta_2 X_i) = 0 \implies \sum Y_i = n\beta_1 + \beta_2 \sum X_i$$
$$\frac{\partial S}{\partial \beta_2} = -2\sum_{i=1}^{n} X_i(Y_i - \beta_1 - \beta_2 X_i) = 0 \implies \sum X_i Y_i = \beta_1 \sum X_i + \beta_2 \sum X_i^2$$

Paso 2: Resolver el sistema (ecuaciones normales).

De la primera ecuación: $\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}$.

Sustituyendo en la segunda:

$$\begin{aligned}
\sum X_i Y_i &= (\bar{Y} - \hat{\beta}_2 \bar{X}) \sum X_i + \hat{\beta}_2 \sum X_i^2 \\
\sum X_i Y_i - \bar{Y} \sum X_i &= \hat{\beta}_2 \left(\sum X_i^2 - \bar{X} \sum X_i \right) \\
\sum X_i Y_i - n\bar{X}\bar{Y} &= \hat{\beta}_2 \left(\sum X_i^2 - n\bar{X}^2 \right) \\
\sum x_i y_i &= \hat{\beta}_2 \sum x_i^2
\end{aligned}$$

Resultado:

$$\hat{\beta}_2 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2} = \frac{S_{XY}}{S_{XX}} \tag{1.55}$$
$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X} \tag{1.56}$$

Verificación de mínimo: La Hessiana de S es $H = 2\mathbf{X}'\mathbf{X}$, que es definida positiva (bajo el supuesto de rango completo de $\mathbf{X}$), confirmando que es un mínimo global.

A.2 Derivación de la Varianza Verdadera de MCO bajo Heteroscedasticidad

Paso 1: Expresar $\hat{\beta}_2$ como función de u_i.

Sabemos que $Y_i = \beta_1 + \beta_2 X_i + u_i$, por lo que $y_i = Y_i - \bar{Y} = \beta_2 x_i + u_i - \bar{u}$.

$$\begin{aligned}\hat{\beta}_2 &= \frac{\sum x_i y_i}{\sum x_i^2} = \frac{\sum x_i(\beta_2 x_i + u_i - \bar{u})}{\sum x_i^2} \\ &= \beta_2 + \frac{\sum x_i u_i}{\sum x_i^2} \quad \left(\text{pues } \sum x_i = 0\right)\end{aligned}$$

Paso 2: Calcular la varianza.

$$\hat{\beta}_2 - \beta_2 = \frac{\sum x_i u_i}{\sum x_i^2} = \sum k_i u_i, \quad k_i = \frac{x_i}{\sum x_i^2}$$

$$\begin{aligned}\mathrm{Var}(\hat{\beta}_2) &= \mathbb{E}\left[\left(\sum k_i u_i\right)^2\right] = \mathbb{E}\left[\sum_i \sum_j k_i k_j u_i u_j\right] \\ &= \sum_i \sum_j k_i k_j \mathbb{E}(u_i u_j)\end{aligned}$$

Bajo heteroscedasticidad (pero sin autocorrelación): $\mathbb{E}(u_i u_j) = \sigma_i^2$ si $i = j$, $= 0$ si $i \neq j$.

$$\mathrm{Var}(\hat{\beta}_2) = \sum_i k_i^2 \sigma_i^2 = \sum_i \frac{x_i^2}{(\sum x_i^2)^2}\sigma_i^2 = \frac{\sum x_i^2 \sigma_i^2}{(\sum x_i^2)^2}$$

Resultado (confirma (??)):

$$\mathrm{Var}(\hat{\beta}_2) = \frac{\sum_{i=1}^n x_i^2 \sigma_i^2}{\left(\sum_{i=1}^n x_i^2\right)^2} \tag{A.1}$$

A.3 Derivación Completa del Estimador MCG

Paso 1: Sea $\mathbf{\Omega} = \text{diag}(\sigma_1^2, \ldots, \sigma_n^2)$. Definir $\mathbf{P} = \mathbf{\Omega}^{-1/2} = \text{diag}(1/\sigma_1, \ldots, 1/\sigma_n)$.

Paso 2: Pre-multiplicar el modelo por $\mathbf{P}$:

$$\mathbf{Py} = \mathbf{PX}\boldsymbol{\beta} + \mathbf{Pu}$$

Paso 3: Verificar la varianza del error transformado:

$$\mathbb{E}(\mathbf{Puu'P'}) = \mathbf{P\Omega P'} = \mathbf{\Omega}^{-1/2}\mathbf{\Omega\Omega}^{-1/2} = \mathbf{I}$$

Paso 4: Aplicar MCO al modelo transformado:

$$\begin{aligned}\hat{\beta}_{GLS} &= [(\mathbf{PX})'(\mathbf{PX})]^{-1}(\mathbf{PX})'(\mathbf{Py}) \\ &= [\mathbf{X'P'PX}]^{-1}\mathbf{X'P'Py} \\ &= [\mathbf{X'\Omega}^{-1}\mathbf{X}]^{-1}\mathbf{X'\Omega}^{-1}\mathbf{y}\end{aligned}$$

Paso 5: Varianza:

$$\begin{aligned}\text{Var}(\hat{\beta}_{GLS}) &= [\mathbf{X'\Omega}^{-1}\mathbf{X}]^{-1}\mathbf{X'\Omega}^{-1}\underbrace{\mathbb{E}(\mathbf{uu'})}_{\mathbf{\Omega}}\mathbf{\Omega}^{-1}\mathbf{X}[\mathbf{X'\Omega}^{-1}\mathbf{X}]^{-1} \\ &= [\mathbf{X'\Omega}^{-1}\mathbf{X}]^{-1}\end{aligned}$$

A.4 Derivación del Estadístico de White

Contexto: Bajo H_0 (homocedasticidad), el estadístico nR^2 de la regresión auxiliar de $\hat{u}_i^2$ sobre las variables en (**??**) converge en distribución a $\chi^2_{(p)}$.

Intuición: Si $\mathbb{E}(u_i^2) = \sigma^2$ (constante), entonces $u_i^2 - \sigma^2$ es una variable de media cero no correlacionada con ninguna función de $\mathbf{X}$. En la regresión auxiliar, todos los coeficientes deberían ser cero, y el R^2 debería ser "pequeño". La cantidad $nR^2 = n \cdot \frac{\text{SCE}}{\text{SCT}}$ mide cuánta variación en $\hat{u}_i^2$ es explicada por las funciones de $\mathbf{X}$. Bajo H_0, esta cantidad sigue $\chi^2_{(p)}$ asintóticamente por el teorema del score de Lagrange (LM test).

Fórmula explícita del estimador de covarianzas de White:

En el modelo multivariado $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$:

$$\widehat{V}_{HC0} = (\mathbf{X}'\mathbf{X})^{-1} \left[\sum_{i=1}^{n} \hat{u}_i^2 \mathbf{x}_i \mathbf{x}_i' \right] (\mathbf{X}'\mathbf{X})^{-1} \tag{A.2}$$

$$\widehat{V}_{HC3} = (\mathbf{X}'\mathbf{X})^{-1} \left[\sum_{i=1}^{n} \frac{\hat{u}_i^2}{(1-h_{ii})^2} \mathbf{x}_i \mathbf{x}_i' \right] (\mathbf{X}'\mathbf{X})^{-1} \tag{A.3}$$

donde $h_{ii} = \mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i$ es el i-ésimo elemento diagonal de la matriz hat $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

A.5 Comparación de Eficiencia: MCO vs. MCG

Definición de pérdida de eficiencia: Para un estimador $\tilde{\beta}$ insesgado, la pérdida de eficiencia relativa respecto a MCG es:

$$\text{Pérdida} = \frac{\text{Var}(\hat{\beta}_{OLS}) - \text{Var}(\hat{\beta}_{GLS})}{\text{Var}(\hat{\beta}_{GLS})} \tag{A.4}$$

Caso escalar (modelo bivariado):

$$\text{Var}(\hat{\beta}_{OLS}) = \frac{\sum x_i^2 \sigma_i^2}{(\sum x_i^2)^2}$$
$$\text{Var}(\hat{\beta}_{GLS}) = \frac{1}{\sum x_i^2/\sigma_i^2}$$

Por la desigualdad de Cauchy-Schwarz:

$$\left(\sum \frac{x_i^2}{\sigma_i^2}\right)\left(\sum x_i^2 \sigma_i^2\right) \geq \left(\sum x_i^2\right)^2$$

Por tanto:

$$\text{Var}(\hat{\beta}_{OLS}) = \frac{\sum x_i^2 \sigma_i^2}{(\sum x_i^2)^2} \geq \frac{1}{\sum x_i^2/\sigma_i^2} = \text{Var}(\hat{\beta}_{GLS}) \tag{A.5}$$

La igualdad se da si y solo si $\sigma_i^2 = c$ para todo i (homocedasticidad), confirmando que MCG es estrictamente más eficiente que MCO en presencia de heteroscedasticidad genuina.

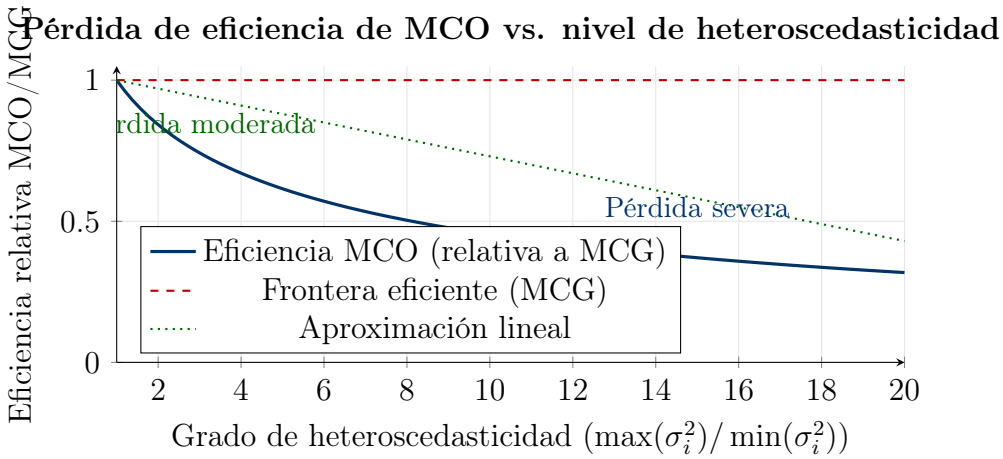

Figure 1.10: A medida que el grado de heteroscedasticidad (razón entre la varianza máxima y mínima) aumenta, la eficiencia relativa de MCO respecto a MCG disminuye. Con homocedasticidad perfecta (ratio = 1), ambos estimadores son igualmente eficientes.

Resumen Ejecutivo del Capítulo 11

Síntesis: Heteroscedasticidad

1. ¿Qué es?

La heteroscedasticidad ocurre cuando $\mathbb{E}(u_i^2) = \sigma_i^2 \neq \sigma^2$ (varianza no constante). Es típica en datos de corte transversal con unidades de tamaño muy diferente.

2. ¿Qué le pasa a MCO?

Propiedad	Estado
Insesgadez	✓Conservada
Consistencia	✓Conservada
Eficiencia (BLUE)	× **Perdida**
Varianzas correctas	× **Incorrectas**
Pruebas t y F	× **Inválidas**

3. ¿Cómo se detecta?

Gráficos de residuales + Pruebas formales: Park, Glejser, Spearman, Goldfeld-Quandt, BPG, White.

4. ¿Cómo se corrige?

- Si σ_i^2 conocida $\rightarrow$ **MCP** (óptimo, BLUE).
- Si σ_i^2 desconocida y muestra grande $\rightarrow$ **Errores robustos de White**.
- Si patrón identificable $\rightarrow$ **Transformaciones** (log, raíz cuadrada, razones).

5. Fórmulas Clave

$$\hat{\beta}_{GLS} = (\mathbf{X}'\mathbf{\Omega}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{\Omega}^{-1}\mathbf{y} \tag{MCG}$$

$$\mathrm{Var}(\hat{\beta}_2)_{\text{verdadera}} = \frac{\sum x_i^2\sigma_i^2}{(\sum x_i^2)^2} \tag{Varianza real MCO}$$

$$W = nR^2_{\text{aux}} \sim \chi^2_{(p)} \tag{Prueba de White}$$

$$F_{GQ} = \frac{RSS_2/(n_2-k)}{RSS_1/(n_1-k)} \sim F_{n_2-k,n_1-k} \tag{Goldfeld-Quandt}$$