Modelos No Lineales en los Parametros: MCO, Minimos Cuadrados No Lineales y Metodos de Estimacion Alternativos

Por que MCO falla y como estimar modelos con raices

Ejercicio 11.3 — *Econometria*, Gujarati & Porter, 5.a ed.

Con derivacion de las ecuaciones normales no lineales, algoritmo de Gauss-Newton y comparacion de metodos

Planteamiento. Se proponen dos modelos donde la variable dependiente es el valor absoluto de los residuos MCO ($|\hat{u}_i|$) como proxy de la desviacion estandar condicional:

$$|\hat{u}_i| = \sqrt{\beta_1 + \beta_2 X_i} + v_i \tag{I}$$

$$|\hat{u}_i| = \sqrt{\beta_1 + \beta_2 X_i^2} + v_i \tag{II}$$

Se pregunta si se pueden estimar los parametros β_1 y β_2 por MCO y, si no, que metodos alternativos existen.

1. Inciso (a): ¿puede MCO estimar estos modelos?

1.1. Respuesta

No. El metodo de MCO no puede aplicarse directamente a los modelos (**??**) y (**??**) porque ambos son **no lineales en los parametros**.

1.2. Condicion de linealidad en los parametros

MCO minimiza la suma de cuadrados residuales:

$$S(\boldsymbol{\beta}) = \sum_{i=1}^{n} v_i^2 = \sum_{i=1}^{n} [Y_i - f(X_i; \boldsymbol{\beta})]^2 \tag{1}$$

Para que MCO produzca ecuaciones normales *lineales* en $\boldsymbol{\beta}$ (y por tanto tenga solucion analitica explicita), la funcion f debe ser lineal en los parametros:

$$f(X_i; \boldsymbol{\beta}) = \beta_1 g_1(X_i) + \beta_2 g_2(X_i) + \cdots \tag{2}$$

para algunas funciones g_j de los datos. En este caso las derivadas parciales:

$$\frac{\partial f}{\partial \beta_j} = g_j(X_i) \tag{3}$$

no dependen de los parametros, y las ecuaciones normales $\partial S / \partial \beta_j = 0$ forman un sistema lineal resoluble analiticamente.

1.3. Por que los modelos (I) y (II) violan esta condicion

En el modelo (**??**), la funcion de regresion es:

$$f(X_i; \beta_1, \beta_2) = \sqrt{\beta_1 + \beta_2 X_i} = (\beta_1 + \beta_2 X_i)^{1/2} \tag{4}$$

Las derivadas parciales respecto a los parametros son:

$$\frac{\partial f}{\partial \beta_1} = \frac{1}{2}(\beta_1 + \beta_2 X_i)^{-1/2} = \frac{1}{2\sqrt{\beta_1 + \beta_2 X_i}} \tag{5}$$

$$\frac{\partial f}{\partial \beta_2} = \frac{X_i}{2}(\beta_1 + \beta_2 X_i)^{-1/2} = \frac{X_i}{2\sqrt{\beta_1 + \beta_2 X_i}} \tag{6}$$

Ambas derivadas dependen de los propios parametros β_1 y β_2, lo que hace que las ecuaciones normales:

$$\frac{\partial S}{\partial \beta_j} = -2 \sum_i v_i \frac{\partial f}{\partial \beta_j} = -2 \sum_i [|\hat{u}_i| - \sqrt{\beta_1 + \beta_2 X_i}] \cdot \frac{\partial f}{\partial \beta_j} = 0 \tag{7}$$

sean **no lineales** en β_1 y β_2. No hay solucion analitica cerrada; MCO ordinario no puede resolver este sistema.

1.4. Sustitucion cuadratica: ¿resuelve el problema?

Una tentacion es elevar al cuadrado ambos lados de (**??**):

$$|\hat{u}_i|^2 = \hat{u}_i^2 = \beta_1 + \beta_2 X_i + w_i \tag{8}$$

donde $w_i = v_i^2 + 2v_i\sqrt{\beta_1 + \beta_2 X_i}$. El lado izquierdo $\hat{u}_i^2$ es observable y el modelo en (**??**) es *lineal* en β_1 y β_2. Sin embargo, el nuevo termino de error w_i es heteroscedastico y correlacionado con los regresores, por lo que MCO sobre la version cuadrada no produce estimadores MELI. Es un atajo que introduce problemas de estimacion.

> MCO no puede estimar los modelos (**??**) y (**??**) porque son no lineales en los parametros: las ecuaciones normales resultantes son no lineales en β_1 y β_2 y no tienen solucion analitica cerrada.

2. Inciso (b): metodos de estimacion alternativos

2.1. Metodo formal 1: Minimos Cuadrados No Lineales (MCNL)

El metodo de **Minimos Cuadrados No Lineales** (NLLS, *Nonlinear Least Squares*) generaliza MCO al caso de modelos no lineales en los parametros. El problema de minimizacion es el mismo:

$$\hat{\boldsymbol{\beta}}^{\text{MCNL}} = \arg\min_{\boldsymbol{\beta}} S(\boldsymbol{\beta}) = \arg\min_{\boldsymbol{\beta}} \sum_i [|\hat{u}_i| - f(X_i; \boldsymbol{\beta})]^2 \tag{9}$$

pero ahora f es no lineal en $\boldsymbol{\beta}$. La diferencia es que la solucion se obtiene *iterativamente* en lugar de analiticamente.

Propiedades asintóticas del estimador MCNL

Bajo condiciones de regularidad, el estimador MCNL es:

- **Consistente**: $\hat{\boldsymbol{\beta}}^{\text{MCNL}} \xrightarrow{p} \boldsymbol{\beta}_0$
- **Asintóticamente normal**: $\sqrt{n}(\hat{\boldsymbol{\beta}}^{\text{MCNL}} - \boldsymbol{\beta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{V})$
- **Asintóticamente eficiente** dentro de la clase de estimadores de momentos bajo homoscedasticidad.

La matriz de varianzas asintótica es:

$$\mathbf{V} = \sigma^2 \left(\mathbf{F}'\mathbf{F}\right)^{-1} \tag{10}$$

donde $\mathbf{F}$ es la matriz de derivadas parciales evaluadas en $\hat{\boldsymbol{\beta}}^{\text{MCNL}}$:

$$F_{ij} = \left.\frac{\partial f(X_i; \boldsymbol{\beta})}{\partial \beta_j}\right|_{\boldsymbol{\beta}=\hat{\boldsymbol{\beta}}} \tag{11}$$

2.2. Metodo formal 2: algoritmo de Gauss-Newton

El algoritmo de **Gauss-Newton** es el procedimiento iterativo mas comun para MCNL. La idea es linealizar f en cada iteracion mediante una expansion de Taylor de primer orden alrededor del valor actual $\boldsymbol{\beta}^{(k)}$:

$$f(X_i; \boldsymbol{\beta}) \approx f(X_i; \boldsymbol{\beta}^{(k)}) + \sum_j \left.\frac{\partial f}{\partial \beta_j}\right|_{\boldsymbol{\beta}^{(k)}} (\beta_j - \beta_j^{(k)}) \tag{12}$$

Definiendo:

$$\tilde{Y}_i^{(k)} = |\hat{u}_i| - f(X_i; \boldsymbol{\beta}^{(k)}) + \sum_j F_{ij}^{(k)} \beta_j^{(k)} \tag{13}$$

$$\tilde{X}_{ij}^{(k)} = F_{ij}^{(k)} = \left.\frac{\partial f}{\partial \beta_j}\right|_{\boldsymbol{\beta}^{(k)}} \tag{14}$$

La actualizacion en la iteracion $k+1$ se obtiene por MCO de $\tilde{Y}_i^{(k)}$ sobre $\tilde{X}_{ij}^{(k)}$:

$$\boldsymbol{\beta}^{(k+1)} = \boldsymbol{\beta}^{(k)} + \left[(\tilde{\mathbf{X}}^{(k)})'\tilde{\mathbf{X}}^{(k)}\right]^{-1} (\tilde{\mathbf{X}}^{(k)})'\tilde{\mathbf{Y}}^{(k)} \tag{15}$$

El algoritmo se repite hasta convergencia: $\|\boldsymbol{\beta}^{(k+1)} - \boldsymbol{\beta}^{(k)}\| < \varepsilon$ para algun criterio de tolerancia ε.

Aplicacion al modelo (I)

Para el modelo (**??**), las derivadas (**??**) y (**??**) evaludas en $\boldsymbol{\beta}^{(k)}$ son:

$$\tilde{X}_{i1}^{(k)} = \frac{1}{2\sqrt{\beta_1^{(k)} + \beta_2^{(k)} X_i}} \tag{16}$$

$$\tilde{X}_{i2}^{(k)} = \frac{X_i}{2\sqrt{\beta_1^{(k)} + \beta_2^{(k)} X_i}} \tag{17}$$

Estas son funciones de los datos observados y de los valores actuales de los parametros. En cada iteracion se recalculan y se aplica MCO sobre las variables pseudo-lineales $(\tilde{Y}^{(k)}, \tilde{X}_1^{(k)}, \tilde{X}_2^{(k)})$.

2.3. Metodo formal 3: Newton-Raphson y Marquardt

El algoritmo de **Newton-Raphson** usa la matriz Hessiana de $S(\boldsymbol{\beta})$ para la actualizacion:

$$\boldsymbol{\beta}^{(k+1)} = \boldsymbol{\beta}^{(k)} - \left[\mathbf{H}^{(k)}\right]^{-1} \mathbf{g}^{(k)} \tag{18}$$

donde $\mathbf{g}^{(k)} = \nabla_{\boldsymbol{\beta}} S(\boldsymbol{\beta}^{(k)})$ es el gradiente y $\mathbf{H}^{(k)} = \nabla^2_{\boldsymbol{\beta}} S(\boldsymbol{\beta}^{(k)})$ es la Hessiana. Es mas rapido que Gauss-Newton cerca del maximo pero requiere calcular segundas derivadas.

El algoritmo de **Marquardt** (o Levenberg-Marquardt) combina Gauss-Newton y descenso de gradiente:

$$\boldsymbol{\beta}^{(k+1)} = \boldsymbol{\beta}^{(k)} + \left[(\tilde{\mathbf{X}}^{(k)})'\tilde{\mathbf{X}}^{(k)} + \mu^{(k)}\mathbf{I}\right]^{-1} (\tilde{\mathbf{X}}^{(k)})'\tilde{\mathbf{Y}}^{(k)} \tag{19}$$

donde $\mu^{(k)} \geq 0$ es un parametro de amortiguacion. Para $\mu^{(k)} = 0$ se recupera Gauss-Newton; para $\mu^{(k)} \to \infty$ se obtiene descenso de gradiente. Este metodo es mas robusto que Gauss-Newton puro y es el estandar en la mayoria de los paquetes de software.

2.4. Metodo formal 4: Maxima Verosimilitud (MV)

Bajo el supuesto de que $v_i \sim \mathcal{N}(0, \sigma^2)$, la funcion de log-verosimilitud para el modelo (**??**) es:

$$\ell(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_i [|\hat{u}_i| - \sqrt{\beta_1 + \beta_2 X_i}]^2 \tag{20}$$

Maximizar (**??**) respecto a $\boldsymbol{\beta}$ es equivalente a minimizar $S(\boldsymbol{\beta})$ en (**??**): los estimadores MV y MCNL coinciden bajo normalidad. Los estimadores MV tienen propiedades asintóticas optimas (consistencia, normalidad asintótica, eficiencia asintótica).

2.5. Metodo informal: busqueda en grilla (prueba y error)

Un metodo informal es la **busqueda en grilla** (*grid search*):

1. Definir una rejilla de valores candidatos para (β_1, β_2), por ejemplo $\beta_1 \in \{0{,}1, 0{,}2, \ldots, 2{,}0\}$ y $\beta_2 \in \{0{,}01, 0{,}02, \ldots, 0{,}5\}$.

2. Para cada par (β_1, β_2) de la rejilla, calcular:

$$S(\beta_1, \beta_2) = \sum_i [|\hat{u}_i| - \sqrt{\beta_1 + \beta_2 X_i}]^2 \tag{21}$$

3. Seleccionar el par que minimiza $S(\beta_1, \beta_2)$.

4. Refinar la busqueda alrededor del minimo encontrado con una grilla mas fina.

Este metodo es computacionalmente intensivo pero conceptualmente simple. No garantiza encontrar el minimo global si la funcion S tiene multiples minimos locales, y es impractico en alta dimension.

2.6. Comparacion de metodos

El metodo recomendado es MCNL implementado mediante el algoritmo de Marquardt, disponible en la mayoria de los paquetes econometricos (Stata: `nl`; R: `nls`; Python: `scipy.optimize.curve_fit`). Se necesitan valores iniciales

Cuadro 1: Comparacion de metodos para estimar modelos no lineales en los parametros

Metodo	**Ventajas**	**Desventajas**	**Cuando usar**
MCNL / Gauss-Newton	Solucion sistematica; propiedades asintóticas conocidas	Requiere valores iniciales; puede no converger	Estandar para modelos no lineales
Marquardt	Mas robusto que G-N; converge en mas casos	Ligeramente mas costoso computacionalmente	Cuando G-N falla
Maxima Verosimilitud	Optimo asintóticamente bajo normalidad	Requiere supuesto distribucional; mas complejo	Cuando se conoce la distribucion de v_i
Busqueda en grilla	Simple; no requiere derivadas; encuentra mínimo global si la grilla es fina	Lenta; imprecisa; no escala a muchos parametros	Diagnostico inicial; pocos parametros

razonables para los parametros; una busqueda en grilla puede servir como punto de partida.

A. Derivacion de las ecuaciones normales del MCNL para el modelo (I)

Para el modelo (**??**), las condiciones de primer orden $\partial S/\partial \beta_j = 0$ son:

$$\frac{\partial S}{\partial \beta_1} = -2\sum_i [|\hat{u}_i| - (\beta_1 + \beta_2 X_i)^{1/2}] \cdot \frac{1}{2(\beta_1 + \beta_2 X_i)^{1/2}} = 0 \tag{22}$$

$$\frac{\partial S}{\partial \beta_2} = -2\sum_i [|\hat{u}_i| - (\beta_1 + \beta_2 X_i)^{1/2}] \cdot \frac{X_i}{2(\beta_1 + \beta_2 X_i)^{1/2}} = 0 \tag{23}$$

Simplificando:

$$\sum_i \frac{|\hat{u}_i|}{(\beta_1 + \beta_2 X_i)^{1/2}} = \sum_i 1 = n \tag{24}$$

$$\sum_i \frac{X_i|\hat{u}_i|}{(\beta_1 + \beta_2 X_i)^{1/2}} = \sum_i X_i \tag{25}$$

Las ecuaciones (**??**) y (**??**) son claramente no lineales en β_1 y β_2 (los parametros aparecen dentro de la raiz cuadrada en el denominador). No hay expresion algebraica cerrada para su solucion: confirma que MCO ordinario no es aplicable.

B. Valores iniciales para el algoritmo iterativo

Una estrategia practica para obtener valores iniciales $(\beta_1^{(0)}, \beta_2^{(0)})$:

1. Elevar al cuadrado el modelo (**??**): $\hat{u}_i^2 \approx \beta_1 + \beta_2 X_i$ (ignorando el termino de error).
2. Estimar esta regresion lineal por MCO.
3. Usar los estimadores MCO como valores iniciales para el algoritmo MCNL.

Este procedimiento de dos pasos proporciona valores iniciales razonables sin garantizar eficiencia, pero acelera la convergencia del algoritmo iterativo.

Nota. Los modelos (**??**) y (**??**) aparecen en el contexto del diagnostico de heteroscedasticidad: se postulan como modelos para la desviacion estandar condicional $\sigma_i = \mathbb{E}[|u_i|]$ en funcion de X_i. Si se prefiere modelar la varianza en lugar de la desviacion, el modelo cuadratico $\hat{u}_i^2 = \beta_1 + \beta_2 X_i + w_i$ es lineal en los parametros y puede estimarse directamente por MCO, aunque w_i no es homoscedastico. Esta es la base de la prueba de Breusch-Pagan (1979).