Minimos Cuadrados Ponderados: Representacion en Desviaciones respecto a las Medias Ponderadas

Demostracion completa de las ecuaciones (11.3.8) y (11.3.9)

Ejercicio 11.5 — *Econometria*, Gujarati & Porter, 5.a ed.

Con manipulacion algebraica paso a paso, lemas auxiliares y verificacion de la varianza

Planteamiento. Considere el modelo de regresion simple con heteroscedasticidad:

$$Y_i = \beta_1 + \beta_2 X_i + u_i, \qquad \mathbb{E}[u_i^2] = \sigma_i^2 \tag{1}$$

El estimador de Minimos Cuadrados Ponderados (MCP) con pesos $w_i = 1/\sigma_i^2$ es, segun la ecuacion (11.3.8) de Gujarati:

$$\hat{\beta}_2^* = \frac{(\sum w_i)(\sum w_i X_i Y_i) - (\sum w_i X_i)(\sum w_i Y_i)}{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2} \tag{2}$$

con varianza (ecuacion 11.3.9):

$$\mathrm{Var}(\hat{\beta}_2^*) = \frac{\sum w_i}{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2} \tag{3}$$

Se pide mostrar que estas expresiones pueden reescribirse como:

$$\hat{\beta}_2^* = \frac{\sum w_i y_i^* x_i^*}{\sum w_i (x_i^*)^2} \tag{4}$$

$$\mathrm{Var}(\hat{\beta}_2^*) = \frac{1}{\sum w_i (x_i^*)^2} \tag{5}$$

donde las desviaciones y medias ponderadas se definen como:

$$\bar{Y}^* = \frac{\sum w_i Y_i}{\sum w_i}, \qquad \bar{X}^* = \frac{\sum w_i X_i}{\sum w_i} \tag{6}$$

$$y_i^* = Y_i - \bar{Y}^*, \qquad x_i^* = X_i - \bar{X}^* \tag{7}$$

1. Lemas auxiliares

Antes de la demostracion principal, establecemos tres lemas que simplifican el algebra.

Lema 1. $\sum w_i x_i^* = 0$

Lema 2. $\sum w_i y_i^* = 0$

Lema 3.

$$\sum w_i (x_i^*)^2 = \sum w_i X_i^2 - \frac{(\sum w_i X_i)^2}{\sum w_i} = \frac{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2}{\sum w_i}$$

$$\begin{aligned}
\sum w_i (x_i^*)^2 &= \sum w_i (X_i - \bar{X}^*)^2 = \sum w_i \big(X_i^2 - 2X_i\bar{X}^* + (\bar{X}^*)^2\big) \\
&= \sum w_i X_i^2 - 2\bar{X}^* \sum w_i X_i + (\bar{X}^*)^2 \sum w_i \\
&= \sum w_i X_i^2 - 2 \cdot \frac{\sum w_i X_i}{\sum w_i} \cdot \sum w_i X_i + \frac{(\sum w_i X_i)^2}{(\sum w_i)^2} \cdot \sum w_i \\
&= \sum w_i X_i^2 - 2\frac{(\sum w_i X_i)^2}{\sum w_i} + \frac{(\sum w_i X_i)^2}{\sum w_i} \\
&= \sum w_i X_i^2 - \frac{(\sum w_i X_i)^2}{\sum w_i} = \frac{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2}{\sum w_i} \qquad \square
\end{aligned} \tag{8}$$

2. Demostracion de $\hat{\beta}_2^* = \sum w_i y_i^* x_i^* / \sum w_i (x_i^*)^2$

2.1. Desarrollo del numerador

Expandimos $\sum w_i y_i^* x_i^*$ usando las definiciones (7):

$$\begin{aligned}\sum w_i y_i^* x_i^* &= \sum w_i (Y_i - \bar{Y}^*)(X_i - \bar{X}^*) \\ &= \sum w_i \left[Y_i X_i - Y_i \bar{X}^* - X_i \bar{Y}^* + \bar{Y}^* \bar{X}^* \right] \\ &= \sum w_i X_i Y_i - \bar{X}^* \sum w_i Y_i - \bar{Y}^* \sum w_i X_i + \bar{Y}^* \bar{X}^* \sum w_i \end{aligned} \tag{9}$$

Sustituyendo $\bar{X}^* = \sum w_i X_i / \sum w_i$ y $\bar{Y}^* = \sum w_i Y_i / \sum w_i$ en (10):

$$\begin{aligned} &= \sum w_i X_i Y_i - \frac{\sum w_i X_i}{\sum w_i} \cdot \sum w_i Y_i - \frac{\sum w_i Y_i}{\sum w_i} \cdot \sum w_i X_i + \frac{\sum w_i Y_i}{\sum w_i} \cdot \frac{\sum w_i X_i}{\sum w_i} \cdot \sum w_i \\ &= \sum w_i X_i Y_i - \frac{(\sum w_i X_i)(\sum w_i Y_i)}{\sum w_i} - \frac{(\sum w_i Y_i)(\sum w_i X_i)}{\sum w_i} + \frac{(\sum w_i Y_i)(\sum w_i X_i)}{\sum w_i} \\ &= \sum w_i X_i Y_i - \frac{(\sum w_i X_i)(\sum w_i Y_i)}{\sum w_i} \end{aligned} \tag{10}$$

Multiplicando y dividiendo por $\sum w_i$:

$$\sum w_i y_i^* x_i^* = \frac{(\sum w_i)(\sum w_i X_i Y_i) - (\sum w_i X_i)(\sum w_i Y_i)}{\sum w_i} \tag{11}$$

2.2. Denominador

Por el Lema 3:

$$\sum w_i (x_i^*)^2 = \frac{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2}{\sum w_i} \tag{12}$$

2.3. Cociente

Dividiendo (12) entre (13):

$$\frac{\sum w_i y_i^* x_i^*}{\sum w_i (x_i^*)^2} = \frac{\dfrac{(\sum w_i)(\sum w_i X_i Y_i) - (\sum w_i X_i)(\sum w_i Y_i)}{\sum w_i}}{\dfrac{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2}{\sum w_i}} = \frac{(\sum w_i)(\sum w_i X_i Y_i) - (\sum w_i X_i)(\sum w_i Y_i)}{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2} \tag{13}$$

El factor $1/\sum w_i$ se cancela en numerador y denominador. La expresion resultante es exactamente la ecuacion (2). Por tanto:

$$\boxed{\hat{\beta}_2^* = \frac{\sum w_i y_i^* x_i^*}{\sum w_i (x_i^*)^2}} \tag{14}$$

□

3. Demostracion de $\mathrm{Var}(\hat{\beta}_2^*) = 1/\sum w_i (x_i^*)^2$

3.1. Punto de partida

La varianza original (3) es:

$$\mathrm{Var}(\hat{\beta}_2^*) = \frac{\sum w_i}{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2} \tag{15}$$

3.2. Conexion con el denominador del Lema 3

Del Lema 3:

$$\sum w_i (x_i^*)^2 = \frac{(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2}{\sum w_i} \tag{16}$$

Despejando el denominador de (16):

$$(\sum w_i)(\sum w_i X_i^2) - (\sum w_i X_i)^2 = \sum w_i \cdot \sum w_i (x_i^*)^2 \tag{17}$$

3.3. Sustitucion

Sustituyendo (18) en (16):

$$\mathrm{Var}(\hat{\beta}_2^*) = \frac{\sum w_i}{\sum w_i \cdot \sum w_i (x_i^*)^2} = \frac{1}{\sum w_i (x_i^*)^2} \tag{18}$$

El factor $\sum w_i$ se cancela en numerador y denominador:

$$\boxed{\mathrm{Var}(\hat{\beta}_2^*) = \frac{1}{\sum w_i (x_i^*)^2}} \tag{19}$$

□

4. Interpretacion de los resultados

4.1. Analogia con MCO ordinario

Comparando los resultados obtenidos con los estimadores MCO ordinarios en desviaciones:

Cantidad	**MCO ordinario**	**MCP (ponderado)**
Pendiente	$\hat{\beta}_2 = \frac{\sum y_i x_i}{\sum x_i^2}$	$\hat{\beta}_2^* = \frac{\sum w_i y_i^* x_i^*}{\sum w_i (x_i^*)^2}$
Varianza	$\mathrm{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_i^2}$	$\mathrm{Var}(\hat{\beta}_2^*) = \frac{1}{\sum w_i (x_i^*)^2}$
Medias usadas	$\bar{Y} = \sum Y_i/n$, $\bar{X} = \sum X_i/n$	$\bar{Y}^* = \sum w_i Y_i / \sum w_i$, $\bar{X}^* = \sum w_i X_i / \sum w_i$
Desviaciones	$y_i = Y_i - \bar{Y}$, $x_i = X_i - \bar{X}$	$y_i^* = Y_i - \bar{Y}^*$, $x_i^* = X_i - \bar{X}^*$

La estructura es completamente analoga: MCP es equivalente a MCO aplicado a variables expresadas en desviaciones respecto a sus *medias ponderadas*, donde las ponderaciones son $w_i = 1/\sigma_i^2$.

4.2. Interpretacion de la varianza

La varianza del estimador MCP es inversamente proporcional a la suma ponderada de cuadrados de las desviaciones de X:

$$\mathrm{Var}(\hat{\beta}_2^*) = \frac{1}{\sum w_i (x_i^*)^2} \tag{20}$$

Cuando las observaciones con mayor varianza del error (menor w_i) tienen valores de X alejados de la media, reciben menos peso, lo que es correcto econometricamente: las observaciones "ruidosas" contribuyen menos a la estimacion.

4.3. Eficiencia del estimador MCP

El estimador MCP es MELI (Mejor Estimador Lineal Insesgado) bajo heteroscedasticidad. Esto se puede ver comparando su varianza con la del estimador MCO ordinario aplicado al mismo modelo:

$$\mathrm{Var}(\hat{\beta}_2^{\mathrm{MCO}}) = \frac{\sum w_i^2 (x_i^*)^2}{\left[\sum w_i (x_i^*)^2\right]^2} \cdot \frac{1}{w_i^2} \geq \frac{1}{\sum w_i (x_i^*)^2} = \mathrm{Var}(\hat{\beta}_2^*) \tag{21}$$

Por la desigualdad de Cauchy-Schwarz: $\left[\sum w_i (x_i^*)^2\right]^2 \leq \sum w_i (x_i^*)^4 \cdot n$, lo que confirma que MCP tiene menor o igual varianza que MCO bajo heteroscedasticidad.

Resultado fundamental. El estimador MCP de la pendiente y su varianza:

$$\hat{\beta}_2^* = \frac{\sum w_i y_i^* x_i^*}{\sum w_i (x_i^*)^2}, \qquad \mathrm{Var}(\hat{\beta}_2^*) = \frac{1}{\sum w_i (x_i^*)^2}$$

son algebraicamente identicos a las expresiones originales (2) y (3). La representacion en desviaciones ponderadas hace explicita la analogia con MCO ordinario y muestra que MCP es equivalente a aplicar MCO con observaciones reescaladas por $\sqrt{w_i}$.

A. Verificacion: propiedad de suma cero de las desviaciones ponderadas

Una propiedad clave que subyace a todo el desarrollo es que las desviaciones ponderadas suman cero:

$$\sum w_i x_i^* = 0 \quad \text{(Lema 1)} \tag{22}$$

$$\sum w_i y_i^* = 0 \quad \text{(Lema 2)} \tag{23}$$

Estas propiedades son el analogo ponderado de la propiedad MCO ordinaria $\sum x_i = \sum y_i = 0$. Garantizan que las condiciones normales del problema MCP se reducen al sistema estudiado.

B. Relacion entre MCP y MCO sobre datos transformados

Si se define $Y_i^+ = \sqrt{w_i} Y_i$, $X_i^+ = \sqrt{w_i} X_i$ y $\mathbf{1}_i^+ = \sqrt{w_i}$, entonces aplicar MCO ordinario al modelo transformado:

$$Y_i^+ = \beta_1 \mathbf{1}_i^+ + \beta_2 X_i^+ + u_i^+ \tag{24}$$

produce exactamente los estimadores MCP $\hat{\beta}_1^*$ y $\hat{\beta}_2^*$. El error transformado $u_i^+ = u_i / \sqrt{\sigma_i^2}$ tiene varianza constante 1, lo que restaura la homoscedasticidad y permite que MCO sea MELI sobre los datos transformados.

Nota. Las ecuaciones (15) y (20) son las formas computacionalmente mas convenientes del estimador MCP. La expresion en desviaciones ponderadas hace explicita la analogia estructural con MCO y facilita la intuicion sobre como cada observacion contribuye ponderadamente a la estimacion de la pendiente.