

Ejercicio 13.3 — Omisión del Intercepto cuando el Modelo Verdadero lo Incluye

Consecuencias del error de especificación por omisión de una variable relevante: el término constante

Ejercicio 13.3 — *Econometría*, Gujarati & Porter, 5.a ed. por Emanuel Quintana Silva

VERIFICACIÓN EMPÍRICA CON DATOS SIMULADOS, $n = 50$, SEMILLA 12345

1. PLANTEAMIENTO DEL PROBLEMA

Se continúa con el ejercicio 13.2, pero ahora el modelo **(2)** es el verdadero:

$$\text{Modelo verdadero: } Y_i = \alpha_0 + \alpha_1 X_i + v_i \quad (1)$$

$$\text{Modelo mal especificado: } Y_i = \beta_1 X_i + u_i \quad (2)$$

El modelo (2) obliga a la línea de regresión a pasar por el origen, omitiendo el término constante $\alpha_0 \neq 0$ que sí existe en la realidad.

En la taxonomía de Gujarati (sección 13.2), este error corresponde a la **omisión de una variable relevante**, donde la “variable” omitida es el término constante α_0 . Es el caso opuesto al ejercicio anterior:

Tipo de error	Consecuencia principal	Ejercicio
Inclusión de irrelevante	Insensatez + ineficiencia	13.2
Omisión de relevante	Sesgo + inconsistencia	13.3

2. CONSECUENCIAS TEÓRICAS

2.1. Sesgo e inconsistencia del estimador de la pendiente

El estimador MCO de β_1 en el modelo (2), forzado a pasar por el origen, es:

$$\hat{\beta}_1 = \frac{\sum X_i Y_i}{\sum X_i^2} \quad (3)$$

Sustituyendo el modelo verdadero $Y_i = \alpha_0 + \alpha_1 X_i + v_i$:

$$\begin{aligned} E(\hat{\beta}_1) &= \frac{\sum X_i E(Y_i)}{\sum X_i^2} = \frac{\sum X_i (\alpha_0 + \alpha_1 X_i)}{\sum X_i^2} \\ &= \alpha_1 + \alpha_0 \left(\frac{\sum X_i}{\sum X_i^2} \right) \end{aligned} \quad (4)$$

El sesgo resultante es:

$$\boxed{\text{Sesgo}(\hat{\beta}_1) = \alpha_0 \cdot \frac{\sum X_i}{\sum X_i^2}} \quad (5)$$

El estimador $\hat{\beta}_1$ solo sería insesgado si:

- $\alpha_0 = 0$ (contradice el supuesto del modelo verdadero), o
- $\sum X_i = 0$ (raramente plausible con datos económicos, donde $X_i > 0$).

Dado que ninguna de estas condiciones se cumple en general, el sesgo **no desaparece al aumentar n** : el estimador también es **inconsistente**.

A diferencia del Ej. 13.2, donde $E(\hat{\alpha}_1) = \beta_1$ se preservaba, aquí $E(\hat{\beta}_1) \neq \alpha_1$ de forma sistemática. La dirección del sesgo depende del signo de α_0 : si $\alpha_0 > 0$ y $\sum X_i > 0$ (el caso típico), el sesgo es **positivo** y se sobreestima la pendiente.

2.2. Estimación incorrecta de la varianza del error

El estimador de σ^2 en el modelo (2) usa $n - 1$ grados de libertad:

$$\hat{\sigma}_{(1)}^2 = \frac{\sum \hat{u}_i^2}{n - 1} \quad (6)$$

Al forzar la línea a pasar por el origen, los residuos $\hat{u}_i$ deben absorber el efecto del intercepto omitido α_0 , produciendo residuos sistemáticamente más grandes que en el modelo correcto. Esto conduce a una **sobreestimación** de σ^2 y, en consecuencia, a varianzas estimadas incorrectas para todos los coeficientes.

2.3. Inferencia estadística inválida

Dado que tanto los coeficientes como sus varianzas estimadas están sesgados:

- Las pruebas t y F **dejan de ser válidas** y pueden llevar a conclusiones erróneas sobre la significancia de X .
- Los intervalos de confianza **no tienen la cobertura nominal**: no contendrán el verdadero α_1 con la probabilidad deseada $(1 - \alpha)$.
- Los errores de Tipo I y Tipo II se cometen de forma sistemática, no aleatoria.

2.4. R^2 potencialmente negativo

En regresión por el origen, los residuos no necesariamente suman cero ($\sum \hat{u}_i \neq 0$), por lo que la descomposición estándar de la varianza total no se sostiene:

$$\underbrace{\sum (Y_i - \bar{Y})^2}_{SCT} \neq \underbrace{SCM}_{\text{explicada}} + \underbrace{SCR}_{\text{residual}} \quad (7)$$

El R^2 convencional puede ser **negativo**, indicando que el modelo ajustado predice peor que el simple promedio $\bar{Y}$. Stata reporta R^2 no centrado (`r2_u`) para `noconstant`, que no es comparable con el R^2 centrado del modelo con intercepto.

2.5. Predicciones sesgadas

Los pronósticos $\hat{Y}_i = \hat{\beta}_1 X_i$ estarán sistemáticamente desplazados respecto a los valores reales. El sesgo es especialmente pronunciado para valores de X cercanos a cero, donde el intercepto omitido tiene mayor peso relativo.

3. RESUMEN DE CONSECUENCIAS

Propiedad	Ej. 13.2 (intercepto innecesario)	Ej. 13.3 (intercepto omitido)
Insesgadez	✓ Preservada	× Perdida
Consistencia	✓ Preservada	× Perdida
Eficiencia	~ Reducida	— No aplica
Validez t y F	✓ Válidas	× Inválidas
Intervalos de conf.	~ Más amplios	× Cobertura incorrecta
R^2 comparable	~ No comparable	× Puede ser negativo
Predicciones	✓ Insesgadas	× Sesgadas sistemática-mente

4. VERIFICACIÓN EMPÍRICA CON DATOS SIMULADOS

Se generan datos del proceso verdadero $Y_i = 3 + 2X_i + v_i$ ($\alpha_0 = 3$, $\alpha_1 = 2$, $v_i \sim N(0, 1)$, $n = 50$) y se comparan ambas especificaciones.

4.1. Modelo correcto — con intercepto

$$\hat{Y}_i = 2,8711 + 2,0160 X_i \quad (8)$$

Variable	Coeficiente	Error est.	Razón t	$P(> t)$
X_i	2.0160	0.0491	41.02	0.000
Constante	2.8711	0.2928	9.81	0.000
$R^2 = 0,9723 \quad \bar{R}^2 = 0,9717 \quad F(1, 48) = 1682,58 \quad n = 50$				

4.2. Modelo mal especificado — regresión por el origen

$$\hat{Y}_i = 2,4423 X_i \quad (9)$$

Variable	Coeficiente	Error est.	Razón t	$P(> t)$
X_i	2.4423	0.0393	62.16	0.000
$R_u^2 = 0,9875$ (no centrado) $F(1, 49) = 3863,98 \quad n = 50$				

El $R^2 = 0,9875$ del modelo por el origen es **no centrado** y no es comparable con el $R^2 = 0,9723$ del modelo con intercepto. La apariencia de “mejor ajuste” en el modelo restringido es un artefacto numérico, no evidencia de superioridad.

5. VERIFICACIÓN DE LA FÓRMULA DEL SESGO

Con los resultados de Stata se verifica algebraicamente la fórmula del sesgo:

Cantidad	Valor
α_0 verdadero	3.0000
$\sum X_i$	263.55
$\sum X_i^2$	1774.68
$\sum X_i / \sum X_i^2$	0.148503
Sesgo teórico = $\alpha_0 \cdot \frac{\sum X_i}{\sum X_i^2}$	0.4455
$\hat{\alpha}_1$ (modelo correcto)	2.0160
$\hat{\beta}_1$ (modelo por el origen)	2.4423
Sesgo empírico = $\hat{\beta}_1 - \hat{\alpha}_1$	0.4264
Diferencia (empírico – teórico)	–0.0191

La pequeña diferencia de $-0,0191$ entre el sesgo empírico ($0,4264$) y el teórico ($0,4455$) se debe a que $\hat{\alpha}_1 \neq \alpha_1 = 2$ exactamente por variación muestral. La fórmula se verifica con alta precisión.

$\hat{\beta}_1 = 2,4423 \neq 2,0160 \approx \hat{\alpha}_1$. La sobreestimación de la pendiente en el modelo restringido ($\Delta = 0,4264$) coincide estrechamente con el sesgo teórico predicho ($0,4455 = 3 \times 263,55/1774,68$). El intercepto estimado en el modelo correcto ($\hat{\alpha}_0 = 2,871$, $t = 9,81$, $p < 0,001$) confirma que el término constante era **necesario** y estadísticamente significativo.

6. TABLA COMPARATIVA DE ESTIMADORES

	Modelo correcto	Modelo origen
Variable	$(\alpha_0, \alpha_1 X)$	$(\beta_1 X)$
X_i (pendiente)	2.0160	2.4423
Error estándar	0.0491	0.0393
Constante	2.8711	—
Error estándar	0.2928	—
n	50	50
R^2	0.9723	0.9875*
Root MSE	0.9650	1.6552
Sesgo de $\hat{\beta}_1$	0	+0,4264

* R^2 no centrado; no comparable con el R^2 centrado del modelo con intercepto.

Nótese que el Root MSE del modelo por el origen (1,6552) es **considerablemente mayor** que el del modelo correcto (0,9650), evidenciando la sobreestimación de σ^2 predicha teóricamente: los residuos deben absorber el efecto del intercepto omitido.

7. SÍNTESIS: COMPARACIÓN DE LOS DOS ERRORES DE ESPECIFICACIÓN

Criterio	Ej. 13.2 (intercepto innecesario)	Ej. 13.3 (intercepto omitido)
Error cometido	Incluir α_0 cuando $\alpha_0 = 0$	Omitir α_0 cuando $\alpha_0 \neq 0$
Tipo en taxonomía	Variable irrelevante incluida	Variable relevante omitida
$E(\hat{\beta}_1)$	$= \beta_1$ (insesgado)	$\neq \alpha_1$ (sesgado)
$\hat{\sigma}^2$	Levemente inflada	Fuertemente sobreestimada
Pruebas t , F	Válidas	Inválidas
Costo principal	Menor eficiencia	Sesgo + inferencia inválida
Gravedad	Leve	Grave

8. CONCLUSIÓN

Omitir un intercepto relevante es un error de especificación **mucho más grave** que incluir uno irrelevante. Mientras que el segundo (Ej. 13.2) solo genera *ineficiencia* — estimadores insesgados pero con mayor varianza —, el primero invalida las propiedades fundamentales del estimador MCO: se pierde la **insesgadez** y la **consistencia**, la inferencia estadística deja de ser válida y las predicciones estarán sistemáticamente sesgadas.

Los datos de Stata confirman la teoría con precisión: $\hat{\beta}_1 = 2,4423$ sobreestima la pendiente verdadera en +0,4264, cifra muy cercana al sesgo teórico de 0,4455. El Root MSE se incrementa de 0,9650 a 1,6552 al restringir el modelo, evidencia

directa de la sobreestimación de σ^2 .

La regla práctica de Gujarati cobra aquí su pleno sentido: *ante la duda sobre si incluir o no un intercepto, es preferible incluirlo y asumir la pequeña pérdida de eficiencia*. Omitirlo cuando realmente existe en el proceso generador de datos produce un error sistemático que no se corrige con muestras más grandes.

Nota metodológica. La asimetría entre los dos errores de especificación tiene implicaciones prácticas directas. En la estrategia de modelación econométrica, la *regla general* es partir del modelo más general (con intercepto) y reducirlo solo si la teoría económica y las pruebas estadísticas lo justifican conjuntamente. Restringir el modelo a priori sin fundamento teórico sólido expone al investigador al sesgo documentado en este ejercicio. Los únicos casos donde la regresión por el origen es apropiada son aquellos en que la teoría garantiza inequívocamente que $Y = 0$ cuando $X = 0$ (ej. ingresos nulos implican consumo nulo en ciertos modelos), y aun en estos casos la restricción debería contrastarse formalmente.

REFERENCIAS

- Gujarati, D. N., & Porter, D. C. (2010). *Econometría* (5.^a ed.). McGraw-Hill. Capítulo 13, secciones 13.2 y 13.3.
- Greene, W. H. (2018). *Econometric Analysis* (8.^a ed.). Pearson. Capítulo 5.
- Wooldridge, J. M. (2016). *Introductory Econometrics* (6.^a ed.). Cengage. Capítulo 3.