

Ejercicio 13.4 — Inclusión de una Variable Irrelevante en el Modelo de Regresión Múltiple

*Consecuencias del error de especificación por inclusión
de una variable cuyo verdadero coeficiente es cero*

Ejercicio 13.4 — *Econometría*, Gujarati & Porter, 5.a ed. por Emanuel Quintana Silva

VERIFICACIÓN EMPÍRICA CON DATOS SIMULADOS, $n = 200$, SEMILLA 2026

1. PLANTEAMIENTO DEL PROBLEMA

Suponga que el verdadero modelo es:

$$\text{Modelo verdadero: } Y_i = \beta_1 + \beta_2 X_{2i} + u_i \quad (1)$$

$$\text{Modelo mal especificado: } Y_i = \alpha_1 + \alpha_2 X_{2i} + \alpha_3 X_{3i} + v_i \quad (2)$$

donde X_3 es una variable **irrelevante** en el sentido de que su verdadero coeficiente poblacional es $\beta_3 = 0$. El modelo (2) incluye esta variable sin que la teoría económica la justifique.

En la taxonomía de Gujarati (sección 13.2), este error corresponde a la **inclusión de una variable irrelevante** o *sobreajuste del modelo*. La comparación con el ejercicio 13.3 es conceptualmente decisiva:

Tipo de error	Consecuencia principal	Ejercicio
Omisión de variable relevante	Sesgo + inconsistencia	13.3
Inclusión de variable irrelevante	Insesgadez + ineficiencia	13.4

2. CONSECUENCIAS TEÓRICAS

2.1. Inciso a) — Comportamiento de R^2 y $\bar{R}^2$

R^2 convencional (no penalizado)

El R^2 del modelo (2) será **mayor o al menos igual** al del modelo (1). Este resultado es un **hecho algebraico**, no estadístico:

$$R^2 = 1 - \frac{SCR}{SCT} = 1 - \frac{\sum \hat{v}_i^2}{\sum (Y_i - \bar{Y})^2} \quad (3)$$

La Suma de Cuadrados de los Residuales ($SCR = \sum \hat{v}_i^2$) **nunca puede aumentar** al añadir un regresor adicional a un modelo MCO, porque el conjunto de parámetros del modelo (1) es un subconjunto de los de (2). En el peor caso, el estimador del nuevo coeficiente puede ser exactamente cero, replicando la SCR original. Formalmente:

$$SCR_{(2)} \leq SCR_{(1)} \implies \boxed{R_{(2)}^2 \geq R_{(1)}^2} \quad (4)$$

Esta propiedad es la razón por la que el R^2 convencional constituye una medida de bondad de ajuste **deficiente** para comparar modelos con distinto número de regresores: siempre premia la inclusión de variables, independientemente de su relevancia teórica o estadística.

R^2 ajustado o corregido ($\bar{R}^2$)

El $\bar{R}^2$ del modelo (2) **probablemente será menor o igual** al del modelo (1). A diferencia del R^2 convencional, el ajustado incorpora una penalización explícita por el número de parámetros estimados:

$$\bar{R}^2 = 1 - \frac{SCR/(n-k)}{SCT/(n-1)} \quad (5)$$

donde k es el número de parámetros (incluyendo el intercepto). Al añadir X_3 , el denominador de $SCR/(n-k)$ disminuye de $n-2$ a $n-3$, lo que tiende a aumentar la

varianza estimada del error aunque SCR se reduzca marginalmente. Puede demostrarse que el $\bar{R}^2$ aumenta si, y solo si, el valor absoluto del estadístico t de la variable añadida supera la unidad:

$$\bar{R}_{(2)}^2 > \bar{R}_{(1)}^2 \iff |t_{\hat{\alpha}_3}| > 1 \quad (6)$$

Dado que el verdadero $\beta_3 = 0$, el estadístico t de $\hat{\alpha}_3$ tenderá a ser pequeño. Por lo tanto:

$$\boxed{\bar{R}_{(2)}^2 \leq \bar{R}_{(1)}^2} \quad (7)$$

Medida	Modelo (1)	Modelo (2)	Relación esperada
R^2	$R_{(1)}^2$	$R_{(2)}^2$	$R_{(2)}^2 \geq R_{(1)}^2$
$\bar{R}^2$	$\bar{R}_{(1)}^2$	$\bar{R}_{(2)}^2$	$\bar{R}_{(2)}^2 \leq \bar{R}_{(1)}^2$

2.2. Inciso b) — Inssegadez y consistencia de los estimadores

Sí: los estimadores MCO del modelo (2) son inssegados y consistentes. Esta es la propiedad central que distingue la sobre-especificación de la sub-especificación.

Demostración algebraica

El estimador MCO del vector de coeficientes en el modelo (2) es:

$$\hat{\alpha} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \quad (8)$$

donde $\mathbf{X} = [\mathbf{1}, \mathbf{X}_2, \mathbf{X}_3]$. Sustituyendo el modelo verdadero $\mathbf{Y} = \beta_1\mathbf{1} + \beta_2\mathbf{X}_2 + \mathbf{u}$:

$$\hat{\alpha} = \beta_1(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{1} + \beta_2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}_2 + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u} \quad (9)$$

Tomando la esperanza y usando el supuesto clásico $E(\mathbf{u} | \mathbf{X}) = \mathbf{0}$:

$$E(\hat{\alpha}) = \beta_1(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{1} + \beta_2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}_2 \quad (10)$$

Nótese que $\mathbf{X}'\mathbf{1}$ y $\mathbf{X}'\mathbf{X}_2$ son, respectivamente, la primera y la segunda columna de $\mathbf{X}'\mathbf{X}$, de modo que:

$$(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{1} = \mathbf{e}_1, \quad (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}_2 = \mathbf{e}_2 \quad (11)$$

donde $\mathbf{e}_j$ denota el j -ésimo vector canónico. Por tanto:

$$E(\hat{\boldsymbol{\alpha}}) = \beta_1\mathbf{e}_1 + \beta_2\mathbf{e}_2 = \begin{pmatrix} \beta_1 \\ \beta_2 \\ 0 \end{pmatrix} \quad (12)$$

Lo que confirma que:

$$\boxed{E(\hat{\alpha}_1) = \beta_1, \quad E(\hat{\alpha}_2) = \beta_2, \quad E(\hat{\alpha}_3) = 0} \quad (13)$$

Los tres estimadores son insesgados: los dos primeros recuperan los verdaderos parámetros del modelo, y el tercero estima correctamente su valor poblacional (que es cero).

Intuición económica

La insesgadez se preserva porque los supuestos del Modelo Clásico de Regresión Lineal (MCRL) se mantienen intactos en el modelo (2). La única violación sería si X_3 estuviese correlacionada con el término de error u_i ; pero como X_3 es exógena y su verdadero coeficiente es simplemente cero (no que la variable “no exista”), la condición de exogeneidad no se viola.

Consistencia

Dado que los estimadores son insesgados y sus varianzas tienden a cero cuando $n \rightarrow \infty$, también son **consistentes**:

$$\hat{\alpha}_j \xrightarrow{p} \beta_j \quad \text{cuando } n \rightarrow \infty \quad (14)$$

A diferencia del Ej. 13.3, donde $E(\hat{\beta}_1) \neq \alpha_1$ de forma sistemática, aquí la insesgadez **se preserva**. Este es el contraste fundamental entre sub-especificación (sesgo) y sobre-especificación (ineficiencia sin sesgo).

2.3. Inciso c) — Efecto sobre las varianzas de $\hat{\beta}_1$ y $\hat{\beta}_2$

Sí: las varianzas en general aumentan. Esta es la consecuencia estadística más importante del sobreajuste.

Demostración general

La matriz de varianzas y covarianzas de los estimadores MCO es:

$$\text{Var}(\hat{\alpha}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (15)$$

Al añadir X_3 , la matriz $\mathbf{X}'\mathbf{X}$ se expande de dimensión 2×2 a 3×3 . En general, los elementos diagonales de $(\mathbf{X}'\mathbf{X})^{-1}$ no pueden disminuir cuando se añaden columnas a $\mathbf{X}$, de modo que:

$$\text{Var}(\hat{\alpha}_j) \geq \text{Var}(\hat{\beta}_j), \quad j = 1, 2 \quad (16)$$

con igualdad únicamente en el caso límite de ortogonalidad perfecta entre X_2 y X_3 .

El Factor de Inflación de la Varianza (VIF)

Para una regresión con dos regresores (X_2 y X_3), la varianza del estimador de la pendiente en el modelo (2) es:

$$\text{Var}(\hat{\alpha}_2) = \frac{\sigma^2}{\sum x_{2i}^2 (1 - r_{23}^2)} = \underbrace{\frac{\sigma^2}{\sum x_{2i}^2}}_{\text{Var}(\hat{\beta}_2)} \cdot \underbrace{\frac{1}{1 - r_{23}^2}}_{\text{VIF}} \quad (17)$$

donde r_{23} es el coeficiente de correlación muestral entre X_2 y X_3 , y $x_{2i} = X_{2i} - \bar{X}_2$. La razón de varianzas define el Factor de Inflación de la Varianza:

$$\boxed{\text{VIF} = \frac{\text{Var}(\hat{\alpha}_2)}{\text{Var}(\hat{\beta}_2)} = \frac{1}{1 - r_{23}^2} \geq 1} \quad (18)$$

El VIF mide cuántas veces se infla la varianza del estimador por efecto de la correlación con el regresor adicional.

Análisis por escenarios de correlación

Correlación r_{23}	r_{23}^2	VIF	Efecto sobre $\text{Var}(\hat{\beta}_2)$
0.000	0.000	1.00	Sin cambio (caso límite de ortogonalidad)
0.300	0.090	1.10	Aumento del 10 %
0.500	0.250	1.33	Aumento del 33 %
0.700	0.490	1.96	Aumento del 96 %
0.900	0.810	5.26	Aumento del 426 %
0.977	0.955	22.01	Aumento del 2101 % (caso empírico)
0.990	0.980	50.25	Aumento del 4925 %

Caso especial: si $r_{23} = 0$ (ortogonalidad perfecta), el $\text{VIF} = 1$ y las varianzas no cambian. En datos económicos reales esta condición prácticamente nunca se satisface.

Consecuencias para la inferencia estadística

Aunque los estimadores siguen siendo insesgados y las pruebas formalmente válidas, la inflación de varianzas tiene efectos directos:

1. **Errores estándar más grandes:** $SE(\hat{\alpha}_j) \geq SE(\hat{\beta}_j)$, lo que produce estadísticos t más pequeños.
2. **Intervalos de confianza más amplios:** el mismo nivel $(1 - \alpha)$ requiere intervalos más anchos, reduciendo la precisión práctica.
3. **Menor potencia de las pruebas:** es más difícil rechazar $H_0 : \beta_j = 0$ aunque sea falsa (mayor probabilidad de Error Tipo II).

4. **Multicolinealidad inducida artificialmente:** si X_3 está correlacionada con X_2 , se introduce un problema de multicolinealidad que no existía en el modelo verdadero.

3. RESUMEN DE CONSECUENCIAS

Propiedad	Modelo (1) (correcto)	Modelo (2) (sobre-especificado)
Insesgadez	Preservada	Preservada
Consistencia	Preservada	Preservada
Eficiencia (MELI)	Óptima (Gauss-Markov)	Reducida: $\text{Var}(\hat{\alpha}) \geq \text{Var}(\hat{\beta})$
Validez t y F	Válidas	Válidas (pero menos potentes)
R^2 convencional	Valor base	Mayor o igual al de (1)
$\bar{R}^2$ ajustado	Valor base	Menor o igual al de (1)
VIF	1 (base)	≥ 1 (se infla según r_{23}^2)
Predicciones	Insesgadas y eficientes	Insesgadas pero menos precisas

4. VERIFICACIÓN EMPÍRICA CON DATOS SIMULADOS

Se generan datos del proceso verdadero $Y_i = 2 + 3X_{2i} + u_i$ ($\beta_1 = 2$, $\beta_2 = 3$, $\beta_3 = 0$, $u_i \sim N(0, 1)$, $n = 200$) y se añaden tres versiones de X_3 con distintos niveles de correlación con X_2 para verificar el efecto VIF empíricamente.

4.1. Código Stata — simulación principal

```

clear
set seed 2026
set obs 200

gen X2 = runiform(1, 10)
gen u = rnormal(0, 1)
gen Y = 2 + 3 * X2 + u

* Variable irrelevante con correlacion baja (~0.03)
gen X3_low = 0.05 * X2 + rnormal(0, 2)

* Variable irrelevante con correlacion moderada (~0.50)
gen X3_mid = 0.50 * X2 + rnormal(0, 1.5)

* Variable irrelevante con correlacion alta (~0.977)
gen X3_hi = 0.90 * X2 + rnormal(0, 0.5)

* ---- Modelo (1): correcto ----
quietly regress Y X2
scalar b2_correct = _b[X2]
scalar se_b2 = _se[X2]
scalar var_b2 = se_b2^2

* ---- Modelos (2a), (2b), (2c): sobre-especificados ----
quietly regress Y X2 X3_low
quietly regress Y X2 X3_mid
quietly regress Y X2 X3_hi

* ---- Tabla comparativa ----
quietly regress Y X2
estimates store m_correcto
quietly regress Y X2 X3_low
estimates store m_bajo
quietly regress Y X2 X3_mid
estimates store m_medio
quietly regress Y X2 X3_hi
estimates store m_alto

estimates table m_correcto m_bajo m_medio m_alto, ///
    b(%9.4f) se stats(N r2 r2_a)

```

Listing 1: Simulación: modelo correcto vs. modelos sobre-especificados

4.2. Resultados — modelo correcto

Variable	Coefficiente	Error est.	Razón t	$P(> t)$
X_{2i}	2.9797	0.0276	107.96	0.000
Constante	2.0436	0.1657	12.33	0.000
$R^2 = 0,9833 \quad \bar{R}^2 = 0,9832 \quad n = 200$				

4.3. Resultados — tabla comparativa de los cuatro modelos

Variable	(1) Correcto	(2a) $r_{23} \approx 0,03$	(2b) $r_{23} \approx 0,50$	(2c) $r_{23} \approx 0,977$
X_2 (coef.)	2.9797	2.9795	2.9858	2.8618
X_2 (SE)	0.0276	0.0274	0.0392	0.1330
$X_{3,\text{low}}$		-0,0809		
(SE)		0.0395		
$X_{3,\text{mid}}$			-0,0110	
(SE)			0.0496	
$X_{3,\text{hi}}$				0.1296
(SE)				0.1431
Constante	2.0436	2.0731	2.0399	2.0542
(SE)	0.1657	0.1650	0.1670	0.1662
n	200	200	200	200
R^2	0.9833	0.9837	0.9833	0.9834
$\bar{R}^2$	0.9832	0.9835	0.9831	0.9832
VIF empírico	1.00	0.98	2.02	23.23

5. VERIFICACIÓN ALGEBRAICA DEL VIF

5.1. Código Stata

```
clear
set seed 2026
set obs 200

gen X2      = runiform(1, 10)
gen X3_hi   = 0.90 * X2 + rnormal(0, 0.5)
gen u       = rnormal(0, 1)
gen Y       = 2 + 3 * X2 + u

* Correlacion muestral entre X2 y X3_hi
correlate X2 X3_hi
scalar r23      = r(rho)
scalar vif_teo  = 1 / (1 - r23^2)

* Varianzas empiricas de la pendiente
quietly regress Y X2
scalar var_b2   = _se[X2]^2

quietly regress Y X2 X3_hi
scalar var_a2   = _se[X2]^2
scalar vif_emp  = var_a2 / var_b2

di "Correlacion r(X2,X3):"          " r23
di "r23^2:"                        " r23^2
di "VIF teorico = 1/(1-r23^2):"     " vif_teo
di "Var(beta_2) modelo correcto:"  " var_b2
di "Var(alpha_2) modelo ampliado:" " var_a2
di "VIF empirico (var_a2/var_b2):" " vif_emp
di "Diferencia (emp - teo):"       " vif_emp - vif_teo
```

Listing 2: Verificación: VIF teórico vs. VIF empírico

5.2. Resultados

Cantidad	Valor
Correlación r_{23} entre X_2 y $X_{3,hi}$	0.9770
r_{23}^2	0.9546
VIF teórico = $1/(1 - r_{23}^2)$	22.0074
$\text{Var}(\hat{\beta}_2)$ modelo correcto (1)	0.000608
$\text{Var}(\hat{\alpha}_2)$ modelo ampliado (2)	0.013157
VIF empírico = $\text{Var}(\hat{\alpha}_2)/\text{Var}(\hat{\beta}_2)$	21.6570
Diferencia (empírico – teórico)	−0,3504

El VIF empírico (21,66) replica con alta precisión el VIF teórico (22,01), con una diferencia de apenas −0,35. Esto confirma que la fórmula $\text{VIF} = 1/(1 - r_{23}^2)$ describe correctamente la inflación de varianzas producida por la variable irrelevante.

6. DIAGNÓSTICO EMPÍRICO RECOMENDADO

En la práctica, para detectar si una variable incluida es irrelevante se recurre a las siguientes herramientas:

6.1. Código Stata

```
clear
set seed 2026
set obs 200
gen X2      = runiform(1, 10)
gen u       = rnormal(0, 1)
gen Y       = 2 + 3 * X2 + u
gen X3_low  = 0.05 * X2 + rnormal(0, 2)

quietly regress Y X2 X3_low
```

```

* 1. Factor de Inflacion de la Varianza
*   VIF > 10 se considera multicolinealidad severa
estat vif

* 2. Prueba F parcial: H0: alpha_3 = 0
*   Si no se rechaza, X3_low no aporta poder explicativo real
test X3_low

* 3. Criterios de informacion (AIC, BIC): menor valor = modelo
    preferido
quietly regress Y X2
estat ic

quietly regress Y X2 X3_low
estat ic

```

Listing 3: Diagnóstico: VIF, prueba F parcial y criterios de información

6.2. Resultados

Factor de Inflación de la Varianza

Variable	VIF	1/VIF
-----+-----		
X2	1.00	0.999995
X3_low	1.00	0.999995
-----+-----		
Mean VIF	1.00	

Con $X_{3,\text{low}}$ prácticamente ortogonal a X_2 , el VIF es 1.00, confirmando que no hay inflación de varianzas en este escenario particular.

Prueba F parcial sobre $\hat{\alpha}_3$

```

( 1)  X3_low = 0

      F( 1, 197) =    4.20
      Prob > F =    0.0417

```

El estadístico $F = 4,20$ con $p = 0,042$ rechaza $H_0 : \alpha_3 = 0$ a un nivel del 5 %, lo que ilustra que incluso una variable irrelevante puede parecer significativa por azar en

una muestra particular. El resultado es consistente con $|t| = \sqrt{4,20} \approx 2,05 > 1$, que explica el leve aumento de $\bar{R}^2$ observado en el escenario de baja correlación.

Criterios de información AIC y BIC

Modelo	n	$\ell(\text{nulo})$	$\ell(\text{modelo})$	k	AIC	BIC
Correcto: $Y = \beta_1 + \beta_2 X_2 + u$	200	-696,47	-287,22	2	578.45	585.04
Ampliado: $Y = \alpha_1 + \alpha_2 X_2 + \alpha_3 X_{3,\text{low}} + v$	200	-696,47	-285,11	3	576.23	586.12

El AIC favorece marginalmente al modelo ampliado ($576,23 < 578,45$), mientras que el BIC favorece al modelo correcto ($585,04 < 586,12$). El BIC penaliza más severamente los parámetros adicionales y, en este caso, identifica correctamente al modelo parsimonioso. Cuando AIC y BIC discrepan, la literatura recomienda preferir el BIC en muestras medianas a grandes.

7. INTERPRETACIÓN INTEGRADA DE LOS RESULTADOS

Los resultados de Stata confirman con precisión las predicciones teóricas:

Sobre la insesgadez (inciso b). En los cuatro modelos estimados, la pendiente oscila entre 2,8618 y 2,9858, convergiendo al verdadero valor $\beta_2 = 3$ con independencia de la correlación que X_3 tenga con X_2 . El intercepto ronda 2,04–2,07 en todos los casos, próximo al verdadero $\beta_1 = 2$. Los coeficientes de la variable irrelevante son pequeños: $-0,0809$ (SE = 0,0395), $-0,0110$ (SE = 0,0496) y $0,1296$ (SE = 0,1431), sin evidencia sólida de efecto sistemático en los tres primeros escenarios.

Sobre las varianzas (inciso c). La inflación de varianzas sigue el patrón del VIF. Con correlación baja ($r_{23} \approx 0,03$), el VIF empírico es $0,98 \approx 1$ y los errores estándar permanecen prácticamente idénticos (0,0274 vs. 0,0276). Con correlación moderada ($r_{23} \approx 0,50$), el VIF sube a 2,02 y el SE se amplía un 42 % (de 0,0276 a 0,0392). Con correlación alta ($r_{23} = 0,977$), el VIF empírico alcanza 23,23 frente al teórico de 22,01 (diferencia de $-0,35$), y el SE se dispara de 0,0276 a 0,1330, un incremento del 382 %.

Sobre R^2 y $\bar{R}^2$ (inciso a). El R^2 convencional crece marginalmente al añadir X_3 en todos los casos (de 0,9833 a valores entre 0,9833 y 0,9837). El $\bar{R}^2$, en cambio, cae en los escenarios de correlación moderada y alta (de 0,9832 a 0,9831), y sube levemente en el caso de baja correlación (a 0,9835) porque el $|t|$ de X_3 supera marginalmente la unidad en esa muestra particular. Esto ilustra que $\bar{R}^2$ no es una garantía mecánica de caída, sino que depende del estadístico t realizado.

8. SÍNTESIS: CONEXIÓN CON LOS EJERCICIOS ANTERIORES

Ej.	Error de especificación	Insesgadez	Eficiencia	Validez de inferencia
13.2	Intercepto innecesario incluido	Preservada	Reducida	Válida (menos potente)
13.3	Intercepto relevante omitido	Perdida	N/A (hay sesgo)	Inválida
13.4	Variable irrelevante X_3 incluida	Preservada	Reducida (VIF)	Válida (menos potente)

Los ejercicios 13.2 y 13.4 son cualitativamente análogos (sobre-especificación): en ambos se preserva la insesgadez pero se pierde eficiencia. La diferencia cuantitativa es que en 13.2 el coste es un único grado de libertad desperdiciado (el intercepto), mientras que en 13.4 el daño depende crucialmente de r_{23} : puede ser despreciable si $X_3 \perp X_2$ o catastrófico si $r_{23} \approx 1$.

9. CONCLUSIÓN

La inclusión de una variable irrelevante en un modelo de regresión múltiple tiene consecuencias asimétricas y bien definidas:

1. **No introduce sesgo:** los estimadores MCO de β_1 y β_2 mantienen su insesgadez y consistencia. En promedio, el modelo sobreajustado recupera los parámetros correctos.
2. **Sí produce ineficiencia:** las varianzas se inflan por un factor $1/(1 - r_{23}^2)$. Con $r_{23} = 0,977$, como en la simulación, la varianza se multiplica por 22 y el error estándar crece más de cuatro veces.
3. **El R^2 convencional es engañoso:** siempre aumenta o permanece igual al añadir variables. El $\bar{R}^2$ ajustado corrige este sesgo y en general cae cuando $|t_{\hat{\alpha}_3}| < 1$.
4. **La inferencia sigue siendo formalmente válida,** pero es menos potente: los intervalos de confianza son innecesariamente amplios y las pruebas de hipótesis tienen menor capacidad para detectar efectos reales.

La regla práctica de Gujarati queda completamente justificada: el costo de incluir una variable irrelevante es solo ineficiencia, mitigable con muestras más grandes; el costo de omitir una variable relevante es sesgo sistemático que no desaparece con $n \rightarrow \infty$. No obstante, incluir variables irrelevantes con alta correlación con los regresores del modelo verdadero puede tornar indetectables efectos reales, lo que también es problemático en la práctica econométrica.

Nota metodológica. La asimetría entre sobre-especificación y sub-especificación tiene implicaciones directas para la estrategia de modelación econométrica. La *regla general* es partir del modelo más general y reducirlo solo si la teoría económica y las pruebas estadísticas lo justifican conjuntamente. Mientras que eliminar variables por parsimonia sin respaldo teórico introduce el sesgo documentado en el ejercicio 13.3, mantener variables claramente irrelevantes con alta multicolinealidad puede producir precisión tan baja que la inferencia carezca de valor práctico. El equilibrio correcto exige teoría económica sólida como primer criterio, seguido del diagnóstico estadístico como herramienta auxiliar.

REFERENCIAS

Gujarati, D. N., & Porter, D. C. (2010). *Econometría* (5.a ed.). McGraw-Hill. Capítulo 13, secciones 13.2 y 13.3.

Greene, W. H. (2018). *Econometric Analysis* (8.a ed.). Pearson. Capítulo 5.

Wooldridge, J. M. (2016). *Introductory Econometrics* (6.a ed.). Cengage. Capítulo 3.