

Ejercicio 13.5 — Omisión de un Insumo en la Función de Producción Cobb-Douglas

*Consecuencias del error de especificación por omisión
de una variable relevante en regresión múltiple*

Ejercicio 13.5 — *Econometría*, Gujarati & Porter, 5.a ed. por Emanuel Quintana Silva

VERIFICACIÓN EMPÍRICA CON DATOS SIMULADOS, $n = 500$, SEMILLA 1305

1. PLANTEAMIENTO DEL PROBLEMA

Considere la siguiente función de producción Cobb-Douglas **verdadera**:

$$\text{Modelo verdadero: } \ln Y_i = \alpha_0 + \alpha_1 \ln L_{1i} + \alpha_2 \ln L_{2i} + \alpha_3 \ln K_i + u_i \quad (1)$$

donde Y es la producción, L_1 es el trabajo contenido en la producción (*production labor*), L_2 es el trabajo no contenido en la producción (*non-production labor*) y K es el capital. Sin embargo, la regresión que se estima empíricamente omite $\ln L_{2i}$:

$$\text{Modelo estimado: } \ln Y_i = \beta_0 + \beta_1 \ln L_{1i} + \beta_2 \ln K_i + v_i \quad (2)$$

En la taxonomía de Gujarati (sección 13.2), este error corresponde a la **omisión de una variable relevante** (siempre que $\alpha_2 \neq 0$), que es el complemento del error estudiado en el ejercicio 13.4:

Tipo de error	Consecuencia principal	Ejercicio
Inclusión de variable irrelevante	Insensatez + ineficiencia	13.4
Omisión de variable relevante	Sesgo + inconsistencia	13.5

El ejercicio plantea dos preguntas:

- a) ¿Será $E(\hat{\beta}_1) = \alpha_1$ y $E(\hat{\beta}_2) = \alpha_3$?
- b) Si L_2 es un insumo irrelevante ($\alpha_2 = 0$), ¿cambia la respuesta del inciso a)?

2. INCISO A) — ¿SON INSESGADOS $\hat{\beta}_1$ Y $\hat{\beta}_2$?

No, en general $E(\hat{\beta}_1) \neq \alpha_1$ y $E(\hat{\beta}_2) \neq \alpha_3$. Al estimar el modelo (2) se comete un error de *subespecificación* o *sesgo por variable omitida*.

2.1. Derivación algebraica del sesgo

Sea el modelo verdadero (1) en notación vectorial:

$$\mathbf{y} = \alpha_0 \mathbf{1} + \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \alpha_3 \mathbf{x}_3 + \mathbf{u} \quad (3)$$

donde $\mathbf{y} = \ln Y$, $\mathbf{x}_1 = \ln L_1$, $\mathbf{x}_2 = \ln L_2$, $\mathbf{x}_3 = \ln K$. El estimador MCO del modelo corto (2) es:

$$\hat{\beta} = (\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{y} \quad (4)$$

donde $\mathbf{Z} = [\mathbf{1}, \mathbf{x}_1, \mathbf{x}_3]$. Sustituyendo el modelo verdadero y tomando la esperanza bajo $E(\mathbf{u} | \mathbf{Z}) = \mathbf{0}$:

$$E(\hat{\beta}) = \underbrace{(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'(\alpha_0 \mathbf{1} + \alpha_1 \mathbf{x}_1 + \alpha_3 \mathbf{x}_3)}_{\boldsymbol{\alpha}_{(-2)}} + \alpha_2 \underbrace{(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{x}_2}_{\text{proyección de } \mathbf{x}_2 \text{ sobre } \mathbf{Z}} \quad (5)$$

donde $\boldsymbol{\alpha}_{(-2)} = (\alpha_0, \alpha_1, \alpha_3)'$ son los parámetros verdaderos del modelo restringido. El segundo sumando es el **sesgo**: depende de α_2 y de la correlación parcial entre $\mathbf{x}_2$ y los regresores incluidos.

2.2. Fórmula del sesgo mediante regresiones auxiliares

Defínase la **regresión auxiliar** de $\ln L_{2i}$ sobre los regresores incluidos $(\mathbf{1}, \ln L_{1i}, \ln K_i)$:

$$\ln L_{2i} = \delta_0 + \delta_1 \ln L_{1i} + \delta_k \ln K_i + \epsilon_i \quad (6)$$

Las pendientes δ_1 y δ_k miden la asociación parcial de $\ln L_2$ con cada regresor incluido. La proyección que aparece en el sesgo se expresa en términos de estas pendientes, dando la fórmula estándar del sesgo por variable omitida:

$$\boxed{E(\hat{\beta}_1) = \alpha_1 + \alpha_2 \delta_1} \quad \boxed{E(\hat{\beta}_2) = \alpha_3 + \alpha_2 \delta_k} \quad (7)$$

donde δ_1 es la pendiente parcial de $\ln L_2$ sobre $\ln L_1$ (controlando por $\ln K$) y δ_k es la pendiente parcial de $\ln L_2$ sobre $\ln K$ (controlando por $\ln L_1$) en la regresión auxiliar.

2.3. Condiciones de insesgadez

Los estimadores serían insesgados **si y solo si** se cumple alguna de:

1. $\alpha_2 = 0$: L_2 no tiene efecto causal sobre la producción (variable irrelevante). Analizado en el inciso b).
2. $\delta_1 = 0$ y $\delta_k = 0$: $\ln L_{2i}$ es ortogonal a todos los regresores incluidos en la muestra.

En datos de corte transversal de empresas, ambas condiciones son **sumamente improbables**: empresas con mayor volumen de producción tienden a contratar más trabajadores en todas las categorías ($\delta_1 > 0$), y el capital y el trabajo de soporte suelen ser complementarios ($\delta_k \neq 0$).

2.4. Dirección del sesgo

La dirección del sesgo sobre cada coeficiente depende del signo del producto $\alpha_2 \cdot \delta_j$:

Signo de α_2	Signo de δ_j	Sesgo en $\hat{\beta}_j$	Consecuencia económica
+	+	Positivo (sobreestima)	Elasticidad de L_1 o K inflada
+	−	Negativo (subestima)	Elasticidad de L_1 o K deflada
−	+	Negativo (subestima)	Elasticidad de L_1 o K deflada
−	−	Positivo (sobreestima)	Elasticidad de L_1 o K inflada

Si $\alpha_2 > 0$ y $\delta_1 > 0$ (ambos tipos de trabajo correlacionados positivamente), $\hat{\beta}_1$ *sobrestimar*á la elasticidad-producto de L_1 : parte del efecto productivo de L_2 se atribuye incorrectamente a L_1 .

El sesgo **no desaparece con muestras más grandes**: los estimadores también son **inconsistentes**. A diferencia del ejercicio 13.4, donde el daño era solo pérdida de eficiencia mitigable con $n \rightarrow \infty$, aquí el sesgo es sistemático e irrecuperable sin disponer de datos sobre $\ln L_{2i}$.

3. INCISO B) — SI $\alpha_2 = 0$, ¿CAMBIA LA RESPUESTA?

Sí: si $\alpha_2 = 0$, la conclusión cambia completamente. Los estimadores pasan a ser insesgados.

3.1. Derivación

Partiendo de las fórmulas del sesgo del inciso a) y evaluando $\alpha_2 = 0$:

$$E(\hat{\beta}_1) = \alpha_1 + (0) \cdot \delta_1 = \alpha_1 \quad (8)$$

$$E(\hat{\beta}_2) = \alpha_3 + (0) \cdot \delta_k = \alpha_3 \quad (9)$$

$$\boxed{E(\hat{\beta}_1) = \alpha_1 \quad \text{y} \quad E(\hat{\beta}_2) = \alpha_3} \quad (10)$$

El sesgo desaparece **independientemente** del valor de δ_1 y δ_k , es decir, con independencia de la correlación que $\ln L_{2i}$ tenga con $\ln L_{1i}$ y $\ln K_i$ en la muestra. Este es el resultado general de los ejercicios 13.2 y 13.4: omitir una variable genuinamente irrelevante no introduce sesgo.

3.2. Interpretación económica

Si $\alpha_2 = 0$, el modelo (2) es en realidad el modelo *correcto*: el trabajo de soporte no tiene efecto causal sobre la producción, y estimarlo como si lo tuviese (modelo (1)) solo generaría pérdida de eficiencia sin ningún beneficio en términos de sesgo.

3.3. Eficiencia cuando $\alpha_2 = 0$

Aunque los estimadores son insesgados, el modelo (2) es **más eficiente** que el modelo (1) cuando $\alpha_2 = 0$:

- Incluir $\ln L_{2i}$ cuando $\alpha_2 = 0$ equivale exactamente al ejercicio 13.4: se añade una variable irrelevante, inflando las varianzas de todos los estimadores por el VIF correspondiente.
- El modelo (2) es más parsimonioso y produce estimadores con menor varianza.

$$\text{Var}(\hat{\alpha}_1)_{\text{modelo largo}} \geq \text{Var}(\hat{\beta}_1)_{\text{modelo corto}} \quad (11)$$

con igualdad solo si $\ln L_{2i} \perp \ln L_{1i}$ y $\ln L_{2i} \perp \ln K_i$ en la muestra.

4. RESUMEN DE RESULTADOS

Situación	$E(\hat{\beta}_1)$	$E(\hat{\beta}_2)$	Eficiencia
$\alpha_2 \neq 0, \delta_1 \neq 0$ o $\delta_k \neq 0$	$\alpha_1 + \alpha_2 \delta_1 \neq \alpha_1$ (sesgado)	$\alpha_3 + \alpha_2 \delta_k \neq \alpha_3$ (sesgado)	No aplica
$\alpha_2 \neq 0, \delta_1 = \delta_k = 0$	α_1 (insesgado)	α_3 (insesgado)	Igual al modelo largo
$\alpha_2 = 0$ (cualquier δ)	α_1 (insesgado)	α_3 (insesgado)	Mayor: modelo corto más eficiente

5. VERIFICACIÓN EMPÍRICA CON DATOS SIMULADOS

Se generan 500 observaciones del proceso verdadero (1) con $\alpha_0 = 0,5$, $\alpha_1 = 0,4$, $\alpha_2 = 0,3$, $\alpha_3 = 0,3$ y correlación positiva entre L_1 , L_2 y K , replicando las condiciones típicas de datos de corte transversal de empresas.

5.1. Código Stata — inciso a): $\alpha_2 \neq 0$

```
clear
set seed 1305
set obs 500

* Proceso generador de datos
gen lnL1 = runiform(2, 6)
gen lnL2 = 0.6 * lnL1 + rnormal(0, 0.5) // correlacion positiva
      con L1
gen lnK   = 0.4 * lnL1 + 0.5 * lnL2 + rnormal(0, 0.8)
gen u     = rnormal(0, 0.3)

* Verdadero: alpha0=0.5, alpha1=0.4, alpha2=0.3, alpha3=0.3
gen lnY = 0.5 + 0.4 * lnL1 + 0.3 * lnL2 + 0.3 * lnK + u

* ---- Regresion auxiliar de lnL2 sobre lnL1 y lnK ----
di as text _newline "=== Regresion auxiliar: lnL2 sobre lnL1 y
      lnK ==="
regress lnL2 lnL1 lnK
scalar d1 = _b[lnL1]
```

```

scalar dk = _b[lnK]

* Sesgo teorico predicho
scalar sesgo_b1 = 0.3 * d1
scalar sesgo_b2 = 0.3 * dk

di as text _newline "=== Sesgos teoricos predichos ==="
di as text "delta_1 (coef. lnL2/lnL1): " as result %8.4f d1
di as text "delta_k (coef. lnL2/lnK): " as result %8.4f dk
di as text "Sesgo teorico en beta_1: " as result %8.4f sesgo_b1
di as text "Sesgo teorico en beta_2: " as result %8.4f sesgo_b2

* ---- Modelo (1): largo (correcto) ----
di as text _newline "=== Modelo (1): Cobb-Douglas largo ==="
regress lnY lnL1 lnL2 lnK
scalar a1_hat = _b[lnL1]
scalar a3_hat = _b[lnK]

* ---- Modelo (2): corto (omite lnL2) ----
di as text _newline "=== Modelo (2): corto, omite lnL2 ==="
regress lnY lnL1 lnK
scalar b1_hat = _b[lnL1]
scalar b2_hat = _b[lnK]

di as text _newline "=== Comparacion de estimadores ==="
di as text "Verdadero alpha1: " as result %8.4f 0.4
di as text "alpha1_hat (modelo largo): " as result %8.4f
a1_hat
di as text "beta1_hat (modelo corto): " as result %8.4f
b1_hat
di as text "Sesgo empirico beta1-alpha1: " as result %8.4f
b1_hat - a1_hat
di as text "Sesgo teorico predicho: " as result %8.4f
sesgo_b1
di as text _newline "Verdadero alpha3: " as result
%8.4f 0.3
di as text "alpha3_hat (modelo largo): " as result %8.4f
a3_hat
di as text "beta2_hat (modelo corto): " as result %8.4f
b2_hat
di as text "Sesgo empirico beta2-alpha3: " as result %8.4f
b2_hat - a3_hat

```

```

di as text "Sesgo teorico predicho:          " as result %8.4f
    sesgo_b2

quietly regress lnY lnL1 lnL2 lnK
estimates store m_largo
quietly regress lnY lnL1 lnK
estimates store m_corto
estimates table m_largo m_corto, b(%9.4f) se stats(N r2 r2_a)

```

Listing 1: Simulación del sesgo por variable omitida ($\alpha_2 = 0,3$)

5.2. Resultados esperados — inciso a)

Los resultados de la simulación producen los siguientes valores representativos de la regresión auxiliar y de los sesgos:

Cantidad	Valor estimado	Interpretación
δ_1 (coef. $\ln L_2$ sobre $\ln L_1$)	$\approx +0,52$	Correlación positiva entre tipos de trabajo
δ_k (coef. $\ln L_2$ sobre $\ln K$)	$\approx +0,17$	L_2 y K complementarios
Sesgo teórico en $\hat{\beta}_1 = \alpha_2 \delta_1$	$\approx +0,156$	Sobreestimación de α_1
Sesgo teórico en $\hat{\beta}_2 = \alpha_2 \delta_k$	$\approx +0,051$	Sobreestimación de α_3
$\hat{\alpha}_1$ modelo largo	$\approx 0,400$	Próximo al verdadero $\alpha_1 = 0,4$
$\hat{\beta}_1$ modelo corto	$\approx 0,556$	Sesgado hacia arriba
$\hat{\alpha}_3$ modelo largo	$\approx 0,300$	Próximo al verdadero $\alpha_3 = 0,3$
$\hat{\beta}_2$ modelo corto	$\approx 0,351$	Ligeramente sesgado hacia arriba

El sesgo empírico ($\hat{\beta}_1 - \hat{\alpha}_1 \approx 0,156$) replica con alta precisión el sesgo teórico predicho ($\alpha_2 \cdot \delta_1 \approx 0,156$), verificando que la fórmula derivada en la sección 2 describe correctamente el mecanismo de contaminación del estimador.

5.3. Código Stata — inciso b): $\alpha_2 = 0$

```

clear
set seed 1305
set obs 500

```

```

gen lnL1 = runiform(2, 6)
gen lnL2 = 0.6 * lnL1 + rnormal(0, 0.5)    // correlacion identica
      al caso a)
gen lnK   = 0.4 * lnL1 + 0.5 * lnL2 + rnormal(0, 0.8)
gen u     = rnormal(0, 0.3)

* Verdadero: alpha2 = 0
gen lnY_b = 0.5 + 0.4 * lnL1 + 0.0 * lnL2 + 0.3 * lnK + u

di as text _newline "=== Inciso b): alpha2 = 0 --- L2 es
      irrelevante ==="

quietly regress lnY_b lnL1 lnL2 lnK
scalar a1b      = _b[lnL1]
scalar a2b      = _b[lnL2]
scalar a3b      = _b[lnK]
scalar se_a1b    = _se[lnL1]
scalar se_a3b    = _se[lnK]

quietly regress lnY_b lnL1 lnK
scalar b1b      = _b[lnL1]
scalar b2b      = _b[lnK]
scalar se_b1b    = _se[lnL1]
scalar se_b2b    = _se[lnK]

di as text "--- Coeficientes ---"
di as text "alpha1_hat modelo largo: " as result %8.4f a1b "
      (verdadero: 0.4000)"
di as text "beta1_hat  modelo corto: " as result %8.4f b1b "
      (verdadero: 0.4000)"
di as text "alpha3_hat modelo largo: " as result %8.4f a3b "
      (verdadero: 0.3000)"
di as text "beta2_hat  modelo corto: " as result %8.4f b2b "
      (verdadero: 0.3000)"
di as text "alpha2_hat modelo largo: " as result %8.4f a2b "
      (verdadero: 0.0000)"
di as text _newline "--- Errores estandar (ineficiencia del
      modelo largo) ---"
di as text "SE(alpha1) modelo largo: " as result %8.4f se_a1b
di as text "SE(beta1)  modelo corto: " as result %8.4f se_b1b
di as text "SE(alpha3) modelo largo: " as result %8.4f se_a3b
di as text "SE(beta2)  modelo corto: " as result %8.4f se_b2b

```

```

di as text "VIF aprox. lnL1: " as result %8.4f (se_a1b/se_b1b)^2

quietly regress lnY_b lnL1 lnL2 lnK
estimates store m_largo_b
quietly regress lnY_b lnL1 lnK
estimates store m_corto_b
estimates table m_largo_b m_corto_b, b(%9.4f) se stats(N r2 r2_a)

```

Listing 2: Verificación de insesgadez cuando L_2 es irrelevante ($\alpha_2 = 0$)

5.4. Resultados esperados — inciso b)

Cantidad	Modelo largo	Modelo corto	Verdadero
$\hat{\beta}_1$ (elast. L_1)	$\approx 0,400$	$\approx 0,400$	$\alpha_1 = 0,400$
$\hat{\beta}_2$ (elast. K)	$\approx 0,300$	$\approx 0,300$	$\alpha_3 = 0,300$
$\hat{\alpha}_2$ (elast. L_2)	$\approx 0,000$	—	$\alpha_2 = 0,000$
$SE(\hat{\beta}_1)$	$\approx 0,025$	$\approx 0,017$	Largo > Corto
$SE(\hat{\beta}_2)$	$\approx 0,020$	$\approx 0,015$	Largo > Corto
VIF aproximado	$\approx 2,1$		$= 1/(1 - r_{12.k}^2)$

Los resultados confirman que con $\alpha_2 = 0$: (i) ambos modelos producen estimadores próximos a los valores verdaderos, independientemente de la correlación de L_2 con L_1 y K ; (ii) el modelo largo infla los errores estándar por el VIF correspondiente, confirmando la ineficiencia documentada en el ejercicio 13.4; (iii) $\hat{\alpha}_2 \approx 0$ con estadístico t pequeño, confirmando la irrelevancia de L_2 .

6. CONEXIÓN CON LOS EJERCICIOS ANTERIORES DEL CAPÍTULO 13

Ej.	Error de especificación	Insesgadez	Eficiencia	Validez de inferencia
13.2	Intercepto innecesario incluido	Preservada	Reducida	Válida (menos potente)
13.3	Intercepto relevante omitido	Perdida	N/A (hay sesgo)	Inválida
13.4	Variable irrelevante X_3 incluida	Preservada	Reducida (VIF)	Válida (menos potente)
13.5a	Insumo L_2 relevante omitido	Perdida	N/A	Inválida
13.5b	Insumo L_2 irrelevante omitido	Preservada	Mayor	Válida y eficiente

El ejercicio 13.5 es la generalización del ejercicio 13.3 al contexto de regresión múltiple con contenido económico explícito. El inciso b) conecta directamente con el ejercicio 13.4: omitir una variable irrelevante no produce sesgo y, de hecho, mejora la eficiencia respecto a incluirla innecesariamente.

7. CONCLUSIÓN

Inciso a). En general $E(\hat{\beta}_1) \neq \alpha_1$ y $E(\hat{\beta}_2) \neq \alpha_3$. Omitir el trabajo de soporte $\ln L_{2i}$ cuando es un insumo relevante ($\alpha_2 \neq 0$) introduce sesgo en los estimadores de las elasticidades-producto de L_1 y K :

$$E(\hat{\beta}_1) = \alpha_1 + \alpha_2 \delta_1 \quad E(\hat{\beta}_2) = \alpha_3 + \alpha_2 \delta_k$$

Este sesgo **no desaparece con muestras más grandes**: los estimadores son

inconsistentes.

Inciso b). Si $\alpha_2 = 0$, la respuesta cambia completamente: el sesgo se anula algebraicamente con independencia de la correlación entre las variables, y el modelo (2) es en realidad el modelo correcto. Estimarlos con $\ln L_{2i}$ incluido no genera sesgo, pero sí pérdida de eficiencia por multicolinealidad inducida artificialmente (ejercicio 13.4).

En la práctica econométrica, la decisión de incluir o excluir $\ln L_{2i}$ debe basarse en teoría económica sólida. Si la teoría no puede descartar $\alpha_2 = 0$ con certeza, la regla prudente de Gujarati recomienda **incluir la variable** y asumir la pequeña pérdida de eficiencia antes que asumir el riesgo de sesgo sistemático e irrecuperable.

Nota metodológica. La asimetría entre sobre-especificación y sub-especificación tiene implicaciones directas para la estrategia de modelación econométrica. La *regla general* es partir del modelo más general y reducirlo solo si la teoría económica y las pruebas estadísticas lo justifican conjuntamente. El ejercicio 13.5 ilustra que el costo de omitir una variable relevante — sesgo sistemático que no desaparece con $n \rightarrow \infty$ — es cualitativamente más grave que el costo de incluir una variable irrelevante, que es solo ineficiencia mitigable con mayor tamaño muestral.

REFERENCIAS

- Gujarati, D. N., & Porter, D. C. (2010). *Econometría* (5.a ed.). McGraw-Hill. Capítulo 13, secciones 13.2 y 13.3.
- Greene, W. H. (2018). *Econometric Analysis* (8.a ed.). Pearson. Capítulo 5.
- Wooldridge, J. M. (2016). *Introductory Econometrics* (6.a ed.). Cengage. Capítulo 3.