

Sesgo por Variable Omitida en el Intercepto

Demostración de $E(\hat{\alpha}_1) = \beta_1 + \beta_3(\bar{X}_3 - b_{32}\bar{X}_2)$

*Especificación incorrecta por omisión de una variable relevante:
efecto sobre el estimador MCO del intercepto*

Ejercicio 13.12 — *Econometría*, Gujarati & Porter, 5.a ed.

DEMOSTRACIÓN CONCEPTUAL, TEÓRICA Y ALGEBRAICA

1. MARCO TEÓRICO Y PLANTEAMIENTO

El ejercicio estudia las consecuencias de **omitir una variable relevante** sobre las propiedades del estimador MCO del intercepto. Si bien el sesgo del coeficiente de pendiente es el resultado más conocido en la literatura sobre errores de especificación, el intercepto también resulta afectado de manera sistemática.

1.1. Modelo verdadero (PRF)

Supóngase que el proceso generador de datos verdadero es el modelo de regresión múltiple:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i, \quad i = 1, \dots, n, \quad (1)$$

donde u_i satisface las propiedades clásicas: $E[u_i] = 0$, $\text{Var}(u_i) = \sigma^2$, y los regresores son fijos (no estocásticos) en muestreos repetidos. Los parámetros β_2 y β_3 son *ambos distintos de cero*, por lo que X_{3i} es una **variable relevante**.

1.2. Modelo estimado (SRF) con variable omitida

En la práctica, el investigador omite X_3 y estima en su lugar el modelo restringido:

$$Y_i = \alpha_1 + \alpha_2 X_{2i} + v_i, \quad (2)$$

donde el error compuesto v_i recoge tanto la perturbación original como la influencia de la variable excluida:

$$v_i = \beta_3 X_{3i} + u_i.$$

Conceptualmente, $\hat{\alpha}_1$ y $\hat{\alpha}_2$ ya no son estimadores del verdadero β_1 y β_2 , pues el supuesto de exogeneidad $E[v_i | X_{2i}] = 0$ se viola siempre que X_{3i} esté correlacionada con X_{2i} .

2. RESULTADO AUXILIAR: SESGO DEL COEFICIENTE DE PENDIENTE (EC. 13.3.3)

Antes de demostrar el resultado pedido, se recuerda el sesgo del estimador de la pendiente, derivado en la ecuación (13.3.3) del texto:

$$E(\hat{\alpha}_2) = \beta_2 + \beta_3 b_{32}, \quad (3)$$

donde b_{32} es el coeficiente de pendiente de la **regresión auxiliar** de la variable omitida X_3 sobre la variable incluida X_2 :

$$X_{3i} = a + b_{32} X_{2i} + \text{residuo}. \quad (4)$$

El término b_{32} captura la relación lineal entre X_3 y X_2 ; si las dos variables son ortogonales, $b_{32} = 0$ y el sesgo en $\hat{\alpha}_2$ desaparece. Este resultado auxiliar se utilizará en el Paso 4 de la demostración principal.

3. DEMOSTRACIÓN: $E(\hat{\alpha}_1) = \beta_1 + \beta_3(\bar{X}_3 - b_{32}\bar{X}_2)$

La demostración se desarrolla en cinco pasos secuenciales.

3.1. Paso 1 — Expresión del estimador MCO del intercepto

En cualquier regresión simple de la forma (2), el estimador MCO del intercepto se obtiene de la condición de primer orden que impone que la recta de regresión muestral pase por el punto de medias $(\bar{X}_2, \bar{Y})$:

$$\hat{\alpha}_1 = \bar{Y} - \hat{\alpha}_2 \bar{X}_2. \quad (5)$$

Esta identidad es exacta en cualquier muestra finita y no depende de ningún supuesto distribucional.

3.2. Paso 2 — Media muestral de Y a partir del modelo verdadero

Promediando ambos lados de la ecuación (1) sobre las n observaciones:

$$\bar{Y} = \beta_1 + \beta_2 \bar{X}_2 + \beta_3 \bar{X}_3 + \bar{u}, \quad (6)$$

donde $\bar{u} = n^{-1} \sum_{i=1}^n u_i$ es la media muestral de las perturbaciones.

3.3. Paso 3 — Sustitución y aplicación del operador de esperanza

Sustituyendo (6) en (5):

$$\hat{\alpha}_1 = (\beta_1 + \beta_2 \bar{X}_2 + \beta_3 \bar{X}_3 + \bar{u}) - \hat{\alpha}_2 \bar{X}_2.$$

Aplicando el operador de valor esperado a ambos lados, y usando que los regresores son fijos (por lo que $\bar{X}_2$ y $\bar{X}_3$ son constantes), $\beta_1, \beta_2, \beta_3$ son parámetros fijos, y $E[\bar{u}] = 0$:

$$\begin{aligned} E(\hat{\alpha}_1) &= \beta_1 + \beta_2 \bar{X}_2 + \beta_3 \bar{X}_3 + \underbrace{E[\bar{u}]}_{=0} - E(\hat{\alpha}_2) \bar{X}_2 \\ &= \beta_1 + \beta_2 \bar{X}_2 + \beta_3 \bar{X}_3 - E(\hat{\alpha}_2) \bar{X}_2. \end{aligned} \quad (7)$$

3.4. Paso 4 — Sustitución del sesgo conocido de la pendiente

Reemplazamos $E(\hat{\alpha}_2)$ en (7) usando el resultado auxiliar (3):

$$E(\hat{\alpha}_1) = \beta_1 + \beta_2 \bar{X}_2 + \beta_3 \bar{X}_3 - (\beta_2 + \beta_3 b_{32}) \bar{X}_2. \quad (8)$$

3.5. Paso 5 — Simplificación algebraica

Distribuyendo $\bar{X}_2$ en el último término de (8):

$$E(\hat{\alpha}_1) = \beta_1 + \beta_2 \bar{X}_2 + \beta_3 \bar{X}_3 - \beta_2 \bar{X}_2 - \beta_3 b_{32} \bar{X}_2. \quad (9)$$

Los términos $\beta_2 \bar{X}_2$ y $-\beta_2 \bar{X}_2$ se cancelan:

$$E(\hat{\alpha}_1) = \beta_1 + \beta_3 \bar{X}_3 - \beta_3 b_{32} \bar{X}_2. \quad (10)$$

Finalmente, factorizando β_3 :

$$\boxed{E(\hat{\alpha}_1) = \beta_1 + \beta_3 (\bar{X}_3 - b_{32} \bar{X}_2)} \quad (11)$$

que es exactamente lo que se quería demostrar. ■

4. INTERPRETACIÓN DEL RESULTADO

4.1. Naturaleza del sesgo

La ecuación (11) muestra que el estimador $\hat{\alpha}_1$ es en general un estimador **sesgado e inconsistente** de β_1 . El sesgo es:

$$\text{Sesgo}(\hat{\alpha}_1) = E(\hat{\alpha}_1) - \beta_1 = \beta_3 (\bar{X}_3 - b_{32} \bar{X}_2). \quad (12)$$

Este sesgo tiene una interpretación geométrica precisa: el intercepto estimado absorbe el *efecto promedio* de la variable omitida ($\beta_3 \bar{X}_3$), pero descontando la parte de ese efecto que ya fue atribuida, de manera espuria, al coeficiente de pendiente a través de la correlación entre X_3 y X_2 (capturada por $b_{32} \bar{X}_2$).

4.2. Condiciones de insesgadez

El intercepto $\hat{\alpha}_1$ sería un estimador insesgado de β_1 únicamente si el sesgo (12) se anulara. Esto ocurre en alguno de los siguientes casos:

1. $\beta_3 = 0$: la variable X_3 no pertenece realmente al modelo, por lo que omitirla no genera sesgo alguno.
2. $\bar{X}_3 = b_{32} \bar{X}_2$: la media muestral de la variable omitida coincide exactamente con la predicción lineal de X_3 a partir de X_2 , evaluada en la media de X_2 . Esta condición es algebraicamente posible pero estadísticamente improbable en datos económicos reales.
3. $\bar{X}_3 = 0$ y $b_{32} = 0$ simultáneamente: ambas variables tienen media cero y son ortogonales, situación que puede lograrse artificialmente centrando las variables pero que no elimina el sesgo sobre la pendiente.

4.3. Relación con el sesgo de la pendiente

Comparando (11) con (3), se aprecia la asimetría del problema: el sesgo de $\hat{\alpha}_2$ depende de b_{32} (la *relación* entre las variables), mientras que el sesgo de $\hat{\alpha}_1$ depende de $(\bar{X}_3 - b_{32} \bar{X}_2)$ (una combinación de *niveles* y *relación*). Así, incluso si $b_{32} = 0$ (variables ortogonales, lo que elimina el sesgo de la pendiente), el intercepto seguirá sesgado siempre que $\bar{X}_3 \neq 0$.

Resumen: La omisión de una variable relevante X_3 produce:

- $E(\hat{\alpha}_2) = \beta_2 + \beta_3 b_{32}$ (sesgo en la pendiente, ec. 13.3.3).
- $E(\hat{\alpha}_1) = \beta_1 + \beta_3 (\bar{X}_3 - b_{32} \bar{X}_2)$ (sesgo en el intercepto, resultado demostrado).

Ambos estimadores son **sesgados e inconsistentes**. El intercepto absorbe el efecto medio de la variable omitida corregido por la correlación con el regresor incluido. En general, no existe ningún remedio dentro del MCO: la única solución correcta es **incluir la variable omitida** en la especificación.