

Evaluación de la Advertencia de Henry Theil sobre la Degradación de la Inferencia Estadística

*Minería de datos, inflación del error Tipo I
y colapso de los intervalos de confianza nominales*

Ejercicio 13.14 — *Econometría*, Gujarati & Porter, 5.a ed.

ANÁLISIS CONCEPTUAL, TEÓRICO Y ALGEBRAICO

1. PLANTEAMIENTO: LA AFIRMACIÓN DE THEIL

Henry Theil advierte que cuando los intervalos de confianza y los estadísticos de prueba se calculan a partir de la *regresión final* de una estrategia de búsqueda de especificación, sus propiedades nominales ya no son válidas. Concretamente señala que:

- Un coeficiente reportado con un **intervalo de confianza del 95 %** puede, en realidad, tener una cobertura de apenas el **80 %**.
- Un nivel de significancia nominal del **1 %** puede corresponder, en la práctica, a un nivel real del **10 %**.

La afirmación no es una opinión metodológica vaga: tiene un sustento probabilístico preciso que se puede derivar algebraicamente a partir de la estructura del proceso de selección de modelos. El objetivo de esta evaluación es demostrar dicho sustento, identificar sus supuestos y discutir sus implicaciones para la práctica econométrica.

2. FUNDAMENTO CONCEPTUAL: INFERENCIA CLÁSICA Y SUS SUPUESTOS IMPLÍCITOS

2.1. El supuesto de pre-especificación

La validez de las pruebas t , F y de los intervalos de confianza estándar descansa en un supuesto que raramente se menciona de forma explícita: el modelo fue **especificado antes de observar los datos**, o al menos antes de examinar las correlaciones entre las variables de interés. Bajo esta condición, la probabilidad de rechazar una hipótesis nula verdadera es exactamente α (el nivel de significancia elegido), y el intervalo de confianza al $(1 - \alpha) \times 100\%$ contiene el verdadero parámetro con esa misma frecuencia en muestreos repetidos.

2.2. La estrategia de regresión y el sesgo de selección

En la práctica, los investigadores suelen seguir una **estrategia de regresión**: se prueban múltiples combinaciones de variables, formas funcionales y submuestras hasta que el modelo resultante luce “estadísticamente satisfactorio” (coeficientes significativos, signos coherentes con la teoría, R^2 elevado). La regresión *final* que se publica es la sobreviviente de un proceso de selección.

Este proceso introduce un **sesgo de selección de modelos**: los datos han sido examinados repetidamente y el modelo reportado es, por construcción, el que mejor se ajusta a esa muestra particular. Los estadísticos de ese modelo están sesgados hacia la significancia, no porque el efecto sea real, sino porque el proceso de búsqueda garantiza que solo los modelos con resultados “favorables” llegan a publicarse. En términos coloquiales: los datos han sido “torturados hasta confesar”.

2.3. Grados de libertad implícitos no contabilizados

Cada vez que el investigador examina una especificación alternativa y la descarta, consume información de la muestra sin que ello quede reflejado en los grados de libertad del modelo final. El resultado es que los errores estándar reportados *subestiman* la verdadera variabilidad del estimador, y los intervalos de confianza son *más estrechos*.

de lo que deberían ser. Este es el mecanismo por el cual un intervalo nominal del 95 % ofrece cobertura real inferior.

3. FUNDAMENTO ALGEBRAICO: LA FÓRMULA DE LOVELL

3.1. Derivación del nivel de significancia real

Sea c el número total de variables candidatas examinadas durante el proceso de búsqueda y k el número de variables retenidas en el modelo final, con $k \leq c$. Supóngase que cada prueba individual se realiza al nivel nominal α , y que las pruebas son aproximadamente independientes. La probabilidad de que, bajo la hipótesis nula global, *al menos una* de las c pruebas individuales resulte significativa es:

$$P(\text{al menos un rechazo erróneo}) = 1 - (1 - \alpha)^c. \quad (1)$$

Sin embargo, el investigador no reporta todas las pruebas realizadas, sino solo las k variables seleccionadas. El nivel de significancia efectivo del modelo final, ajustado por la búsqueda de las mejores k variables entre c candidatas, es la **fórmula de Lovell**:

$$\alpha^* = 1 - (1 - \alpha)^{c/k}. \quad (2)$$

Para α pequeño, la expansión de Taylor de primer orden de $(1 - \alpha)^{c/k} \approx 1 - (c/k)\alpha$ produce la aproximación lineal:

$$\alpha^* \approx \frac{c}{k} \alpha. \quad (3)$$

3.2. Verificación numérica del ejemplo de Theil: 1 % $\rightarrow$ 10 %

Theil afirma que un nivel de significancia nominal del 1 % puede corresponder en realidad a un 10 %. Este resultado se reproduce exactamente con $c = 20$ variables candidatas y $k = 2$ variables retenidas:

$$\alpha^* \approx \frac{c}{k} \alpha = \frac{20}{2} \times 0,01 = 10 \times 0,01 = 0,10. \quad (4)$$

Usando la fórmula exacta (2):

$$\alpha^* = 1 - (1 - 0,01)^{20/2} = 1 - (0,99)^{10} = 1 - 0,9044 = 0,0956 \approx 9,6 \%. \quad (5)$$

Ambas expresiones confirman el orden de magnitud: el nivel real es aproximadamente diez veces mayor que el nominal reportado.

3.3. Verificación numérica del ejemplo de Theil: 95 % $\rightarrow$ 80 %

El nivel de confianza nominal es $1 - \alpha = 0,95$, es decir, $\alpha = 0,05$. Supóngase que el proceso de búsqueda involucra $c = 4$ variables candidatas con $k = 1$ variable retenida:

$$\alpha^* \approx \frac{c}{k} \alpha = \frac{4}{1} \times 0,05 = 0,20. \quad (6)$$

El nivel de confianza real es entonces:

$$1 - \alpha^* = 1 - 0,20 = 0,80 = 80 \%. \quad (7)$$

Verificación con la fórmula exacta:

$$\alpha^* = 1 - (1 - 0,05)^{4/1} = 1 - (0,95)^4 = 1 - 0,8145 = 0,1855 \approx 18,6 \%. \quad (8)$$

El nivel de confianza real es $1 - 0,186 \approx 81,4 \%$, consistente con la cota del 80 % señalada por Theil. Las dos afirmaciones del enunciado quedan así demostradas algebraicamente.

3.4. Resumen de los resultados numéricos

Nivel nominal	c	k	c/k	α^* (aprox.)	Nivel real
$\alpha = 0,01$ (1 %)	20	2	10	0,10	$\approx 10 \%$
$\alpha = 0,05$ (5 %)	4	1	4	0,20	$\approx 80 \%$ de confianza
$\alpha = 0,05$ (5 %)	3	1	3	0,15	$\approx 85 \%$ de confianza

4. EVALUACIÓN CRÍTICA DE LA AFIRMACIÓN DE THEIL

4.1. Aspectos en los que la afirmación es correcta

1. **Validez matemática.** La fórmula de Lovell [(2)–(3)] es un resultado probabilístico riguroso, no una intuición. La degradación de los niveles nominales bajo búsqueda de especificación es un hecho demostrable, no una opinión.
2. **Prevalencia del problema en la práctica.** La minería de datos no es una anomalía rara: es el procedimiento habitual en econometría aplicada. La mayoría de las publicaciones empíricas no reportan el número de especificaciones exploradas antes del modelo final, lo que hace imposible para el lector calibrar α^* .
3. **La recomendación de interpretar “liberalmente” es operativamente correcta.** En ausencia de información sobre el proceso de búsqueda, la única respuesta racional del lector es aplicar un descuento al nivel de significancia reportado. Theil formaliza este descuento de manera que puede cuantificarse.

4.2. Limitaciones y matices

1. **La fórmula supone pruebas independientes.** La derivación de (2) asume que las c pruebas son aproximadamente independientes. En la práctica, las variables candidatas suelen estar correlacionadas, lo que hace que la inflación real de α^* sea menor que la predicha por Lovell. La fórmula es por tanto una *cota superior* del nivel real, no una estimación exacta.
2. **No toda búsqueda de especificación es invalidante.** Existen procedimientos de selección de variables con propiedades estadísticas controladas: el criterio de información de Akaike (AIC), el criterio bayesiano de Schwarz (BIC) y los métodos LASSO penalizan la complejidad del modelo de forma que la tasa de falsos positivos puede mantenerse bajo control. Theil escribe en un contexto anterior al desarrollo masivo de estos métodos.
3. **La solución propuesta (interpretación “liberal”) es paliativa, no**

estructural. Ajustar subjetivamente los niveles de confianza reportados no sustituye la necesidad de transparencia en el proceso de modelado. La solución correcta es reportar todas las especificaciones exploradas, aplicar la corrección de Lovell explícitamente, o utilizar métodos de selección con garantías formales.

5. IMPLICACIONES PARA LA PRÁCTICA ECONOMÉTRICA

La advertencia de Theil impone cuatro obligaciones metodológicas concretas:

- P1. Transparencia en el proceso de búsqueda.** El investigador debe reportar c y k , de modo que el lector pueda aplicar la corrección (3) y obtener α^* .
- P2. Análisis de sensibilidad.** Un resultado solo merece confianza si los coeficientes clave son estables ante variaciones razonables en la especificación (inclusión o exclusión de controles, transformaciones funcionales, submuestras).
- P3. Uso de criterios de información penalizados.** El AIC y el BIC introducen una penalización por el número de parámetros que mitiga parcialmente el sobreajuste. No eliminan el problema de la minería de datos, pero reducen su severidad.
- P4. Distinción entre significancia estadística y relevancia económica.** Dado que la significancia nominal es una cota inferior de la significancia real, un coeficiente borderline ($p \approx 0,05$) tras búsqueda de especificación puede tener $\alpha^* > 0,20$. La pregunta que debe primar es si la magnitud del efecto es sustantiva desde el punto de vista económico o de política pública.

Conclusión: La afirmación de Theil es técnicamente correcta y empíricamente relevante. La fórmula de Lovell demuestra algebraicamente que la búsqueda de especificación infla el error Tipo I en un factor de c/k , degradando los intervalos de confianza y los niveles de significancia de manera proporcional a la intensidad del proceso de búsqueda. Sus limitaciones son que la fórmula es una cota superior (las pruebas reales no son independientes) y que la recomendación de interpretar “liberalmente” es una respuesta paliativa que no reemplaza la transparencia

metodológica. El legado de Theil es haber cuantificado el costo estadístico de la minería de datos, convirtiendo una crítica cualitativa en un resultado numérico verificable.