UNIVERSIDAD — FACULTAD DE ECONOMÍA

NOTAS DE ECONOMETRÍA

Autocorrelación

Capítulo 12 — Gujarati & Porter (2010)

Complementado con Wooldridge (2016)

"Si se viola el supuesto de no autocorrelación, los estimadores MCO son todavía insesgados y consistentes, pero ya no son eficientes; la inferencia basada en MCO puede ser gravemente engañosa."

— Gujarati & Porter, *Econometría*, 5.ª ed., p. 415

Clase: Martes 17 de marzo de 2026

Fuentes: Gujarati & Porter (2010), cap. 12
Wooldridge (2016), cap. 12

Temas: Supuestos Gauss-Markov, causas, consecuencias, detección (Durbin-Watson) y corrección (MCG)

Índice

1 Supuesto de No Autocorrelación en el MCLR **2**

1.1 Representación Matricial Completa 2

2 Naturaleza de la Autocorrelación **2**

2.1 Clasificación según el Tipo de Datos 3

2.2 Proceso Autorregresivo de Primer Orden AR(1) 3

2.3 Patrones Típicos de los Residuos 3

2.4 Sesgo de Especificación: Forma Funcional Incorrecta 4

2.5 Diagramas de Dispersión $\hat{u}_t$ vs. $\hat{u}_{t-1}$ 5

3 Causas de la Autocorrelación **6**

3.1 Inercia o Tendencia Común 6

3.2 Sesgo de Especificación: Omisión de Variables Relevantes 6

3.3 Omisión de Efectos Dinámicos (Variables Rezagadas) 7

3.4 Transformación de Datos: Primeras Diferencias 7

3.5 Manipulación de los Datos (Interpolación/Extrapolación) 7

3.6 Fenómeno de la Telaraña (*Cobweb Phenomenon*) 7

3.7 Sesgo de Especificación: Forma Funcional Incorrecta 8

4 Consecuencias de Ignorar la Autocorrelación **8**

4.1 Varianza Real del Estimador MCO bajo AR(1) 8

4.2 Intervalos de Confianza: MCO vs. MCG 8

5 Detección de la Autocorrelación **9**

5.1 Inspección Gráfica de los Residuos 9

5.2 Test de Durbin-Watson 9

5.2.1 Estadístico 10

5.2.2 Relación con $\hat{\rho}$ 10

5.2.3 Regla de Decisión 10

5.2.4 Limitaciones del Test DW 10

5.3 Test de Breusch-Godfrey (LM) 11

6 Estimación por MCO Ignorando la Autocorrelación **11**

7 Corrección: Mínimos Cuadrados Generalizados (MCG) **11**

7.1 MCG Exactos 11

7.2 Transformación de Prais-Winsten 12

7.3 Estimación Iterativa de Cochrane-Orcutt 12

7.4 Errores Estándar Robustos de Newey-West 13

8 Resumen Esquemático del Procedimiento **13**

9 Comparación: MCO vs. MCG bajo Autocorrelación **14**

10 Ejemplo Numérico: Función de Consumo **14**

11 Autocorrelación de Orden Superior: AR(p) **14**

12 Autocorrelación Espacial en Datos de Corte Transversal **15**

13 Conclusiones **15**

1. Supuesto de No Autocorrelación en el MCLR

El **Modelo Clásico de Regresión Lineal (MCLR)** descansa sobre seis supuestos conocidos como condiciones de *Gauss-Markov*. Uno de los más frecuentemente violados en datos de series de tiempo es el **supuesto de no autocorrelación**.

Definición: No Autocorrelación

Dado el modelo de regresión lineal

$$Y_t = \beta_1 + \beta_2 X_t + u_t, \quad t = 1, 2, \ldots, T, \tag{1}$$

se requiere que los términos de error no estén correlacionados entre observaciones distintas:

$$\mathrm{Cov}(u_i, u_j) = E(u_i u_j) = 0, \quad i \neq j. \tag{2}$$

Equivalentemente, en notación matricial: $E(\mathbf{u}\mathbf{u}') = \sigma^2 \mathbf{I}_n$.

Importancia del supuesto. Si (2) se cumple, los estimadores MCO son *BLUE* (Best Linear Unbiased Estimators) según el Teorema de Gauss-Markov. Si se viola, los MCO siguen siendo insesgados y consistentes, pero dejan de ser eficientes y los errores estándar son sesgados (generalmente subestimados), lo que invalida la inferencia estadística.

1.1. Representación Matricial Completa

Para el modelo matricial $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$, la estructura de la matriz de varianzas-covarianzas de los errores bajo autocorrelación es:

$$E(\mathbf{u}\mathbf{u}') = \sigma^2 \boldsymbol{\Omega} = \sigma^2 \begin{pmatrix} 1 & \rho & \rho^2 & \cdots & \rho^{T-1} \\ \rho & 1 & \rho & \cdots & \rho^{T-2} \\ \rho^2 & \rho & 1 & \cdots & \rho^{T-3} \\ \vdots & & \ddots & & \vdots \\ \rho^{T-1} & \cdots & & & 1 \end{pmatrix}, \tag{3}$$

donde ρ es el coeficiente de autocorrelación de primer orden y $|\rho| < 1$ para que el proceso sea estacionario. Bajo el supuesto de no autocorrelación se tiene $\boldsymbol{\Omega} = \mathbf{I}_n$.

2. Naturaleza de la Autocorrelación

La autocorrelación ocurre cuando el término de error en un periodo está correlacionado con el término de error en otro periodo.

2.1. Clasificación según el Tipo de Datos

1. **Corte transversal:** La correlación se manifiesta en el espacio (autocorrelación espacial). Ejemplo: el PIB de un departamento influye en el de los departamentos vecinos.

2. **Series de tiempo:** La correlación se extiende a través de periodos cronológicos. Es la forma más común y estudiada.

3. **Datos de panel:** Combina ambas dimensiones: variación temporal y transversal.

2.2. Proceso Autorregresivo de Primer Orden AR(1)

El esquema más utilizado para modelar la autocorrelación es el **proceso AR(1)**:

$$u_t = \rho\, u_{t-1} + \varepsilon_t, \quad |\rho| < 1, \quad \varepsilon_t \sim \text{iid}\Big(0,\, \sigma_\varepsilon^2\Big), \tag{4}$$

donde ρ es el coeficiente de autocorrelación de primer orden. A partir de (4) se obtienen las propiedades:

$$E(u_t) = 0, \tag{5}$$

$$\text{Var}(u_t) = \frac{\sigma_\varepsilon^2}{1-\rho^2}, \tag{6}$$

$$\text{Cov}(u_t, u_{t-k}) = \rho^k \cdot \frac{\sigma_\varepsilon^2}{1-\rho^2}. \tag{7}$$

> La autocorrelación de orden k se define como $\rho_k = \rho^k$. Para $\rho > 0$ todos los $\rho_k > 0$ (autocorrelación positiva); para $\rho < 0$ los ρ_k alternan de signo (autocorrelación negativa).

2.3. Patrones Típicos de los Residuos

La **Figura 1** reproduce los cinco patrones de autocorrelación y no autocorrelación presentados en Gujarati & Porter (cap. 12, figura 12.1). La identificación visual de estos patrones es el primer paso diagnóstico.

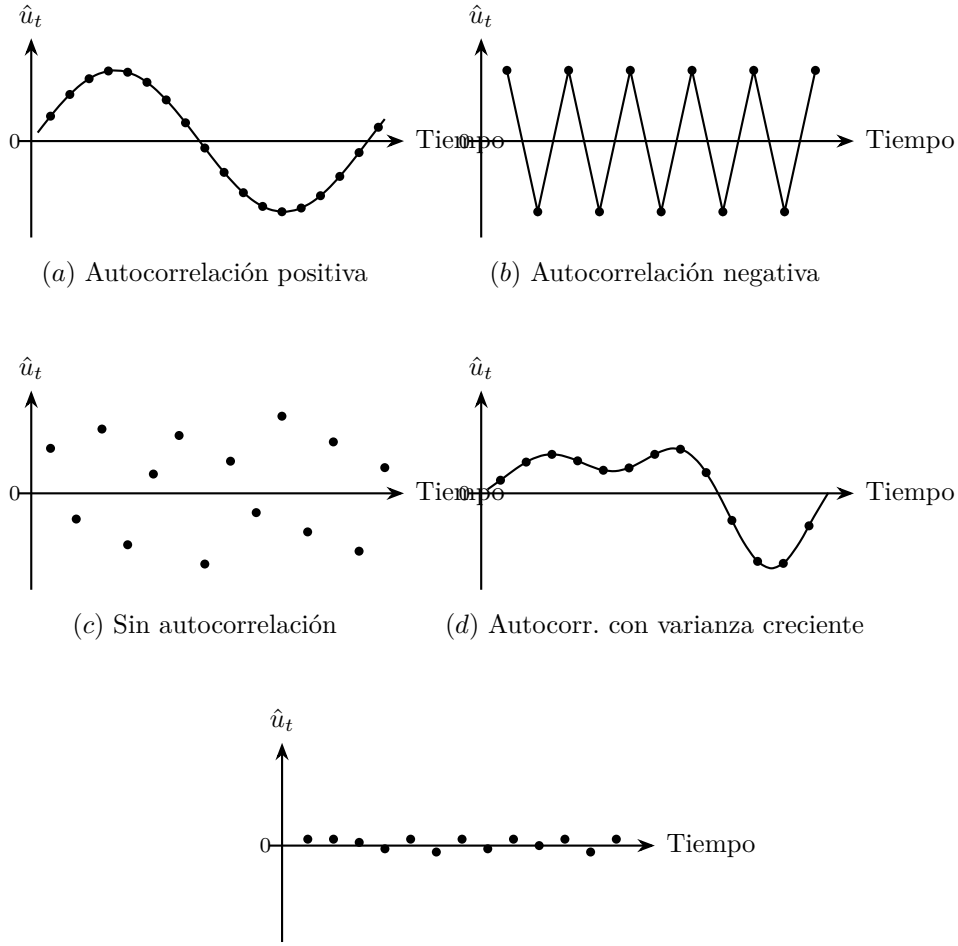

(a) Autocorrelación positiva (b) Autocorrelación negativa

(c) Sin autocorrelación (d) Autocorr. con varianza creciente

(e) Casi sin autocorrelación (ruido blanco)

Figura 1: Patrones de autocorrelación y no autocorrelación en los residuos (Gujarati & Porter, figura 12.1). Los paneles (a) y (b) ilustran autocorrelación positiva y negativa en series de tiempo; (c) muestra el patrón ideal; (d) combina autocorrelación y heterocedasticidad; (e) corresponde al ruido blanco.

2.4. Sesgo de Especificación: Forma Funcional Incorrecta

Un caso importante de falsa autocorrelación surge cuando la **forma funcional del modelo es incorrecta** (Gujarati & Porter, figura 12.2). Si la verdadera relación es curvilínea pero se estima una recta, los residuos mostrarán un patrón sistemático.

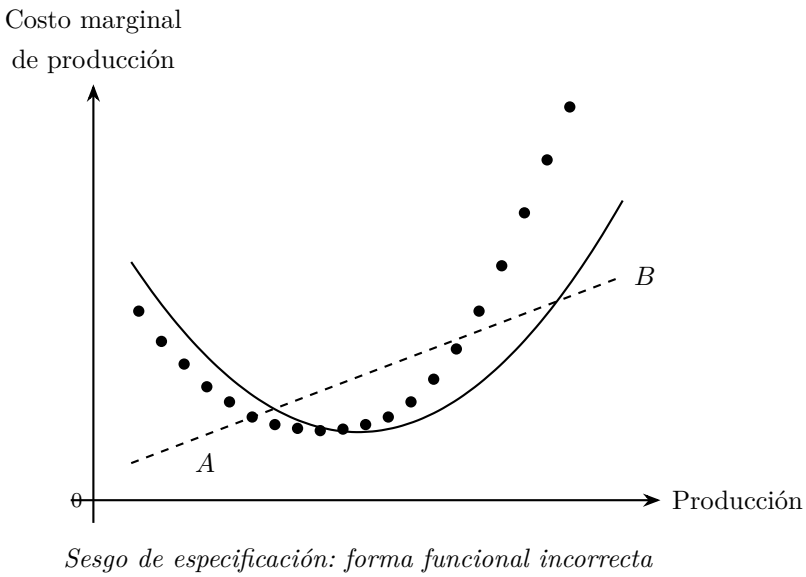

Figura 2: Figura 12.2 de Gujarati & Porter. Ajustar una recta AB a datos que siguen una relación cuadrática genera residuos con patrón sistemático (+, +, , , +, +), simulando autocorrelación cuando en realidad el problema es de forma funcional incorrecta.

2.5. Diagramas de Dispersión $\hat{u}_t$ vs. $\hat{u}_{t-1}$

La **Figura 3** (Gujarati & Porter, figura 12.3) muestra los diagramas de dispersión que permiten diagnosticar visualmente la autocorrelación al graficar el residuo actual contra el residuo rezagado un periodo.

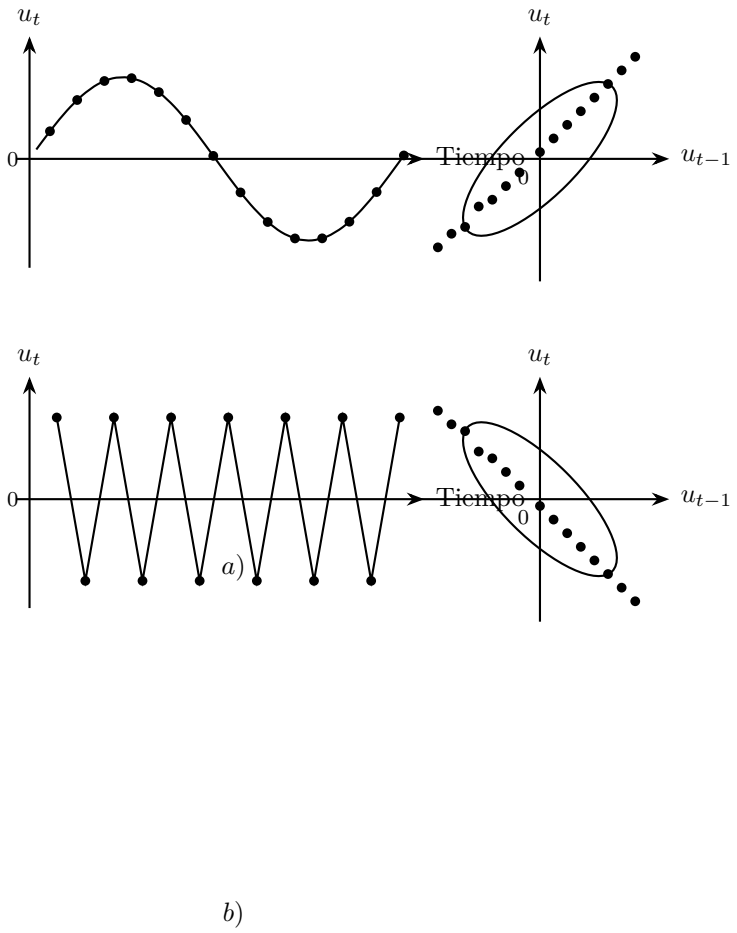

Figura 3: Figura 12.3 de Gujarati & Porter. Izquierda: serie temporal de los residuos. Derecha: diagrama de dispersión $\hat{u}_t$ contra $\hat{u}_{t-1}$. Panel a): autocorrelación positiva (elipse orientada noreste-suroeste). Panel b): autocorrelación negativa (elipse orientada noroeste-sureste).

3. Causas de la Autocorrelación

3.1. Inercia o Tendencia Común

Las series macroeconómicas (PIB, consumo, inversión) presentan **inercia**: el valor presente depende del valor pasado. Formalmente, si X_t tiene componente autorregresivo, esto se transmite al error u_t a través de la dinámica del modelo. En periodos cortos (diario, semanal, mensual), los cambios tienden a ser graduales, no aleatorios.

3.2. Sesgo de Especificación: Omisión de Variables Relevantes

Si se omite una variable Z_t que evoluciona sistemáticamente en el tiempo, su efecto queda absorbido por el término de error, generando autocorrelación.

Ejemplo 3.1 (Inversión con variable omitida)**.** Suponga la función de inversión real:

$$\text{(Modelo incorrecto)} \quad I_t = \beta_1 + \beta_2 \,\text{Ingreso}_t + \beta_3 \,\text{Impuestos}_t + u_t, \tag{8}$$

$$\text{(Modelo correcto)} \quad I_t = \alpha_1 + \alpha_2 \,\text{Ingreso}_t + \alpha_3 \,\text{Impuestos}_t + \alpha_4 \,\text{TasaInterés}_t + v_t. \tag{9}$$

En (8), $u_t = \alpha_4 \,\text{TasaInterés}_t + v_t$. Como la tasa de interés sigue un proceso persistente, $\text{Cov}(u_t, u_{t-1}) \neq 0$.

3.3. Omisión de Efectos Dinámicos (Variables Rezagadas)

En muchos fenómenos económicos, el pasado determina el presente.

Ejemplo 3.2 (Oferta agrícola)**.** El agricultor decide cuánto sembrar en función del precio anterior, no del actual:

$$\text{(Incorrecto)} \quad S_t = \beta_1 + \beta_2 P_t - \beta_3 C_t + u_t,$$

$$\text{(Correcto)} \quad S_t = \beta_1 + \beta_2 P_{t-1} - \beta_3 C_{t-1} + u_t,$$

donde P_t es el precio y C_t el costo de producción. Omitir el rezago introduce autocorrelación como artefacto.

3.4. Transformación de Datos: Primeras Diferencias

Para eliminar tendencias estocásticas o reducir multicolinealidad, se trabaja en primeras diferencias: $\Delta Y_t = Y_t - Y_{t-1}$. Si el modelo original tenía $u_t \sim \text{MA}(1)$, la diferenciación puede inducir autocorrelación de primer orden en los nuevos errores.

3.5. Manipulación de los Datos (Interpolación/Extrapolación)

Completar datos faltantes mediante interpolación lineal o cúbica introduce dependencia artificial entre observaciones contiguas, pues los valores imputados son combinaciones lineales de observaciones vecinas.

3.6. Fenómeno de la Telaraña (*Cobweb Phenomenon*)

En mercados como el agrícola o ganadero, la oferta reacciona con un rezago de un periodo completo al precio vigente:

$$Q_t^S = f(P_{t-1}), \quad Q_t^D = g(P_t), \quad Q_t^S = Q_t^D. \tag{10}$$

El ciclo oferta-precio genera una estructura de error correlacionada que se transmite al modelo econométrico.

3.7. Sesgo de Especificación: Forma Funcional Incorrecta

Como se ilustró en la Figura 2: ajustar una función lineal a datos con relación cuadrática genera residuos con patrón sistemático que parece autocorrelación, pero es en realidad un problema de mala especificación.

4. Consecuencias de Ignorar la Autocorrelación

Propiedades de MCO bajo autocorrelación AR(1)

Si $u_t = \rho\, u_{t-1} + \varepsilon_t$ con $|\rho| < 1$ y se utiliza MCO para estimar $\hat{\boldsymbol{\beta}}$:

(a) $\hat{\boldsymbol{\beta}}$ sigue siendo **insesgado**: $E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta}$.

(b) $\hat{\boldsymbol{\beta}}$ sigue siendo **consistente**.

(c) $\hat{\boldsymbol{\beta}}$ **no** es eficiente; existe un estimador lineal insesgado con menor varianza (MCG).

(d) La matriz $\mathrm{Var}(\hat{\boldsymbol{\beta}}_{MCO})$ estimada por $s^2(\mathbf{X}'\mathbf{X})^{-1}$ está **sesgada** (generalmente subestima la varianza real).

(e) Las pruebas t, F y los intervalos de confianza son **inválidos**.

4.1. Varianza Real del Estimador MCO bajo AR(1)

Para el modelo simple $Y_t = \beta_1 + \beta_2 X_t + u_t$ con $u_t = \rho\, u_{t-1} + \varepsilon_t$, la verdadera varianza del estimador de la pendiente es:

$$\mathrm{Var}(\hat{\beta}_2^{MCO}) = \frac{\sigma^2}{\sum x_t^2}\left[1 + 2\rho\frac{\sum_{t=2}^{T} x_t x_{t-1}}{\sum x_t^2} + 2\rho^2\frac{\sum_{t=3}^{T} x_t x_{t-2}}{\sum x_t^2} + \cdots\right], \tag{11}$$

donde $x_t = X_t - \bar{X}$. El término entre corchetes puede ser considerablemente mayor que 1 cuando $\rho > 0$ y X_t es una serie creciente, lo que implica que la varianza estimada por MCO subestima la verdadera.

4.2. Intervalos de Confianza: MCO vs. MCG

La **Figura 4** (Gujarati & Porter, figura 12.4) ilustra las consecuencias prácticas: el intervalo de confianza MCO al 95 % es más estrecho que el correcto (MCG), lo que lleva a rechazar falsamente $H_0 : \beta_2 = 0$.

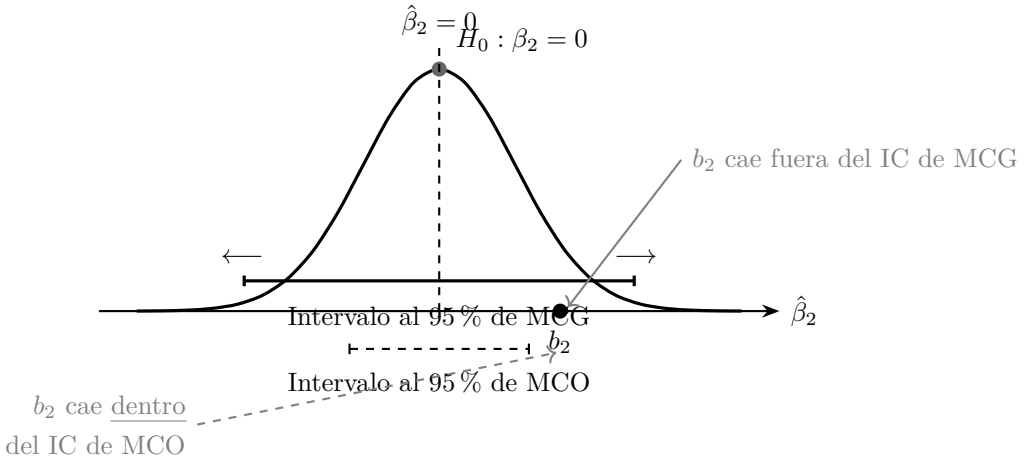

Figura 4: Figura 12.4 de Gujarati & Porter. Distribución muestral de $\hat{\beta}_2$ bajo $H_0 : \beta_2 = 0$. El estimador particular b_2 cae dentro del IC de MCO (incorrecto) pero fuera del IC de MCG (correcto). Conclusión: **MCO acepta** falsamente H_0; **MCG rechaza** correctamente H_0.

> **Mensaje central.** Para establecer intervalos de confianza y probar hipótesis en presencia de autocorrelación, debe utilizarse el **Método de Mínimos Cuadrados Generalizados (MCG)**, no MCO, aunque los estimadores derivados de MCO sean insesgados y consistentes. (Véase Gujarati & Porter, secc. 12.11.)

5. Detección de la Autocorrelación

5.1. Inspección Gráfica de los Residuos

El análisis gráfico es el primer paso. Se grafica $\hat{u}_t$ contra:

(a) el tiempo t,

(b) el valor rezagado $\hat{u}_{t-1}$,

(c) los valores ajustados $\hat{Y}_t$.

Los patrones descritos en la Figura 1 son el diagnóstico visual de referencia.

5.2. Test de Durbin-Watson

Es el test más utilizado para detectar autocorrelación de **primer orden** en residuos de modelos estimados por MCO.

5.2.1. Estadístico

$$d = \frac{\sum_{t=2}^{T} (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^{T} \hat{u}_t^2} \tag{12}$$

5.2.2. Relación con $\hat{\rho}$

Expandiendo (12) y usando la aproximación $\hat{\rho} \approx \frac{\sum_{t=2}^{T} \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^{T} \hat{u}_t^2}$:

$$d \approx 2(1 - \hat{\rho}). \tag{13}$$

Por tanto:

Cuadro 1: Relación entre el estadístico d de Durbin-Watson y el grado de autocorrelación.

$\hat{\rho}$	$d \approx 2(1-\hat{\rho})$	Interpretación
$+1$	0	Autocorrelación positiva perfecta
$+0.5$	1	Autocorrelación positiva fuerte
0	2	Sin autocorrelación
-0.5	3	Autocorrelación negativa fuerte
-1	4	Autocorrelación negativa perfecta

5.2.3. Regla de Decisión

Sea d_L y d_U los valores críticos inferior y superior de las tablas de Durbin-Watson para un nivel de significancia α, tamaño de muestra n y número de regresores k:

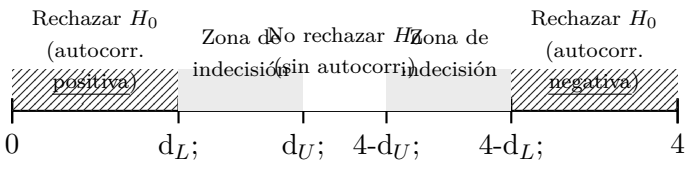

Figura 5: Regla de decisión del test de Durbin-Watson. H_0: no hay autocorrelación ($\rho = 0$).

5.2.4. Limitaciones del Test DW

1. Solo detecta autocorrelación de **primer orden**.

2. No es válido cuando el modelo incluye valores rezagados de Y_t como regresor (**modelos dinámicos**).

3. Existe una **zona de indecisión** $[d_L, d_U]$ y $[4 - d_U, 4 - d_L]$.

4. Los valores críticos dependen de la matriz $\mathbf{X}$.

5.3. Test de Breusch-Godfrey (LM)

Supera las limitaciones del DW al permitir probar autocorrelación de **orden arbitrario** p. El procedimiento es:

Paso 1. Estimar el modelo por MCO y obtener $\hat{u}_t$.

Paso 2. Regresar $\hat{u}_t$ sobre $\mathbf{x}_t$ (regresores originales) y los rezagos $\hat{u}_{t-1}, \hat{u}_{t-2}, \ldots, \hat{u}_{t-p}$.

Paso 3. El estadístico LM es:

$$LM = (T - p)\, R^2 \xrightarrow{H_0} \chi^2(p). \tag{14}$$

Paso 4. Rechazar H_0 (no autocorrelación de orden p) si $LM > \chi^2_{\alpha,p}$.

6. Estimación por MCO Ignorando la Autocorrelación

Si se ignora la autocorrelación y se aplica MCO al modelo $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$ con $E(\mathbf{u}\mathbf{u}') = \sigma^2\boldsymbol{\Omega} \neq \sigma^2\mathbf{I}$:

$$\hat{\boldsymbol{\beta}}_{MCO} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}, \tag{15}$$

$$E(\hat{\boldsymbol{\beta}}_{MCO}) = \boldsymbol{\beta}, \tag{16}$$

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}_{MCO}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Omega}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}. \tag{17}$$

MCO <u>estima</u> la varianza con $\widehat{\mathrm{Var}} = s^2(\mathbf{X}'\mathbf{X})^{-1}$, que es **incorrecta** cuando $\boldsymbol{\Omega} \neq \mathbf{I}$.

7. Corrección: Mínimos Cuadrados Generalizados (MCG)

7.1. MCG Exactos

Si $\boldsymbol{\Omega}$ es conocida, el estimador MCG es:

$$\hat{\boldsymbol{\beta}}_{MCG} = (\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{Y}, \tag{18}$$

con varianza:

$$\mathrm{Var}(\hat{\boldsymbol{\beta}}_{MCG}) = \sigma^2(\mathbf{X}'\boldsymbol{\Omega}^{-1}\mathbf{X})^{-1}. \tag{19}$$

Por el Teorema de Aitken, $\hat{\boldsymbol{\beta}}_{MCG}$ es BLUE.

7.2. Transformación de Prais-Winsten

En la práctica, ρ es desconocido. El procedimiento estándar transforma las variables para eliminar la autocorrelación.

Para el modelo $Y_t = \beta_1 + \beta_2 X_t + u_t$ con $u_t = \rho u_{t-1} + \varepsilon_t$:

$$Y_t^* = Y_t - \rho\, Y_{t-1}, \tag{20}$$

$$X_t^* = X_t - \rho\, X_{t-1}, \tag{21}$$

lo que da el **modelo transformado**:

$$Y_t^* = \beta_1^*(1-\rho) + \beta_2 X_t^* + \varepsilon_t, \tag{22}$$

donde $\varepsilon_t \sim \mathrm{iid}(0, \sigma_\varepsilon^2)$. Se aplica MCO a (22) (estimación válida).

> La observación inicial $t = 1$ se trata como $Y_1^* = \sqrt{1-\rho^2}\, Y_1$ (transformación de **Prais-Winsten**), conservando la eficiencia asintótica. Si se descarta la primera observación se habla de **transformación de Cochrane-Orcutt**.

7.3. Estimación Iterativa de Cochrane-Orcutt

Paso 1. Estimar el modelo original por MCO; obtener $\{\hat{u}_t\}$.

Paso 2. Estimar $\hat{\rho}$ mediante la regresión auxiliar:

$$\hat{u}_t = \hat{\rho}\, \hat{u}_{t-1} + v_t. \tag{23}$$

Paso 3. Construir las variables transformadas usando (20) y (21).

Paso 4. Estimar (22) por MCO para obtener nuevos $\hat{\beta}$.

Paso 5. Regresar al Paso 1 con los nuevos residuos. Repetir hasta convergencia ($|\hat{\rho}^{(k+1)} - \hat{\rho}^{(k)}| < \epsilon$).

7.4. Errores Estándar Robustos de Newey-West

Cuando la forma de $\mathbf{\Omega}$ es desconocida o se sospecha de heterocedasticidad y autocorrelación simultánea, se utilizan los **errores estándar HAC** (Heteroskedasticity and Autocorrelation Consistent) de Newey-West:

$$\widehat{\mathrm{Var}}_{NW}(\hat{\boldsymbol{\beta}}_{MCO}) = (\mathbf{X}'\mathbf{X})^{-1}\hat{\mathbf{S}}(\mathbf{X}'\mathbf{X})^{-1}, \tag{24}$$

donde $\hat{\mathbf{S}} = \hat{\sigma}_0 + \sum_{j=1}^{m} w_j(\hat{\sigma}_j + \hat{\sigma}_j')$, con $w_j = 1 - j/(m+1)$ (pesos de Bartlett) y $\hat{\sigma}_j = T^{-1}\sum_{t=j+1}^{T} \hat{u}_t\hat{u}_{t-j}\mathbf{x}_t\mathbf{x}_{t-j}'$.

8. Resumen Esquemático del Procedimiento

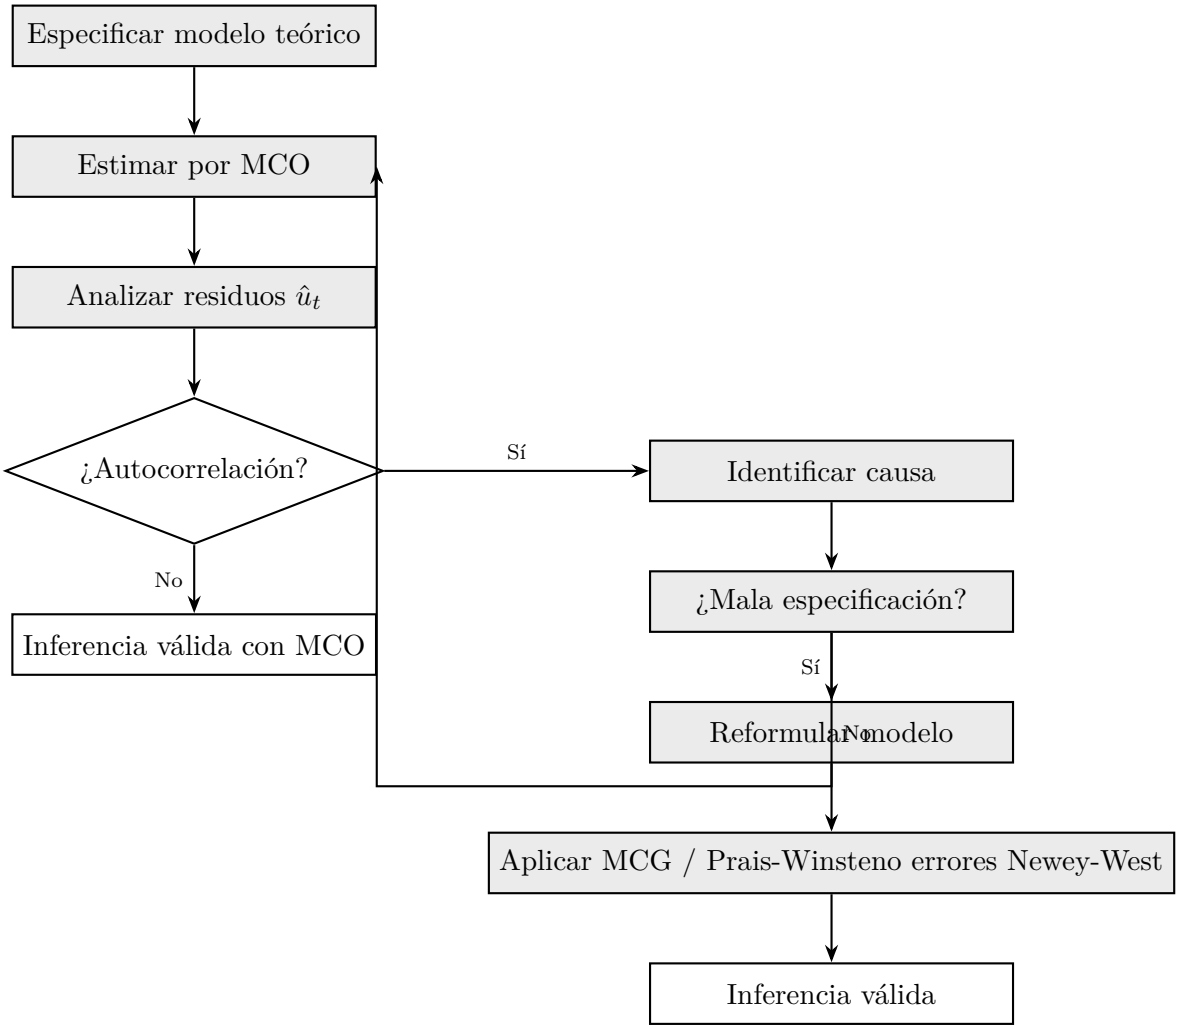

Figura 6: Diagrama de flujo para el tratamiento de la autocorrelación en un modelo de regresión lineal.

9. Comparación: MCO vs. MCG bajo Autocorrelación

Cuadro 2: Propiedades de los estimadores MCO y MCG cuando existe autocorrelación AR(1).

Propiedad	**MCO**	**MCG**
Insesgado	✓	✓
Consistente	✓	✓
Eficiente (BLUE)	×	✓
Var. estimada correcta	×	✓
Pruebas t y F válidas	×	✓
Requiere conocer ρ	No	Sí (o estimarlo)

10. Ejemplo Numérico: Función de Consumo

Considere la estimación de la función de consumo para una economía:

$$C_t = \beta_1 + \beta_2 Y_t^D + u_t, \quad t = 1, \ldots, 20, \tag{25}$$

donde C_t es consumo agregado e Y_t^D es ingreso disponible.

Ejemplo 10.1 (Diagnóstico DW)**.** Suponga que MCO arroja: $\hat{d} = 0.95$, $n = 20$, $k = 1$. De las tablas DW con $\alpha = 5\,\%$: $d_L = 1.20$, $d_U = 1.41$. Como $\hat{d} = 0.95 < d_L = 1.20$, se **rechaza** H_0 de no autocorrelación positiva. Se procede con Cochrane-Orcutt:

1. Regresar $\hat{u}_t$ sobre $\hat{u}_{t-1}$: $\hat{\rho} = 0.48$ (con $p < 0.05$).
2. Transformar: $C_t^* = C_t - 0.48\, C_{t-1}$, $Y_t^{D*} = Y_t^D - 0.48\, Y_{t-1}^D$.
3. Re-estimar por MCO; nuevo $\hat{d} = 2.08 \approx 2$ (no se rechaza H_0).

11. Autocorrelación de Orden Superior: AR(p)

En series con frecuencia trimestral o mensual, la autocorrelación puede ser estacional. El proceso AR(p) generaliza (4):

$$u_t = \rho_1 u_{t-1} + \rho_2 u_{t-2} + \cdots + \rho_p u_{t-p} + \varepsilon_t. \tag{26}$$

Para datos trimestrales, es común encontrar $\rho_4 \neq 0$ (componente estacional); para mensuales, $\rho_{12} \neq 0$. El test de Breusch-Godfrey con $p = 4$ o $p = 12$ detecta esta estructura.

12. Autocorrelación Espacial en Datos de Corte Transversal

En datos de corte transversal (departamentos, municipios, países), la autocorrelación se manifiesta en el espacio:

$$u_i = \lambda \sum_{j \neq i} w_{ij}\, u_j + \varepsilon_i, \tag{27}$$

donde w_{ij} son los pesos espaciales (e.g., inverso de la distancia entre las unidades i y j) y λ es el coeficiente de autocorrelación espacial. El test análogo al DW para el caso espacial es el **estadístico I de Moran**.

13. Conclusiones

1. La autocorrelación viola el supuesto de Gauss-Markov $E(\mathbf{u}\mathbf{u}') = \sigma^2\mathbf{I}$, aunque preserva la insesgadez y consistencia de MCO.

2. La principal consecuencia práctica es que los errores estándar de MCO son sesgados, invalidando toda la inferencia estadística.

3. El diagnóstico visual (gráficos de residuos) combinado con el test de Durbin-Watson o Breusch-Godfrey es el procedimiento estándar.

4. La corrección mediante MCG (Cochrane-Orcutt o Prais-Winsten) o mediante errores HAC de Newey-West restaura la validez de la inferencia.

5. En la práctica, la autocorrelación puede ser síntoma de mala especificación: omisión de variables, forma funcional incorrecta o dinámica no modelada. La solución correcta es reformular el modelo, no solo aplicar una corrección mecánica.

Referencias

[1] Gujarati, D. N., & Porter, D. C. (2010). *Econometría* (5.ª ed.). McGraw-Hill.

[2] Wooldridge, J. M. (2016). *Introductory Econometrics: A Modern Approach* (6.ª ed.). Cengage Learning.

[3] Greene, W. H. (2018). *Econometric Analysis* (8.ª ed.). Pearson.

[4] Hayashi, F. (2000). *Econometrics*. Princeton University Press.

[5] Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.