Econometría — Notas de Clase

Capítulo 12: Autocorrelación en los Errores

Wooldridge, Cap. 12 & Gujarati & Porter, Cap. 12

Apuntes de clase en la UPTC por Emanuel Quintana Silva · 17 de marzo de 2026

Resumen

Estos apuntes desarrollan de forma exhaustiva el problema de la **autocorrelación** (o correlación serial) en los errores del modelo de regresión lineal clásico. Se cubren: definición y naturaleza del problema, las ocho causas principales, el proceso AR(1) y sus propiedades, las consecuencias sobre los estimadores MCO, los métodos gráficos y paramétricos de detección (Rachas, Durbin–Watson, Breusch–Godfrey) con su derivación algébrica completa, los procedimientos remediales (GLS, FGLS, Newey–West/HAC) y un árbol de decisión integrador.

Índice

1. Contexto: Supuestos del MCRL sobre los Errores **4**

2. Naturaleza del Problema **4**
2.1. Distinción Terminológica 5
2.2. Tipos de Datos y Manifestación 5

3. Causas de la Autocorrelación **5**

4. El Esquema Autorregresivo AR(1) **7**
4.1. Propiedades del Proceso AR(1) Estacionario ($|\rho| < 1$) 7
4.2. Esquemas de Orden Superior 7

5. Consecuencias de Estimar con MCO bajo Autocorrelación **8**
5.1. Distorsión de la Varianza del Estimador 8
5.2. Estimador $\hat{\sigma}^2$ Sesgado 8
5.3. Cuadro Completo de Consecuencias 9

6. Métodos de Detección **9**
6.1. Método Gráfico 9
6.2. Prueba de las Rachas (Geary / Wald–Wolfowitz) 11
6.2.1. Hipótesis 11
6.2.2. Procedimiento 11
6.2.3. Distribución Bajo H_0 11
6.2.4. Regla de Decisión 11
6.2.5. Ejemplo Numérico 12
6.3. Prueba d de Durbin–Watson 12
6.3.1. Hipótesis 12
6.3.2. Seis Supuestos Requeridos 12
6.3.3. Estadístico 13
6.3.4. Derivación Algébrica Completa 13
6.3.5. Regiones de Decisión 13
6.4. Estadístico h de Durbin (Modelos Autorregresivos) 14
6.5. Prueba de Breusch–Godfrey (LM) 14
6.5.1. Procedimiento 14

7. Medidas Remediales **15**
7.1. Mínimos Cuadrados Generalizados Exactos (MCG/GLS) 15
7.1.1. Transformación de Prais–Winsten (Primera Observación) 15

7.2. MCG Factibles (FGLS): ρ Desconocido 15
7.2.1. Método de Cochrane–Orcutt (CO) 15
7.3. Errores Estándar Robustos — Newey–West (HAC) 16

Hoja de Fórmulas **17**

1. Contexto: Supuestos del MCRL sobre los Errores

El Modelo Clásico de Regresión Lineal (MCRL) impone sobre el vector de perturbaciones $\mathbf{u}$ la estructura de covarianza escalar:

$$E[\mathbf{u}\mathbf{u}^\top] = \sigma^2 \mathbf{I}_n$$

lo que implica dos supuestos simultáneos:

1. **Homocedasticidad:** $\mathrm{Var}(u_i) = \sigma^2$ para todo i.
2. **No autocorrelación:** $\mathrm{Cov}(u_i, u_j) = E[u_i u_j] = 0$ para $i \neq j$.

Supuesto de No Autocorrelación (Gauss–Markov)

$$\mathrm{Cov}(u_i,\, u_j) \;=\; E[u_i\, u_j] \;=\; 0, \qquad i \neq j$$

Para el modelo $Y_i = \beta_1 + \beta_2 X_i + u_i$: el error de cualquier observación *no* está relacionado con el error de ninguna otra observación, ni en el **tiempo** ni en el **espacio**. Si este supuesto se viola: $E[\mathbf{u}\mathbf{u}^\top] = \sigma^2\Omega$ donde $\Omega \neq \mathbf{I}$.

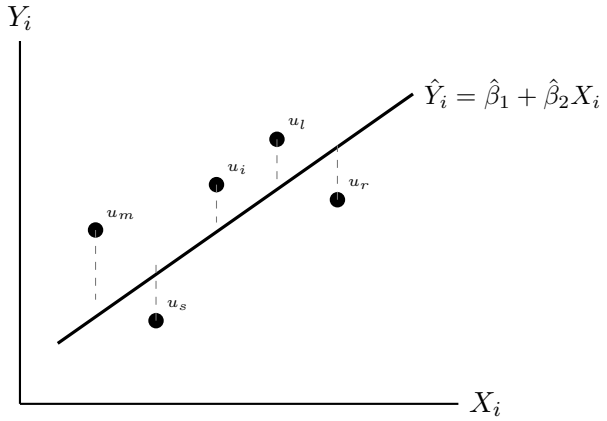

Figura 1: Supuesto cumplido: residuos u_i dispersos aleatoriamente, sin patrón sistemático en el tiempo ni el espacio.

2. Naturaleza del Problema

412)

Definición — Gujarati & Porter (2010

La **autocorrelación** es la correlación entre miembros de series de observaciones ordenadas en el tiempo (series de tiempo) o en el espacio (datos de corte transversal). Ocurre cuando $E(u_i u_j) \neq 0$ para $i \neq j$.

Cuando existe autocorrelación, la matriz de covarianza de los errores adopta:

$$E[\mathbf{u}\mathbf{u}^\top] = \sigma^2 \begin{pmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{n-1} \\ \rho_1 & 1 & \rho_1 & \cdots & \rho_{n-2} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \rho_{n-1} & \cdots & \cdots & \cdots & 1 \end{pmatrix} = \sigma^2 \Omega$$

donde $\rho_k = \mathrm{Corr}(u_t,\, u_{t-k})$ es la autocorrelación en el rezago k.

2.1. Distinción Terminológica

Término	Definición (Tintner)
Autocorrelación	Correlación de una serie *consigo misma* con rezago: $\mathrm{Corr}(u_t,\, u_{t-k})$, $k \geq 1$.
Correlación serial	Correlación entre dos series *distintas* desplazadas en el tiempo. En práctica econométrica ambos términos se usan indistintamente.

2.2. Tipos de Datos y Manifestación

1. **Series de tiempo** — forma más frecuente; errores del periodo t correlacionados con los de $t-1$, $t-2, \ldots$
2. **Datos de corte transversal** — autocorrelación *espacial*: unidades geográficas vecinas presentan errores similares.
3. **Datos de panel** — combinación de dependencia temporal y espacial (datos agrupados).

3. Causas de la Autocorrelación

1. **Inercia (Momentum macroeconómico).** Las series económicas (PIB, empleo, inflación, consumo) exhiben ciclos de expansión y contracción. En una fase de recuperación, cada valor sucesivo suele ser mayor que el anterior, creando dependencia sistemática entre observaciones contiguas.

2. **Sesgo de especificación: variables excluidas.** Si se omite una variable relevante *que sí está autocorrelacionada*, su influencia se absorbe en u_t.

   Ejemplo (apuntes):

$$\text{Especificado:} \quad I_t = \beta_1 + \beta_2 \,\text{Ingreso}_t + \beta_3 \,\text{Impuestos}_t + \underbrace{u_t}_{\ni \alpha_4 r_t} \tag{1}$$

$$\text{Correcto:} \quad I_t = \alpha_1 + \alpha_2 \,\text{Ingreso}_t + \alpha_3 \,\text{Impuestos}_t + \alpha_4 \, r_t + v_t$$

   Al omitir la tasa de interés r_t, el error de (1) hereda su autocorrelación.

3. **Forma funcional incorrecta.** Ajustar un modelo lineal a una relación curvilínea produce residuos con patrón sistemático (sobreestimación en los extremos, subestimación en el centro).

4. **Omisión de variables rezagadas.** Ignorar la dinámica del modelo (efectos retardados). Ejemplo agrícola:

$$\text{Incorrecto:} \quad S_t = \beta_1 + \beta_2 P_t - \beta_3 C_t + u_t \tag{2}$$

$$\text{Correcto:} \quad S_t = \beta_1 + \beta_2 P_{t-1} - \beta_3 C_{t-1} + u_t \tag{3}$$

   donde S_t = oferta agrícola, P_t = precio, C_t = costos de producción.

5. **Fenómeno de la telaraña (*cobweb*).** En mercados con rezago entre producción y venta, la oferta actual responde al precio del periodo anterior, generando un patrón cíclico de sobreproducción/subproducción que se refleja en los errores del modelo.

6. **Manipulación de datos.** Promediar, interpolar o extrapolar datos para cambiar la frecuencia (mensual $\to$ trimestral) introduce suavizado artificial que correlaciona observaciones adyacentes.

7. **Transformaciones de datos.** Aplicar primeras diferencias ($\Delta y_t = y_t - y_{t-1}$) para corregir colinealidad puede *inducir* autocorrelación en Δu_t incluso si u_t era independiente.

8. **No estacionariedad.** Si las variables del modelo no son estacionarias, los errores reflejan esa inestabilidad mediante autocorrelación persistente ($\rho \to 1$).

Autocorrelación Pura vs. Inducida

La autocorrelación **pura** surge de la naturaleza del fenómeno (inercia, cobweb). La **inducida** es un artefacto de errores del investigador: especificación incorrecta, omisión de variables o transformaciones inadecuadas. Antes de aplicar remedios es fundamental diagnosticar cuál tipo está presente.

4. El Esquema Autorregresivo AR(1)

Proceso AR(1) — Esquema de Primer Orden

$$\boxed{u_t \;=\; \rho\, u_{t-1} \;+\; \varepsilon_t}, \qquad -1 < \rho < 1$$

- ρ — coeficiente de autocorrelación de primer orden (*poblacional*); AR(1) $\equiv \rho$.
- ε_t — ruido blanco puro: (1) $E[\varepsilon_t] = 0$; (2) $\mathrm{Var}(\varepsilon_t) = \sigma_\varepsilon^2$; (3) $\mathrm{Cov}(\varepsilon_t, \varepsilon_s) = 0$, $t \neq s$.

4.1. Propiedades del Proceso AR(1) Estacionario ($|\rho| < 1$)

$$E[u_t] = 0 \tag{4}$$

$$\mathrm{Var}(u_t) = \frac{\sigma_\varepsilon^2}{1-\rho^2} \tag{5}$$

$$\mathrm{Cov}(u_t,\, u_{t-k}) = \rho^k \cdot \frac{\sigma_\varepsilon^2}{1-\rho^2} \tag{6}$$

$$\mathrm{Corr}(u_t,\, u_{t-k}) = \rho^k \tag{7}$$

Derivación de (5)*:* Tomando varianza de $u_t = \rho u_{t-1} + \varepsilon_t$:

$$\sigma_u^2 = \rho^2\sigma_u^2 + \sigma_\varepsilon^2 \;\Rightarrow\; \sigma_u^2(1-\rho^2) = \sigma_\varepsilon^2 \;\Rightarrow\; \sigma_u^2 = \frac{\sigma_\varepsilon^2}{1-\rho^2}$$

Interpretación de ρ y su relación con d

Valor de ρ	$d \approx 2(1-\rho)$	**Interpretación**
$\rho = 0$	$d = 2$	Sin autocorrelación
$\rho \to 1$	$d \to 0$	Autocorr. positiva perfecta
$\rho \to -1$	$d \to 4$	Autocorr. negativa perfecta

Rango: $-1 \leq \rho \leq 1$ y $0 \leq d \leq 4$.

4.2. Esquemas de Orden Superior

- **AR(p):** $u_t = \rho_1 u_{t-1} + \rho_2 u_{t-2} + \cdots + \rho_p u_{t-p} + \varepsilon_t$
- **MA(1):** $u_t = \varepsilon_t + \lambda\varepsilon_{t-1}$
- **ARMA(p, q):** combinación autorregresiva y de media móvil.

La prueba Durbin–Watson sólo detecta AR(1). Para órdenes superiores se requiere Breusch–Godfrey.

5. Consecuencias de Estimar con MCO bajo Autocorrelación

Teorema — Propiedades de MCO bajo AR(1)

En presencia de autocorrelación AR(1), el estimador MCO $\hat{\boldsymbol{\beta}}$:

1. **Linealidad e insesgadez:** $E[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$ (se preserva: depende de $E[\mathbf{u}] = \mathbf{0}$, no de $E[\mathbf{u}\mathbf{u}^\top]$).
2. **Consistencia:** $\hat{\boldsymbol{\beta}} \xrightarrow{p} \boldsymbol{\beta}$ (se preserva).
3. **Eficiencia (BLUE) perdida:** MCO **ya no es el mejor estimador lineal insesgado**. El estimador MCG/GLS tiene menor varianza.

5.1. Distorsión de la Varianza del Estimador

Fórmula habitual de MCO (incorrecta bajo AR(1)):

$$\widehat{\mathrm{Var}}(\hat{\beta}_2)_{\mathrm{MCO}} = \frac{\hat{\sigma}^2}{\sum x_t^2}$$

Varianza *verdadera* bajo AR(1):

$$\mathrm{Var}(\hat{\beta}_2)_{\mathrm{AR1}} = \frac{\sigma^2}{\sum x_t^2}\left[1 + 2\rho\,\frac{\sum x_t x_{t-1}}{\sum x_t^2} + 2\rho^2\,\frac{\sum x_t x_{t-2}}{\sum x_t^2} + \cdots\right]$$

Si X_t también sigue AR(1) con coeficiente r:

$$\boxed{\mathrm{Var}(\hat{\beta}_2)_{\mathrm{AR1}} \approx \mathrm{Var}(\hat{\beta}_2)_{\mathrm{MCO}} \cdot \frac{1 + r\rho}{1 - r\rho}}$$

Cuando $r > 0$ y $\rho > 0$ (frecuente en macroeconomía), este factor > 1: MCO **subestima** la varianza real.

5.2. Estimador $\hat{\sigma}^2$ Sesgado

$$\hat{\sigma}^2 = \frac{\sum_{t=1}^{n} \hat{u}_t^2}{n - k}$$

es un estimador **sesgado hacia abajo** de σ^2 bajo autocorrelación positiva, agravando la subestimación de los errores estándar.

5.3. Cuadro Completo de Consecuencias

Propiedad	**Estado**	**Consecuencia práctica**
Insesgadez	Se mantiene	$E[\hat{\beta}] = \beta$; no hay sesgo sistemático.
Consistencia	Se mantiene	Con $n \to \infty$, $\hat{\beta} \to \beta$.
Eficiencia (BLUE)	Se pierde	Existe GLS con menor varianza.
$\hat{\sigma}^2$	Sesgado $\downarrow$	Falsa sensación de precisión.
Errores estándar	Subestimados	Estadísticos t y F artificialmente altos.
Pruebas t y F	Inválidas	Error Tipo I excesivo; variables declaradas significativas cuando no lo son.
R^2	Sobreestimado	Falsa sensación de buen ajuste.
Intervalos de conf.	Demasiado estrechos	Inferencia sobre β no es confiable.

6. Métodos de Detección

6.1. Método Gráfico

Estimar el modelo por MCO, obtener $\hat{u}_t$ y graficarlos contra (a) el tiempo t, o (b) el residuo rezagado $\hat{u}_{t-1}$.

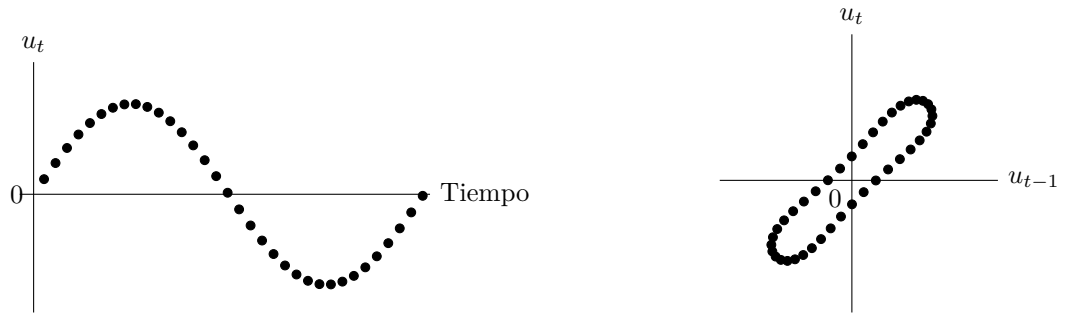

(a) Autocorrelación positiva: onda suave / nube elíptica con pendiente $+45°$

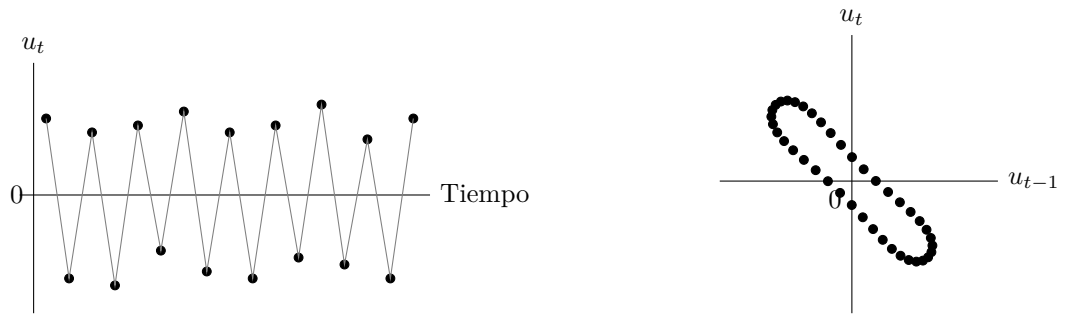

(b) Autocorrelación negativa: zigzag rápido / nube elíptica con pendiente $-45°$

Figura 2: Figura 12.3 (Gujarati & Porter, 2010, p. 416). Columna izquierda: u_t contra el tiempo. Columna derecha: u_t contra u_{t-1}.

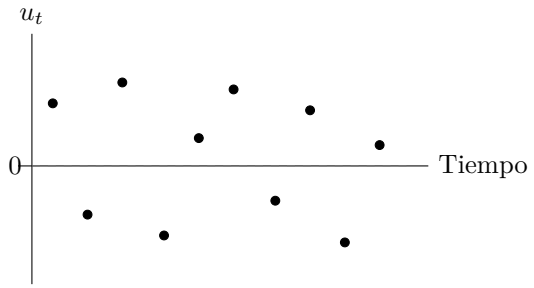

Figura 3: Sin autocorrelación: residuos $\hat{u}_t$ dispersos aleatoriamente alrededor de cero, sin ningún patrón sistemático.

6.2. Prueba de las Rachas (Geary / Wald–Wolfowitz)

6.2.1. Hipótesis

$$H_0 : \text{Los } \hat{u}_t \text{ son aleatorios (no están correlacionados en el tiempo).}$$
$$H_a : \text{Los } \hat{u}_t \text{ no son aleatorios — existe correlación serial.}$$

6.2.2. Procedimiento

1. Estimar el modelo por MCO; obtener $\hat{u}_1, \ldots, \hat{u}_n$.
2. Asignar signos ($+$ o $-$) a cada residuo.
3. Identificar las **rachas**: sucesiones ininterrumpidas del mismo signo.

Definición — Racha

Una **racha** es una subsecuencia contigua de observaciones con el mismo símbolo (signo). Ejemplo con $R = 5$ rachas:

$$\underbrace{+,+,+}_{R_1},\ \underbrace{-,-}_{R_2},\ \underbrace{+}_{R_3},\ \underbrace{-,-,-,-}_{R_4},\ \underbrace{+,+}_{R_5}$$

Sea N_1 = número de $+$, N_2 = número de $-$, $N = N_1 + N_2$.

6.2.3. Distribución Bajo H_0

$$E(R) = \frac{2N_1N_2}{N} + 1 \tag{8}$$

$$\sigma_R^2 = \frac{2N_1N_2(2N_1N_2 - N)}{N^2(N-1)} \tag{9}$$

Para N grande ($N_1 > 10$, $N_2 > 10$): $Z = (R - E(R))/\sigma_R \sim \mathcal{N}(0,1)$.

6.2.4. Regla de Decisión

$$\Pr\Big[\, E(R) - z_{\alpha/2}\,\sigma_R \le R \le E(R) + z_{\alpha/2}\,\sigma_R \,\Big] = 1 - \alpha$$

- R **dentro** del intervalo $\Rightarrow$ **no rechazar** H_0.
- R **fuera** del intervalo $\Rightarrow$ **rechazar** H_0: los errores son interdependientes.

6.2.5. Ejemplo Numérico

t	$\hat{u}_t$	Signo	t	$\hat{u}_t$	Signo
1	$+1.25$	$+$	6	-0.63	$-$
2	$+2.53$	$+$	7	-0.81	$-$
3	-0.97	$-$	8	$+4.10$	$+$
4	$+1.58$	$+$	9	$+4.30$	$+$
5	-0.64	$-$			

Secuencia: $\underbrace{+,+}_{R_1},\underbrace{-}_{R_2},\underbrace{+}_{R_3},\underbrace{-,-,-}_{R_4},\underbrace{+,+}_{R_5} \Rightarrow R = 5,\ N_1 = 5,\ N_2 = 4,\ N = 9.$

$$E(R) = \frac{2(5)(4)}{9} + 1 \approx 5.44; \qquad \sigma_R \approx 1.38$$

Al 95 %: intervalo $[2.74,\ 8.14]$. Como $R = 5 \in [2.74,\ 8.14]$, **no se rechaza** H_0.

6.3. Prueba d de Durbin–Watson

6.3.1. Hipótesis

$$\begin{aligned} H_0 &: \rho = 0 \quad \text{(no hay autocorrelación AR(1))} \\ H_a &: \rho \neq 0 \quad \text{(hay autocorrelación de primer orden)} \end{aligned}$$

6.3.2. Seis Supuestos Requeridos

1. El modelo incluye **intercepto**.
2. Las variables explicativas son **no estocásticas** (fijas en muestras repetidas).
3. Las perturbaciones siguen AR(1): $u_t = \rho u_{t-1} + \varepsilon_t$.
4. Los errores ε_t se distribuyen **normalmente**.
5. El modelo **no incluye** Y_{t-1} como regresor.
6. **No hay datos faltantes**.

6.3.3. Estadístico

$$\boxed{d \;=\; \frac{\displaystyle\sum_{t=2}^{n}(\hat{u}_t - \hat{u}_{t-1})^2}{\displaystyle\sum_{t=1}^{n}\hat{u}_t^2}}$$

6.3.4. Derivación Algébrica Completa

Expandiendo el numerador:

$$\begin{aligned} d &= \frac{\sum \hat{u}_t^2 - 2\sum \hat{u}_t\hat{u}_{t-1} + \sum \hat{u}_{t-1}^2}{\sum \hat{u}_t^2} \\ &\approx \frac{2\sum \hat{u}_t^2 - 2\sum \hat{u}_t\hat{u}_{t-1}}{\sum \hat{u}_t^2} && \left(\textstyle\sum_{t=2}^{n}\hat{u}_t^2 \approx \sum_{t=2}^{n}\hat{u}_{t-1}^2\right) \\ &= 2\left(1 - \underbrace{\frac{\sum \hat{u}_t\hat{u}_{t-1}}{\sum \hat{u}_t^2}}_{=\hat{\rho}}\right) \end{aligned}$$

Relación fundamental:

$$\boxed{d \;\approx\; 2(1-\hat{\rho})}, \qquad \hat{\rho} = \frac{\sum_{t=2}^{n}\hat{u}_t\hat{u}_{t-1}}{\sum_{t=1}^{n}\hat{u}_t^2}, \qquad 0 \le d \le 4$$

6.3.5. Regiones de Decisión

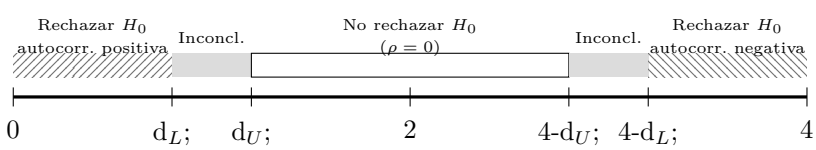

Figura 4: Regiones de decisión del estadístico Durbin–Watson.

Rango de d	$\hat{\rho}$ aprox.	**Decisión**	**Interpretación**
$0 < d < d_L$	≈ 1	Rechazar H_0	Autocorr. positiva
$d_L \le d \le d_U$	—	Inconcluso	Zona de indeterminación
$d_U < d < 4-d_U$	≈ 0	No rechazar H_0	Sin autocorrelación
$4-d_U \le d \le 4-d_L$	—	Inconcluso	Zona de indeterminación
$4-d_L < d < 4$	≈ -1	Rechazar H_0	Autocorr. negativa

Limitaciones de Durbin–Watson

1. Sólo detecta autocorrelación de **primer orden** AR(1).
2. **Inválida** si el modelo incluye Y_{t-1} como regresor.
3. **Zona de indeterminación** entre d_L y d_U.
4. Los valores críticos dependen de n, k y α.
5. Requiere errores normalmente distribuidos.

6.4. Estadístico h de Durbin (Modelos Autorregresivos)

Cuando el modelo contiene Y_{t-1} como regresor, d está sesgado. Se usa el **estadístico** h:

$$h = \hat{\rho}\sqrt{\frac{n}{1 - n\,\widehat{\mathrm{Var}}(\hat{\alpha})}} \xrightarrow{d} \mathcal{N}(0,1) \quad \text{bajo } H_0$$

donde $\hat{\alpha}$ es el coeficiente MCO de Y_{t-1}.

Condición de Validez

h no está definido si $n \cdot \widehat{\mathrm{Var}}(\hat{\alpha}) \geq 1$. En tal caso usar directamente Breusch–Godfrey.

6.5. Prueba de Breusch–Godfrey (LM)

La prueba BG supera todas las limitaciones de Durbin–Watson:

1. Detecta autocorrelación de **orden** p **arbitrario**.
2. Válida con regresores **estocásticos**, incluyendo Y_{t-1}.
3. No requiere normalidad de ε_t.

6.5.1. Procedimiento

1. Estimar el modelo original por MCO; obtener $\hat{u}_t$.
2. Estimar la regresión auxiliar:

$$\hat{u}_t = \alpha_0 + \alpha_1 X_{1t} + \cdots + \alpha_k X_{kt} + \gamma_1 \hat{u}_{t-1} + \cdots + \gamma_p \hat{u}_{t-p} + \eta_t$$

3. El estadístico LM:

$$\mathrm{LM} = (n-p)\,R^2 \xrightarrow{d} \chi^2(p) \quad \text{bajo } H_0 : \gamma_1 = \cdots = \gamma_p = 0$$

4. Versión F (muestras pequeñas):

$$F = \frac{R^2/p}{(1-R^2)/(n-k-p)} \sim F(p,\, n-k-p)$$

7. Medidas Remediales

7.1. Mínimos Cuadrados Generalizados Exactos (MCG/GLS)

Caso: ρ conocido. Transformación de cuasi-diferencias:

$$Y_t^* = Y_t - \rho\, Y_{t-1}$$
$$X_t^* = X_t - \rho\, X_{t-1}$$

Modelo transformado ($t = 2, \ldots, n$):

$$Y_t^* = \beta_1(1-\rho) + \beta_2 X_t^* + \varepsilon_t$$

ε_t es ruido blanco: se cumplen todos los supuestos del MCRL.

7.1.1. Transformación de Prais–Winsten (Primera Observación)

La primera observación no puede cuasi-diferenciarse. Se recupera con:

$$Y_1^* = \sqrt{1-\rho^2} \cdot Y_1, \qquad X_1^* = \sqrt{1-\rho^2} \cdot X_1$$

En muestras pequeñas, descartar la primera observación (Cochrane–Orcutt) genera pérdida significativa de eficiencia.

7.2. MCG Factibles (FGLS): ρ Desconocido

7.2.1. Método de Cochrane–Orcutt (CO)

1. Estimar por MCO; obtener $\hat{u}_t$.
2. Regresar $\hat{u}_t$ sobre $\hat{u}_{t-1}$ para estimar $\hat{\rho}$:

$$\hat{\rho} = \frac{\sum_{t=2}^{n} \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^{n} \hat{u}_t^2}$$

3. Transformar: $\tilde{Y}_t = Y_t - \hat{\rho}\, Y_{t-1}$, $\tilde{X}_t = X_t - \hat{\rho}\, X_{t-1}$.
4. Re-estimar por MCO con las variables transformadas.
5. Actualizar $\hat{\rho}$ con los nuevos residuos y repetir hasta convergencia.

CO vs. Prais–Winsten

Cochrane–Orcutt **descarta** la primera observación en cada iteración (costoso cuando $n < 50$). Prais–Winsten la retiene aplicando $\sqrt{1-\hat{\rho}^2}$ y es preferible en la práctica.

7.3. Errores Estándar Robustos — Newey–West (HAC)

En muestras **grandes**, se mantienen los coeficientes MCO pero se corrige la inferencia con la matriz de varianza–covarianza HAC:

$$\widehat{\mathrm{Var}}(\hat{\boldsymbol{\beta}})_{\mathrm{NW}} = (\mathbf{X}'\mathbf{X})^{-1}\hat{\mathbf{S}}(\mathbf{X}'\mathbf{X})^{-1}$$

donde $\hat{\mathbf{S}} = \hat{\Gamma}_0 + \sum_{j=1}^{m} w_j(\hat{\Gamma}_j + \hat{\Gamma}_j')$, con pesos de Bartlett $w_j = 1 - \frac{j}{m+1}$ y truncamiento $m \approx \lfloor 4(n/100)^{2/9} \rfloor$.

Propiedades:

- Coeficientes idénticos a MCO; sólo se corrigen los errores estándar.
- Consistente bajo heterocedasticidad y autocorrelación de cualquier orden hasta rezago m.
- No requiere especificar la forma de Ω.

Hoja de Fórmulas — Referencia Rápida

Fórmulas Esenciales — Autocorrelación

Supuesto clásico:	$E(u_i u_j) = 0, \quad i \neq j$	(A1)
Proceso AR(1):	$u_t = \rho\, u_{t-1} + \varepsilon_t, \quad \lvert\rho\rvert < 1$	(A2)
Varianza AR(1):	$\mathrm{Var}(u_t) = \dfrac{\sigma_\varepsilon^2}{1-\rho^2}$	(A3)
Covarianza AR(1):	$\mathrm{Cov}(u_t, u_{t-k}) = \rho^k \dfrac{\sigma_\varepsilon^2}{1-\rho^2}$	(A4)
Estadístico DW:	$d = \dfrac{\sum_{t=2}^{n}(\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^{n}\hat{u}_t^2} \approx 2(1-\hat{\rho})$	(A5)
Estimador $\hat{\rho}$:	$\hat{\rho} = \dfrac{\sum \hat{u}_t \hat{u}_{t-1}}{\sum \hat{u}_t^2}$	(A6)
Rango de d :	$0 \leq d \leq 4$	(A7)
Media de rachas:	$E(R) = \dfrac{2N_1N_2}{N} + 1$	(A8)
Varianza de rachas:	$\sigma_R^2 = \dfrac{2N_1N_2(2N_1N_2 - N)}{N^2(N-1)}$	(A9)
Estadístico h :	$h = \hat{\rho}\sqrt{\dfrac{n}{1 - n\,\widehat{\mathrm{Var}}(\hat{\alpha})}}$	(A10)
Prueba BG (LM):	$\mathrm{LM} = (n-p)R^2 \sim \chi^2(p)$	(A11)
Transf. GLS:	$Y_t^* = Y_t - \rho Y_{t-1}; \quad X_t^* = X_t - \rho X_{t-1}$	(A12)
Prais–Winsten ($t=1$) :	$Y_1^* = \sqrt{1-\rho^2}\, Y_1; \quad X_1^* = \sqrt{1-\rho^2}\, X_1$	(A13)
Var. verdadera MCO:	$\mathrm{Var}(\hat{\beta}_2)_{\mathrm{AR1}} \approx \mathrm{Var}(\hat{\beta}_2)_{\mathrm{MCO}} \cdot \dfrac{1+r\rho}{1-r\rho}$	(A14)

Prueba	**Orden**	**Condición**	**Limitación principal**
Gráfico	Cualquiera	Residuos MCO	Subjetivo
Rachas (Geary)	Cualquiera	Sólo signos	No cuantifica magnitud
Durbin–Watson	AR(1)	No Y_{t-1}	Zona inconclusa; sólo orden 1
Durbin h	AR(1)	Modelo AR	Requiere $n \cdot \widehat{\mathrm{Var}} < 1$
Breusch–Godfrey	AR(p)	Residuos MCO	Elección de p

Gujarati, D. N. & Porter, D. C. (2010). *Econometría*, 5.ª ed., Cap. 12. McGraw-Hill.
Wooldridge, J. M. (2016). *Introductory Econometrics*, 6th ed., Cap. 12. Cengage.