Solución Completa – Problema 2.15

Tabla 2.8: Gasto en Comida y Gasto Total (55 familias, India)

Gujarati – Econometría Básica, Capítulo 2

Descripción del Problema

Se cuenta con datos de 55 familias de la India sobre su **Gasto en Comida** (variable dependiente, Y) y su **Gasto Total** (variable independiente, X), ambas medidas en rupias. El objetivo es estudiar la relación entre ambas variables, diagnosticar y corregir el problema de **heteroscedasticidad**.

El modelo de regresión es:

$$\text{Gasto_en_Comida}_i = \beta_0 + \beta_1 \cdot \text{Gasto_Total}_i + u_i, \quad i = 1, 2, \ldots, 55$$

Inciso A: Regresión del Gasto en Comida sobre el Gasto Total

Comandos en Stata

Stata – Regresión MCO

```
. rename var2 Gasto_en_Comida
. rename var3 Gasto_Total
. reg Gasto_en_Comida Gasto_Total
. twoway (scatter Gasto_en_Comida Gasto_Total) (lfit
Gasto_en_Comida Gasto_Total)
```

Gráfico de Dispersión con Línea Ajustada

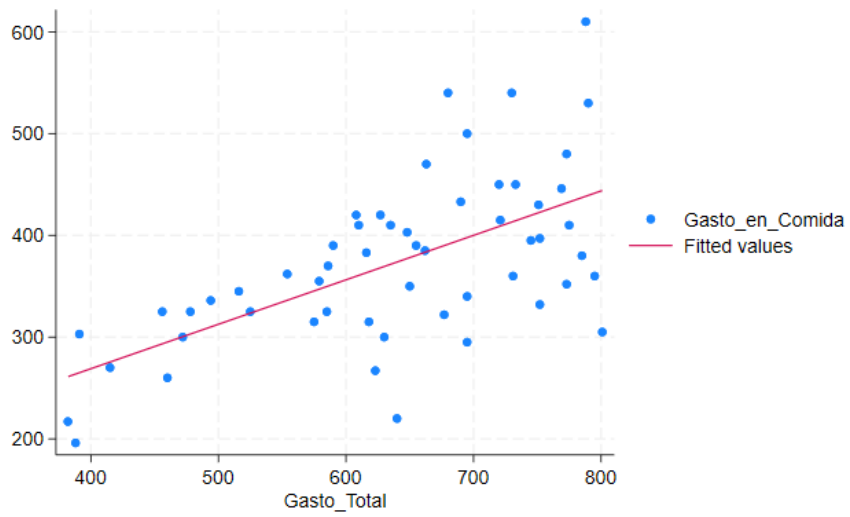

Figura 1: Dispersión de Gasto en Comida vs. Gasto Total con línea de regresión MCO ajustada. Se observa una tendencia positiva aunque con variabilidad creciente.

Resultados de la Regresión (MCO)

Cuadro 1: Resultados de Regresión: Gasto_en_Comida sobre Gasto_Total

Variable	Coef.	Error Est.	t	P> $\lvert t \rvert$	IC 95 % Inf.	IC 95 % Sup.
Gasto_Total	0.4368	0.0783	5.58	0.000	0.2797	0.5939
_cons	94.2088	50.8563	1.85	0.070	−7,7961	196.2137

Cuadro 2: Estadísticos Globales del Modelo

Estadístico	Valor	Estadístico	Valor
N observaciones	55	R-cuadrado	0.3698
F(1, 53)	31.10	R-cuad. ajustado	0.3579
Prob > F	0.0000	Raíz ECM (RMSE)	66.856

Interpretación

Interpretación de la Regresión MCO

- **Intercepto ($\hat{\beta}_0 = 94{,}21$):** Cuando el gasto total es cero, el gasto estimado en comida sería de 94.21 rupias (sin interpretación económica directa, ya que no se puede tener gasto total igual a cero en la práctica).
- **Pendiente ($\hat{\beta}_1 = 0{,}4368$):** Por cada rupia adicional de gasto total, el gasto en comida aumenta en promedio **0.4368 rupias**. Es decir, aproximadamente el 43.7 % del ingreso marginal se destina a alimentación.
- **Significancia:** El coeficiente de Gasto_Total es estadísticamente significativo al 1 % (p-valor = 0.000). El intercepto es marginalmente significativo (p = 0.070).
- **Bondad de ajuste:** $R^2 = 0{,}3698$ indica que el gasto total explica el **36.98 %** de la variación en el gasto en comida, razonable para datos de corte transversal.
- **Ecuación estimada:**

$$\widehat{\text{Gasto_en_Comida}} = 94{,}2088 + 0{,}4368 \cdot \text{Gasto_Total}$$

Inciso B: Gráfica de Residuos vs. Gasto Total

Comandos en Stata

Stata – Generación y Gráfica de Residuos

```
. predict errores, residuals
. gen R = errores^2
. twoway (scatter R Gasto_Total), ///
title(Residuos al cuadrado vs Gasto Total")

* Gráficos diagnósticos adicionales:
. rvfplot
. rvpplot Gasto_Total
. kdensity errores, normal
. lvr2plot
```

Gráfico Principal: $\hat{u}^2$ vs. Gasto Total

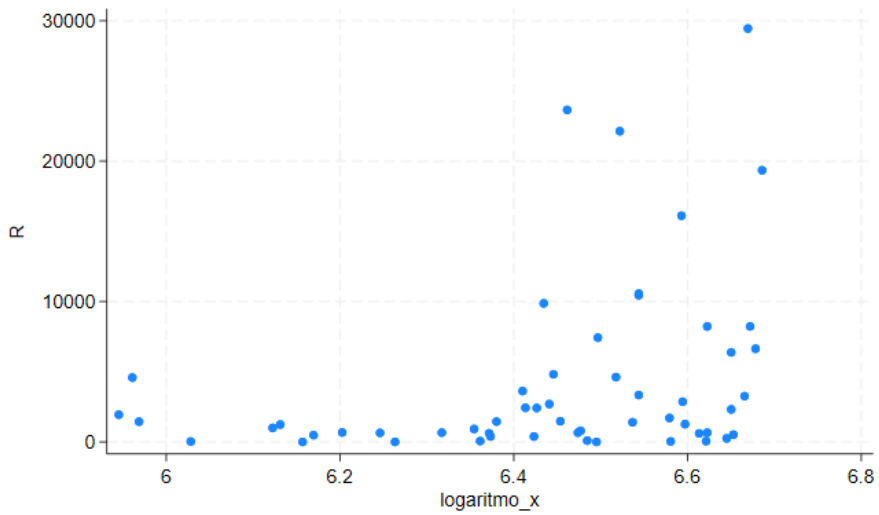

Figura 2: Residuos al cuadrado ($\hat{u}_i^2$) contra Gasto Total. El patrón de "abanico" o "cono" es la señal clásica de heteroscedasticidad: la varianza de los errores crece con la variable independiente.

Gráficos Diagnósticos Adicionales

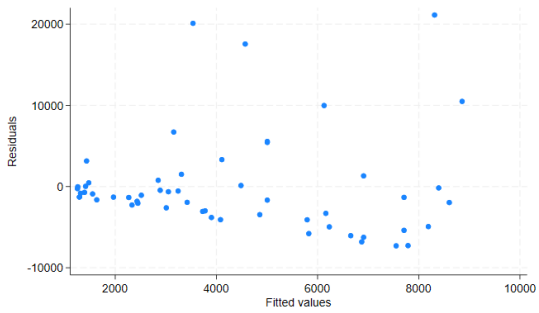

(a) Residuos vs. valores ajustados (`rvfplot`). La dispersión creciente confirma la heteroscedasticidad.

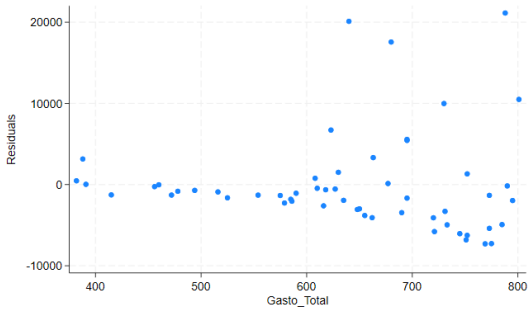

(b) Residuos vs. Gasto Total (`rvpplot`). Patrón similar al gráfico de $\hat{u}^2$.

Figura 3: Gráficos de residuos de Stata. Ambos muestran varianza no constante.

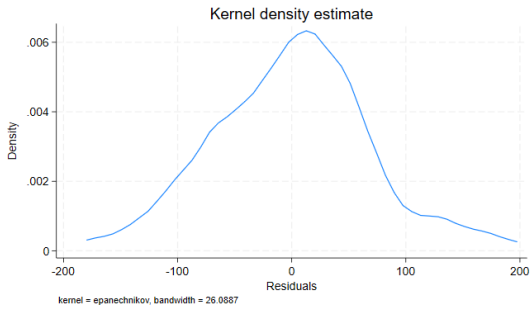

(a) Densidad kernel de los residuos vs. distribución normal. Cola derecha ligeramente más pesada, consistente con asimetría positiva.

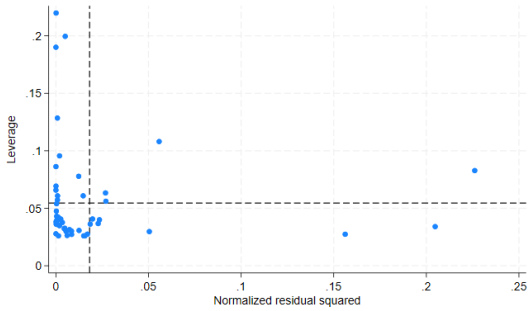

(b) Leverage vs. residuos al cuadrado (`lvr2plot`). Permite identificar observaciones influyentes.

Figura 4: Diagnósticos adicionales: distribución de errores y observaciones influyentes.

Análisis Visual

Diagnóstico Visual de Heteroscedasticidad

- Para valores bajos de Gasto_Total (alrededor de 380–500), los residuos al cuadrado son relativamente **pequeños y concentrados** cerca de cero.
- Conforme el Gasto_Total aumenta (600–800), la dispersión de $\hat{u}^2$ se vuelve **notablemente mayor**, con valores que alcanzan hasta 30,000.
- Este patrón de **abanico o cono** (ver Figura **??**) es la señal clásica de heteroscedasticidad.
- El `rvfplot` (Figura **??**) confirma el mismo patrón: la nube de puntos se ensancha hacia la derecha.

- La densidad kernel (Figura **??**) muestra asimetría positiva en los residuos, señal adicional de mal especificación o heteroscedasticidad.
- **Conclusión visual:** Se sospecha fuertemente la presencia de heteroscedasticidad. El supuesto $\text{Var}(u_i) = \sigma^2$ no se satisface.

Inciso C: Pruebas Formales de Heteroscedasticidad

Prueba de Breusch-Pagan / Cook-Weisberg (LM)

4.1.1. Hipótesis Formales

$$H_0 : \text{Var}(u_i \mid X_i) = \sigma^2 \quad \text{(varianza constante — homocedasticidad)}$$
$$H_a : \text{Var}(u_i \mid X_i) = f(X_i) \quad \text{(varianza depende de } X \text{ — heteroscedasticidad)}$$

Estadístico: $\text{LM} = n \cdot R^2_{\text{aux}} \sim \chi^2(p)$ bajo H_0.
Regla de decisión: Rechazar H_0 si p-valor $< \alpha$.

4.1.2. Comando en Stata

Stata – Prueba Breusch-Pagan

```
. estat hettest
```

4.1.3. Resultados

Cuadro 3: Prueba Breusch-Pagan/Cook-Weisberg

Hipótesis nula	H_0: Varianza constante (homocedasticidad)	
$\chi^2(1)$	=	7.18
Prob $> \chi^2$	=	**0.0074**

4.1.4. Interpretación

Conclusión – Breusch-Pagan

El estadístico $\chi^2(1) = 7{,}18$ con p-valor $= 0{,}0074 < 0{,}01$. Se **rechaza la hipótesis nula de varianza constante** al 1 % de significancia. La prueba confirma formalmente la presencia de **heteroscedasticidad** en el modelo original.

Prueba de White

4.2.1. Hipótesis Formales

$$H_0 : \text{Var}(u_i \mid X_i) = \sigma^2 \quad \text{(homocedasticidad)}$$

$$H_a : \text{Var}(u_i) \text{ depende de } X_i, X_i^2 \text{ y/o sus productos cruzados}$$

4.2.2. Comando en Stata

Stata – Prueba de White

```
. estat imtest, white
```

4.2.3. Resultados

Cuadro 4: Prueba de White para Heteroscedasticidad No Restringida

Fuente	χ^2	gl	p-valor
Heteroscedasticidad	4.14	2	0.1259
Asimetría (Skewness)	7.81	1	0.0052
Curtosis (Kurtosis)	3.50	1	0.0615
Total (IM-test)	**15.45**	4	**0.0038**

Conclusión – Prueba de White

- La prueba de White para heteroscedasticidad ($\chi^2 = 4{,}14$, p $= 0{,}1259 > 0{,}05$) **no rechaza** H_0 aisladamente.
- La descomposición Cameron-Trivedi muestra que el total es significativo ($\chi^2 = 15{,}45$, p $= 0{,}0038$), principalmente impulsado por la **asimetría** de los residuos, consistente con lo observado en la Figura **??**.
- En conjunto con B-P, la evidencia apoya la presencia de heteroscedasticidad.

Prueba de Park

4.3.1. Fundamento Teórico

Park (1966) propone que $\sigma_i^2 = \sigma^2 X_i^\beta e^{v_i}$. Tomando logaritmos:

$$\ln(\hat{u}_i^2) = \alpha_0 + \alpha_1 \ln(X_i) + v_i$$

Si α_1 es significativo, existe heteroscedasticidad.

4.3.2. Comandos en Stata

Stata – Prueba de Park

```
. gen ln_u2 = ln(errores^2)
. gen ln_x = ln(Gasto_Total)
. reg ln_u2 ln_x
. twoway (scatter ln_u2 ln_x) (lfit ln_u2 ln_x), ///
xtitle("ln(Gasto Total)") ytitle("ln(u^2)")
```

4.3.3. Gráfico Park: $\ln(\hat{u}^2)$ vs. $\ln(X)$

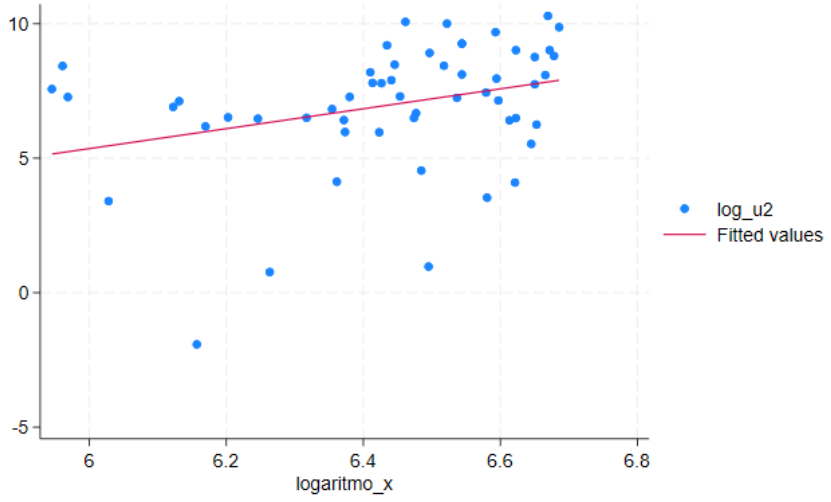

Figura 5: Prueba de Park: $\ln(\hat{u}_i^2)$ contra ln(Gasto_Total). La pendiente positiva y significativa ($\hat{\alpha}_1 = 3{,}70$, p = 0.021) confirma heteroscedasticidad de tipo potencial.

4.3.4. Resultados de Stata

Cuadro 5: Prueba de Park: $\ln(\hat{u}^2)$ sobre ln(Gasto_Total)

Variable	Coef.	Error Est.	t	p-valor	IC 95 % Inf.	IC 95 % Sup.
ln(Gasto_Total)	3.7032	1.5519	2.39	0.0206	0.5907	6.8157
_cons	−16,8629	10.0014	−1,69	0.0977	−36,928	3.203
$R^2 = 0{,}0970$			F(1,53) = 5.69,	p = 0.0206		

Conclusión – Prueba de Park

$\hat{\alpha}_1 = 3{,}7032$ significativo (p = 0.0206 < 0,05). Se rechaza H_0. La varianza del error crece como $X^{3{,}7}$, indicando heteroscedasticidad fuerte. La Figura **??** muestra visualmente esta relación creciente.

Prueba de Glejser

4.4.1. Fundamento Teórico

Glejser (1969) propone regresar $|\hat{u}_i|$ sobre transformaciones de X_i:

1. $|\hat{u}_i| = \alpha_0 + \alpha_1 X_i + v_i$ (lineal)
2. $|\hat{u}_i| = \alpha_0 + \alpha_1 \sqrt{X_i} + v_i$ (raíz cuadrada)
3. $|\hat{u}_i| = \alpha_0 + \alpha_1 \dfrac{1}{X_i} + v_i$ (inversa)

4.4.2. Comandos en Stata

Stata – Prueba de Glejser

```
. gen abs_u = abs(errores)
. gen sqrt_x = sqrt(Gasto_Total)
. gen inv_x = 1/Gasto_Total
. reg abs_u Gasto_Total      * Forma 1: lineal
. twoway (scatter abs_u Gasto_Total)(lfit abs_u Gasto_Total)
. reg abs_u sqrt_x        * Forma 2: raíz cuadrada
. twoway (scatter abs_u sqrt_x)(lfit abs_u sqrt_x)
. reg abs_u inv_x        * Forma 3: inversa
```

4.4.3. Gráficos de las Tres Formas de Glejser

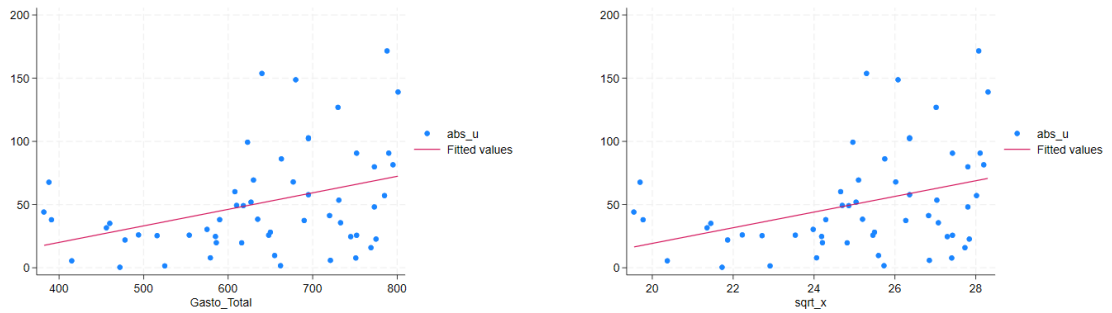

(a) Forma 1 – Lineal: $|\hat{u}_i|$ vs. X_i. Pendiente = 0.1307, t = 2,88, p = 0.006.

(b) Forma 2 – Raíz cuadrada: $|\hat{u}_i|$ vs. $\sqrt{X_i}$. Pendiente = 6.199, t = 2,80, p = 0.007.

Figura 6: Prueba de Glejser – Formas 1 y 2. En ambos casos el coeficiente $\hat{\alpha}_1$ es positivo y significativo (p < 0.01), rechazando H_0 de homocedasticidad.

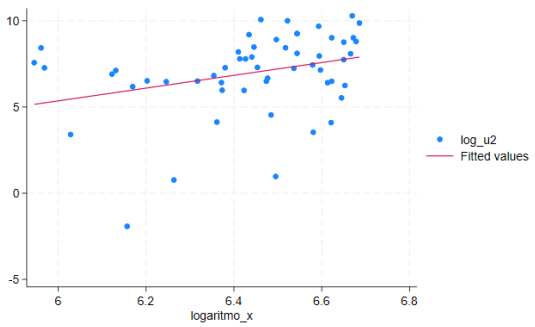

Figura 7: Forma Park/Log: $\ln(\hat{u}_i^2)$ vs. $\ln(X_i)$ (también aplicable como Forma 3 de Glejser en escala logarítmica). Ver análisis completo en Figura **??**.

4.4.4. Resultados por Forma Funcional

Forma 1 – Lineal

Cuadro 6: Glejser Forma 1: `reg abs_u Gasto_Total`

Variable	Coef.	Error Est.	t	p-valor	IC 95 % Inf.	IC 95 % Sup.
Gasto_Total	0.1307	0.0454	**2.88**	**0.006**	0.0396	0.2218
_cons	−32,22	29.49	−1,09	0.280	−91,37	26.93
$R^2 = 0{,}135$			F(1,53) = 8.28,	p = 0.006		

Forma 2 – Raíz Cuadrada

Cuadro 7: Glejser Forma 2: `reg abs_u sqrt_x`

Variable	Coef.	Error Est.	t	p-valor	IC 95 % Inf.	IC 95 % Sup.
sqrt_x	6.1994	2.2134	**2.80**	**0.007**	1.7598	10.639
_cons	−104,72	55.95	−1,87	0.067	−216,95	7.51
$R^2 = 0{,}129$			F(1,53) = 7.84,	p = 0.007		

Forma 3 – Inversa

Cuadro 8: Glejser Forma 3: `reg abs_u inv_x`

Variable	Coef.	Error Est.	t	p-valor	IC 95 % Inf.	IC 95 % Sup.
inv_x	−37,567,74	15,057.74	**−2,49**	**0.016**	−67,769,75	−7,365,72
_cons	112.43	25.07	4.48	0.000	62.15	162.71
$R^2 = 0{,}105$			F(1,53) = 6.22,	p = 0.016		

4.4.5. Resumen Glejser

Cuadro 9: Síntesis Prueba de Glejser

Forma	$\hat{\alpha}_1$	t	p-valor	R^2	Decisión
1. Lineal	0,1307	2,88	0,006	0,135	Rechazar H_0
2. Raíz	6,1994	2,80	0,007	0,129	Rechazar H_0
3. Inversa	−37,567	−2,49	0,016	0,105	Rechazar H_0

Conclusión – Prueba de Glejser

- Las **tres formas funcionales** rechazan H_0 ($p < 0.05$).
- La **Forma 1 lineal** tiene el mejor ajuste ($R^2 = 0{,}135$).
- La **Forma 2 raíz** ($p = 0.007$) sugiere $\sigma_i^2 \propto X_i$, la forma más común en datos de gasto familiar.
- Los gráficos (Figuras **??** y **??**) confirman visualmente la relación cre-

ciente entre $|\hat{u}|$ y las transformaciones de X.

Prueba de Goldfeld-Quandt

4.5.1. Fundamento Teórico

Goldfeld-Quandt (1965): ordenar por X, eliminar c observaciones del centro, estimar MCO por subgrupo y calcular:

$$\lambda = \frac{\mathrm{SCR}_2/(m-k)}{\mathrm{SCR}_1/(m-k)} = \frac{\mathrm{SCR}_2}{\mathrm{SCR}_1} \sim F(m-k,\ m-k)$$

4.5.2. Hipótesis Formales

$$H_0 : \sigma_1^2 = \sigma_2^2 \qquad H_a : \sigma_2^2 > \sigma_1^2$$

4.5.3. Comandos en Stata

Stata – Prueba de Goldfeld-Quandt

```
* Grupo 1: observaciones 1--25 (Gasto_Total bajo)
. reg Gasto_en_Comida Gasto_Total if _n <= 25
* Grupo 2: observaciones 31--55 (Gasto_Total alto)
. reg Gasto_en_Comida Gasto_Total if _n >= 31
```

4.5.4. Partición de Observaciones ($c = 5$)

Cuadro 10: Partición de Observaciones – Prueba Goldfeld-Quandt

Grupo	Observaciones	Gasto Total (rango)	n
Grupo 1 (bajo)	obs 1–25	382–635 rupias	25
Eliminadas	*obs 26–30*	*640–662 rupias*	*5*
Grupo 2 (alto)	obs 31–55	663–801 rupias	25

4.5.5. Resultados y Cálculo del Estadístico

Cuadro 11: Regresiones por Grupo – Goldfeld-Quandt

Estadístico	Grupo 1 (bajo)	Grupo 2 (alto)
n	25	25
Raíz ECM	43.389	83.269
SCR	**43,300.21**	**159,475.36**
gl residual	23	23

$$\lambda = \frac{159{,}475{,}36}{43{,}300{,}21} = \mathbf{3{,}683} > F_{0{,}05}(23, 23) = 2{,}014 \quad \Rightarrow \quad \textbf{Se rechaza } H_0$$

Conclusión – Goldfeld-Quandt

$\lambda = 3{,}683$ con p-valor $= 0{,}0014 < 0{,}01$. Se rechaza H_0 al 1 %. La varianza del Grupo 2 (gasto alto) es estadísticamente mayor que la del Grupo 1. La raíz ECM del Grupo 2 (83.27) prácticamente duplica la del Grupo 1 (43.39).

Inciso D: Corrección mediante Transformación Logarítmica

Justificación Teórica

El modelo log-log estabiliza la varianza cuando $\sigma_i^2 \propto X_i$:

$$\ln(\text{Gasto_en_Comida}_i) = \beta_0 + \beta_1 \ln(\text{Gasto_Total}_i) + u_i$$

donde β_1 es la **elasticidad-gasto en comida**.

Comandos en Stata

Stata – Transformación Logarítmica

```
. gen logaritmo_y = ln(Gasto_en_Comida)
. gen logaritmo_x = ln(Gasto_Total)
. reg logaritmo_y logaritmo_x
. estat hettest
. predict errores_log, residuals
. rvfplot
. kdensity errores_log, normal
```

Resultados

Cuadro 12: Regresión Log-Log: logaritmo_y sobre logaritmo_x

Variable	Coef.	Err. Est.	t	P> $\lvert t \rvert$	IC 95 % Inf.	IC 95 % Sup.
logaritmo_x	0.7363	0.1207	6.10	0.000	0.4942	0.9784
_cons	1.1543	0.7780	1.48	0.144	−0,4061	2.7147

Cuadro 13: Estadísticos Globales – Modelo Log-Log

N observaciones	55	R-cuadrado	0.4125
F(1, 53)	37.21	R-cuad. ajustado	0.4014
Prob > F	0.0000	Raíz ECM	0.17662

Verificación de Heteroscedasticidad (Post-corrección)

Cuadro 14: Breusch-Pagan en el Modelo Log-Log

$\chi^2(1)$	=	1.60
Prob $> \chi^2$	=	**0.2052**

Interpretación

Interpretación del Modelo Log-Log

1. **Elasticidad ($\hat{\beta}_1 = 0{,}7363$):** Por cada 1 % de aumento en el gasto total, el gasto en comida aumenta **0.7363 %**. Los alimentos se comportan como **bien normal no de lujo** (Ley de Engel: la proporción del ingreso destinada a alimentos disminuye conforme el ingreso crece).
2. **Mejora en el ajuste:** R^2 mejora de 0.3698 (lineal) a **0.4125** (log-log).
3. **Corrección de heteroscedasticidad:** Breusch-Pagan post-corrección: $\chi^2(1) = 1{,}60$, p $= 0{,}2052 > 0{,}05$. **No se rechaza** H_0. La transformación logarítmica **corrigió exitosamente** el problema.
4. **Ecuación estimada:**

$$\widehat{\ln(\mathrm{GC})} = 1{,}1543 + 0{,}7363 \cdot \ln(\mathrm{GT}) \quad \Leftrightarrow \quad \widehat{\mathrm{GC}} = e^{1{,}1543} \cdot \mathrm{GT}^{0{,}7363}$$

Inciso E: Errores Estándar Robustos de White

Fundamento Teórico

White (1980) propone estimar la varianza de $\hat{\beta}$ de forma consistente:

$$\widehat{\mathrm{Var}}_{HC}(\hat{\boldsymbol{\beta}}) = (X'X)^{-1} \left(\sum_{i=1}^{n} \hat{u}_i^2 x_i x_i' \right) (X'X)^{-1}$$

Comando en Stata

Stata – Regresión con Errores Robustos de White

```
. reg Gasto_en_Comida Gasto_Total, robust
```

Resultados

Cuadro 15: Regresión con Errores Robustos (White)

Variable	Coef.	Err. Robusto	t	P> $\|t\|$	IC 95 % Inf.	IC 95 % Sup.
Gasto_Total	0.4368	0.0743	5.88	0.000	0.2879	0.5857
_cons	94.2088	43.2631	2.18	0.034	7.434	180.984

Comparación MCO vs. Robustos

Cuadro 16: Comparación de Errores Estándar

Variable	Coef.	Error MCO	Error Robusto
Gasto_Total	0.4368	0.0783	**0.0743**
_cons	94.2088	50.8563	**43.2631**

Conclusión – Errores Robustos y Decisión Final

1. Los errores robustos son *ligeramente menores*: los MCO *sobreestimaban* modestamente la incertidumbre.
2. El intercepto cambia su significancia: con MCO p = 0.070 (marginalmente sig.), con robustos p = 0.034 (**significativo al 5 %**).
3. Los coeficientes no cambian (solo cambian los errores estándar).
4. **Recomendación:**
   - **Errores robustos**: solución sencilla cuando se desea mantener la interpretación en niveles.
   - **Modelo log-log**: preferible por mayor eficiencia, mejor R^2 y corrección estructural de la heteroscedasticidad.
   - **Especificación final recomendada**: modelo log-log (B-P post: p = 0.205, R^2 = 0,41, elasticidad = 0.74).

Resumen Ejecutivo

Cuadro 17: Resumen de Resultados por Inciso

Inc.	Procedimiento	Conclusión Principal
A	Regresión MCO lineal	$\hat{Y} = 94{,}21 + 0{,}437X$; $R^2 = 0{,}37$; sig. al 1 %
B	Gráfica $\hat{u}^2$ vs. X (Fig. **??**)	Patrón de abanico; heteroscedasticidad visual clara
C	B-P (p=0.007); White (p=0.126 / IM=0.004); Park ($t = 2{,}39$); Glejser (3 formas, p<0.02); GQ ($\lambda = 3{,}68$)	Todas confirman heteroscedasticidad creciente con X
D	Modelo log-log + B-P post	Heteroscedasticidad corregida (p=0.205); elasticidad=0.74; R^2=0.41
E	Errores robustos de White	Diferencias pequeñas; modelo log-log es la opción preferida

Nota sobre los Archivos Gráficos Utilizados

Los gráficos integrados en este documento corresponden a los archivos `.png` generados en Stata y disponibles en el directorio de trabajo: `relacion_u_2_y_gasto_total.png`, `glejser_abs_u_gasto_total.png`, `glejser_abs_u_sqrt_x.png`, `glejser_in_u2_in_x.png`, `dispersion_con_linea_ajustada.png`, `rvfplot.png`, `rvpplot.png`, `kdensity_errores.png`, `lvr2plot.png`. Para compilar, todos deben estar en el mismo directorio que el archivo `.tex`.

Fuente de los datos: Chandan Mukherjee, Howard White y Marc Wuyts, *Econometrics and Data Analysis for Developing Countries*, Routledge, Nueva York, 1998, p. 457.